


데이터 불균형 문제 I

박성호

컴퓨터공학부

Agenda

1. 데이터 불균형 문제 (Data Imbalance Problems)
2. 분류 모델의 성능 평가 (Evaluation of classifiers; Confusion matrix)
3. 데이터 불균형 솔루션 (Solutions for Data Imbalance Problems)
4. 언더샘플링 (Undersampling)



데이터 불균형 문제 (Data Imbalance Problems)

■ 데이터 불균형 문제 (Data Imbalance Problems)

- 데이터 불균형 문제는 현장의 데이터를 다룰 때 흔하게 접하게 되는 문제
 - ✓ Telecommunication, web, finance-world, ecology, biology, medicine, production facility, quality control,...
- “Most of the standard learning algorithms consider a balanced training set”



Reference#1: López, V., Fernández, A., García, S., Palade, V., & Herrera, F. (2013). An insight into classification with imbalanced data: Empirical results and current trends on using data intrinsic characteristics. Information Sciences, 250, 113-141.

Reference#2 <https://www.jagranjosh.com/general-knowledge/list-of-indian-states-on-the-basis-of-sex-ratio-1521445111-1>

데이터 불균형 문제 (Data Imbalance Problems)

우리나라 암 발생률(남성)

■ 발병 남성 ■ 정상 남성




* 국가 암 정보센터(2016)

제조업의 불량 판정




신용 카드 사기 탐지


데이터 불균형 문제 (Data Imbalance Problems)



(a) Visual examples of eight thorax disease, and (b) distribution of classes in the dataset.



(a) Visual examples of 5 ordered classes sub types of diabetic retinopathy, and (b) distribution of classes in the dataset.





Label	Voxel Count
Label 0	8729308
Label 1	11698
Label 2	126003
Label 4	60991

Sample segmentation of brain tumor with corresponding voxels count for each class.

데이터 불균형 문제 (Data Imbalance Problems)

- 불균형 데이터의 분포

● 이상
● 정상



데이터 불균형 문제 (Data Imbalance Problems)

- 불균형 데이터란?

“정상” 범주의 관측치 수와
“이상” 범주의 관측치 수의
차이가 크게 나타나는 경우

데이터 불균형 문제 (Data Imbalance Problems)

■ 데이터 불균형 문제 (Data Imbalance Problems)


- 데이터 불균형 문제는 지도학습의 분류예측 문제(classification)에서 하나의 범주(class)에 속하는 표본의 수가 타 범주의 표본 수 보다 현저하게 적은 경우의 문제를 말한다.
- 이 때, 표본수가 상대적으로 많은 범주를 **majority class**라고 하며, 상대적으로 적은 범주를 **minority class**라고 한다.
- (문제점) 데이터 불균형 문제를 대상으로 학습모델을 적용 시, 관측치 수의 영향으로 **majority class에 과적합(overfitting)**이 발생하게 되고, 결국 학습모델의 **성능 저하(inaccurate performance)** 문제가 발생한다.



왜 문제인가?

양품을 정확히 분류 vs 불량품을 정확히 분류


→ 불량품(이상)을 정확히 분류 하는 것이 중요



왜 문제인가?

음성을 정확히 분류 vs 양성(이상)을 정확히 분류


→ 양성(이상)을 정확히 분류 하는 것이 중요




데이터 불균형 문제의 기본 개념

- 분류예측 학습모델 측면의 입장

● 이상
● 정상




정상 관측치 분포



실제 **이상** 관측치 분포



데이터 불균형 문제의 기본 개념

- 분류예측 학습모델 측면의 입장




데이터 불균형 문제의 기본 개념

- 실제 학습 시, ...




데이터 불균형 문제의 기본 개념

- 이상과 현실의 차이(gap)




데이터 불균형 문제의 기본 개념

- 차이(gap)을 어떻게 바로잡을 수 있을까?




데이터 불균형 문제의 기본 개념

- 차이(gap)을 어떻게 바로잡을 수 있을까?



Agenda

1. 데이터 불균형 문제 (Data Imbalance Problems)
2. 분류 모델의 성능 평가 (Evaluation of classifiers; Confusion matrix)
3. 데이터 불균형 솔루션 (Solutions for Data Imbalance Problems)
4. 언더샘플링 (Undersampling)



분류 모델의 예측성능 평가


- 정오행렬 (Confusion matrix)

Confusion matrix (정오행렬)		예측	
		이상	정상
실제	이상	A	B
	정상	C	D

- 예측 정확도 (Accuracy)


$$\frac{A + D}{A + B + C + D}$$

분류 모델의 예측성능 평가



분류 모델의 예측성능 평가

- 정오행렬 (Confusion matrix)

혼돈행렬 (Confusion matrix)		예측	
		이상	정상
실제	이상	5	5
	정상	0	40

- 예측 정확도 (Accuracy)

$$\text{Accuracy} = \frac{5 + 40}{5 + 5 + 0 + 40} = \frac{45}{50} = 0.9$$



왜 문제인가?

양품을 정확히 분류 VS 불량품을 정확히 분류

→ 불량품(이상)을 정확히 분류 하는 것이 중요

적절한 분류경계선이 형성되지 못함

→ 불량품(이상)을 정확히 찾아내지 못함

높은 예측 정확도를 보임(?)

→ **모델 성능 왜곡** 가능성이 있음

분류 모델의 예측성능 평가


- 불균형 상황에 적절한 평가 지표

정오행렬 (Confusion matrix)		예측	
		이상 (1) (+)	정상 (0) (-)
실제	이상 (1) (+)	n_{11}	n_{10}
	정상 (0) (-)	n_{01}	n_{00}

- Sensitivity, true positive, recall $= n_{11}/(n_{11} + n_{10})$
- Specificity, true negative $= n_{00}/(n_{01} + n_{00})$
- Precision $= n_{11}/(n_{11} + n_{01})$
- **F1-score** $= \frac{2 \times \text{recall} \times \text{precision}}{\text{recall} + \text{precision}}$
- **Geometric mean** $= \sqrt{\text{sensitivity} \times \text{specificity}}$

Agenda

1. 데이터 불균형 문제 (Data Imbalance Problems)
2. 분류 모델의 성능 평가 (Evaluation of classifiers; Confusion matrix)
3. 데이터 불균형 솔루션 (Solutions for Data Imbalance Problems)
4. 언더샘플링 (Undersampling)



데이터 불균형 솔루션





데이터를 조정해서 해결하자

- 샘플링 기법
→ Sampling method

모델을 수정해서 해결하자


- 비용 기반 학습
→ Cost sensitive learning
- 단일 범주 분류기법
→ Novelty detection

데이터 불균형 솔루션




Agenda

1. 데이터 불균형 문제 (Data Imbalance Problems)
2. 분류 모델의 성능 평가 (Evaluation of classifiers; Confusion matrix)
3. 데이터 불균형 솔루션 (Solutions for Data Imbalance Problems)
4. 언더샘플링 (Undersampling)




언더샘플링 (Undersampling)




- Undersampling Techniques have an effect on Majority Class
- Undersampling techniques remove examples from the training dataset that belong to the majority class in order to better balance the class distribution, such as reducing the skew from a 1:100 to a 1:10, 1:2, or even a 1:1 class distribution.
- This is different from oversampling that involves adding examples to the minority class in an effort to reduce the skew in the class distribution.

언더샘플링 (Undersampling)




Random undersampling

- 다수 범주에 속해있는 관측치를 임의로 줄이자




Random undersampling

- 다수 범주에 속해있는 관측치를 임의로 줄이자




Random undersampling

- 무작위 샘플링 #1



Random undersampling


무작위 샘플링 #2



- Although simple and effective, a limitation of this technique is that examples are removed without any concern for how useful or important they might be in determining the decision boundary between the classes.

Random undersampling

- 무작위 샘플링 #3




- This means it is possible, or even likely, that useful information will be deleted.

Tomek links

- 두 범주 사이를 탐지하고, 정리를 통해, 부정확한 분류 경계선을 방지
 - 정의: $d(x_i, x_k) < d(x_i, x_j)$ 또는 $d(x_j, x_k) < d(x_i, x_j)$ 가 되는 관측치 x_k 가 없는 경우 ($x_i \in$ 다수클래스, $x_j \in$ 소수클래스)
 - 두 샘플 x_i, x_j 는 tomek links를 형성
 - 둘 중 하나는 노이즈이거나, 둘 다 경계선 근처에 있음

$x_i \in$ +

$x_j \in$ -




* $d(x_i, x_j)$ 는 x_i, x_j 사이의 거리

Tomek links

- 두 범주 사이를 탐지하고, 정리를 통해, 부정확한 분류 경계선을 방지
 - 정의: $d(x_i, x_k) < d(x_i, x_j)$ 또는 $d(x_j, x_k) < d(x_i, x_j)$ 가 되는 관측치 x_k 가 없는 경우 ($x_i \in$ 다수클래스, $x_j \in$ 소수클래스)
 - 두 샘플 x_i, x_j 는 tomek links를 형성
 - 둘 중 하나는 노이즈이거나, 둘 다 경계선 근처에 있음

$x_i \in$ +


$x_j \in$ -



* $d(x_i, x_j)$ 는 x_i, x_j 사이의 거리

Tomek links

- 두 범주 사이를 탐지하고, 정리를 통해, 부정확한 분류 경계선을 방지
 - 정의: $d(x_i, x_k) < d(x_i, x_j)$ 또는 $d(x_j, x_k) < d(x_i, x_j)$ 가 되는 관측치 x_k 가 없는 경우 ($x_i \in$ 다수클래스, $x_j \in$ 소수클래스)
 - 두 샘플 x_i, x_j 는 tomek links를 형성
 - 둘 중 하나는 노이즈이거나, 둘 다 경계선 근처에 있음




* $d(x_i, x_j)$ 는 x_i, x_j 사이의 거리

- In some other words, a Tomek's link exist if the two samples are the nearest neighbors of each other


Tomek links

- Tomek links를 형성 후, 다수 범주에 속한 관측치를 제거



Tomek links


- Tomek links를 형성 후, 다수 범주에 속한 관측치를 제거



Tomek links

- Tomek links 언더샘플링 효과


— 이상
+ 정상



- Tomek's link method **removes noisy** samples

Condensed Nearest Neighbor Rule (CNN rule)

- 다수 범주의 데이터를 제거하는 규칙을 정의
 - 소수 범주 전체와 다수 범주에서 무작위로 하나의 관측치를 선택
 - 서브 데이터셋을 구성




Condensed Nearest Neighbor Rule (CNN rule)

- 다수 범주의 데이터를 제거하는 규칙을 정의
 - 1-NN 알고리즘을 통해 원 데이터를 분류

— 이상

+ 정상




Condensed Nearest Neighbor Rule (CNN rule)

- 다수 범주의 데이터를 제거하는 규칙을 정의
 - 1-NN 알고리즘을 통해 원 데이터를 분류

— 이상

+ 정상




Condensed Nearest Neighbor Rule (CNN rule)

- 다수 범주의 데이터를 제거하는 규칙을 정의
 - 1-NN 알고리즘을 통해 원 데이터를 분류


— 이상

+ 정상



Condensed Nearest Neighbor Rule (CNN rule)

- 다수 범주의 데이터를 제거하는 규칙을 정의
 - 1-NN 알고리즘을 통해 원 데이터를 분류




— 이상
+ 정상
+ 오분류

- CNN method removes **uninformative** samples

Condensed Nearest Neighbor Rule (CNN rule)

- 완벽하게 분류되는 관측치들을 제거하는 컨셉의 방법

— 이상
+ 정상




- A criticism of the cnn is that examples are selected randomly, especially initially.
- CNN is sensitive to noise and will add noisy samples.

One-side selection (OSS)


- Tomek links + CNN: 두 방법론들의 개념을 혼합하여 적용

— 이상
+ 정상

샘플링 이전



샘플링 이후



언더샘플링의 특징 및 한계점



- 다수 범주 관측치 제거로 계산 시간 감소
- 데이터 클렌징으로 데이터 오버랩 감소가 가능??



- 데이터 제거로 인한 정보 손실 발생
→ 모델 학습에 유용한 관측치가 제거 될 수 있음

Summary

- ❑ 이번 시간에는 데이터 불균형 문제가 무엇인지 다루었습니다.
- ❑ 불균형이 어떤 면에서 분류예측 학습모델에 안 좋은 영향을 끼치는지 이해합니다.
- ❑ 불균형 문제 해결을 위해서, 언더샘플링에 대한 기법을 다루었습니다.
- ❑ 언더샘플링 기법 중에서 Random Undersampling, Tomek links, Condensed nearest neighbor rule, One-Sided Selection 기법에 대해 알아보았습니다.

데이터 불균형 문제에 대한 관련 연구들

Method	Paper
Resampling	N.V. Chawla, K.W. Bowyer, L.O. Hall, W.P. Kegelmeyer, SMOTE: synthetic minority over-sampling technique
	C. Bunkhumpornpat, K. Sinapiromsaran, C. Lursinsap, Safe-level-SMOTE: Safe-level-synthetic minority over-sampling TEchnique for handling the class imbalanced problem
	G.E.A.P.A. Batista, R.C. Prati, M.C. Monard, A study of the behaviour of several methods for balancing machine learning training data
Cost-sensitive	P. Domingos, Metacost: a general method for making classifiers cost-sensitive
	B. Zadrozny, J. Langford, N. Abe, Cost-sensitive learning by cost-proportionate example weighting
	V. López, A. Fernández, J.G. Moreno-Torres, F. Herrera, Analysis of preprocessing vs. cost-sensitive learning for imbalanced classification
Ensemble	M. Galar, A. Fernández, E. Barrenechea, H. Bustince, F. Herrera, A review on ensembles for class imbalance problem: bagging, boosting and hybrid based approaches
	C. Seiffert, T.M. Khoshgoftaar, J. Van Hulse, A. Napolitano, RUSBoost: a hybrid approach to alleviating class imbalance
	R. Barandela, R.M. Valdovinos, J.S. Sánchez, New applications of ensembles of classifiers