


데이터 불균형 문제 II

박성호


컴퓨터공학부

오버샘플링 (Oversampling)



Resampling (random oversampling)

- 소수 클래스 내 관측치를 증가



Resampling (random oversampling)

- 소수 클래스 내 관측치를 증가

		No	변수1	변수2	변수3	...	변수p	정상/이상
다수 클래스 (300개)	[	1	50	16	2	...	10	정상
		2	74	11	1	...	80	정상
		⋮	⋮	⋮	⋮	⋮	⋮	⋮
		299	24	14	5	...	21	정상
		300	75	18	8	...	40	정상
소수 클래스 (10개)	[	301	500	64	24	...	0.1	이상
		⋮	⋮	⋮	⋮	⋮	⋮	⋮
		310	700	64	48	...	0.5	이상

Resampling (random oversampling)



- 소수 클래스 내 관측치를 증가: **복제 (복원 추출)**



No	변수1	변수2	변수3	...	변수p	정상/이상
1	50	16	2	...	10	정상
2	74	11	1	...	80	정상
⋮	⋮	⋮	⋮	⋮	⋮	⋮
299	24	14	5	...	21	정상
300	75	18	8	...	40	정상
301	500	64	24	...	0.1	이상
⋮	⋮	⋮	⋮	⋮	⋮	⋮
310	700	64	48	...	0.5	이상
311	500	64	24	...	0.1	이상
⋮	⋮	⋮	⋮	⋮	⋮	⋮
599	700	64	48	...	0.5	이상
600	700	64	48	...	0.5	이상

다수 클래스
(300개)


소수 클래스
(10개)

복제한
소수 클래스
(290개)




Resampling (random oversampling)

- 다수/소수 클래스 관측치 수가 비슷해질 때까지 복제




Resampling (random oversampling)

- Resampling 이전: 불균형으로 인해 부적절한 분류경계선 형성




Resampling (random oversampling)

- Resampling 이전: 불균형으로 인해 부적절한 분류경계선 형성





Resampling (random oversampling)

- **Resampling 문제점:** 소수 클래스에 대한 과적합(Overfitting)문제 가능



과적합 문제 (Overfitting problem)

- 과소적합(Underfitting) and 과적합(Overfitting)



Decision Tree 예시


Decision Tree 복잡도
:= 나무 가지의 수

모델의 복잡도


- ✓ 과소적합: 모델이 너무 단순하여 학습 에러가 큼
- ✓ 과적합: 모델이 학습 에러를 작게 만드는데 치중하여 모델의 복잡도가 너무 높아져 테스트 데이터에 대한 에러가 큼

과적합 문제 (Overfitting problem)

- 분류 모델의 과적합(Overfitting)



- 회귀 모델의 과적합(Overfitting)




Resampling (random oversampling)

- **Resampling 기법의 문제점 정리**

- ✓ 기존에 가지고 있는 소수 클래스의 개수는 매우 적음
- ✓ 적은 수의 관측치를 계속 복제한다고 해서, 새로운 정보 (관측치)를 얻기에는 한계가 있음
- ✓ 오버샘플링의 기본 전략은 '소수 클래스를 잘 설명하는' 가상의 관측치를 생성하는데 있음


Synthetic Minority Oversampling Technique (SMOTE)

- 소수 클래스에서 가상의 데이터를 생성하는 보편적인 방법




Synthetic Minority Oversampling Technique (SMOTE)

- SMOTE의 수행 절차와 예시
 - ✓ 소수 클래스에서 각 관측치마다 k 개의 주변 관측치를 탐색




Synthetic Minority Oversampling Technique (SMOTE)

- SMOTE의 수행 절차와 예시
 - ✓ 소수 클래스에서 각 관측치마다 k 개의 주변 관측치를 탐색
 - ✓ $k = 5$ 일 경우



Synthetic Minority Oversampling Technique (SMOTE)


- SMOTE의 수행 절차와 예시
 - ✓ 랜덤하게 주변에 있는 관측치들 중 하나를 선택



Synthetic Minority Oversampling Technique (SMOTE)


- SMOTE의 수행 절차와 예시

- ✓ 선택된 두 관측치(자기 자신 & 주변)을 기반으로 가상의 관측치를 생성



Synthetic Minority Oversampling Technique (SMOTE)


- SMOTE의 수행 절차와 예시
 - ✓ 선택된 두 관측치(자기 자신 & 주변) 사이의 거리를 산출



Synthetic Minority Oversampling Technique (SMOTE)


- SMOTE의 수행 절차와 예시

- ✓ 선택된 두 관측치(자기 자신 & 주변) 사이의 거리를 산출
- ✓ 새로운 관측치를 생성



Synthetic Minority Oversampling Technique (SMOTE)

- SMOTE의 수행 절차와 예시
 - ✓ 소수 클래스 내 모든 관측치에 대해 해당 과정을 시행




Synthetic Minority Oversampling Technique (SMOTE)

- SMOTE의 수행 절차와 예시

- ✓ 소수 클래스 내 모든 관측치에 대해 해당 과정을 시행


— 이상

+ 정상




Synthetic Minority Oversampling Technique (SMOTE)

- SMOTE의 수행 결과



Borderline-SMOTE

- Borderline이란?




분류문제를 생각하자

→ 어떤 관측치가 더 중요할까?


Borderline-SMOTE

- 좋은 모델을 구축하는데 어떤 관측치가 더 중요할까?




Borderline-SMOTE

- 좋은 모델을 구축하는데 어떤 관측치가 더 중요할까?




Borderline-SMOTE

- 좋은 모델을 구축하는데 어떤 관측치가 더 중요할까?



Borderline-SMOTE

- Borderline 인근에만 샘플링을 수행



Borderline-SMOTE

- 1. Borderline을 찾는다


- ✓ 소수 클래스 임의의 관측치에 대해서 주변 k 개를 탐색
- ✓ k 개 중 다수 클래스의 수를 확인

— 이상
+ 정상

($k=5$)

다수 클래스 개수 : 0

“Safe” 관측치




Borderline-SMOTE

- 1. Borderline을 찾는다

- ✓ 소수 클래스 임의의 관측치에 대해서 주변 k 개를 탐색
- ✓ k 개 중 다수 클래스의 수를 확인

— 이상
+ 정상

($k=5$)



Borderline-SMOTE

- 1. Borderline을 찾는다
 - ✓ 소수 클래스 임의의 관측치에 대해서 주변 k 개를 탐색
 - ✓ k 개 중 다수 클래스의 수를 확인

3가지 타입의 관측치로 분류

- k : 소수 클래스 주변 탐지 관측치 수
- k' : k 소수 클래스 주변의 다수 클래스 수

주변에 다수 클래스만 있다 ($k = k'$)

→ Noise 관측치

다수 클래스 개수가 $k/2$ 보다 많다 ($k/2 < k' < k$)


→ Danger 관측치

다수 클래스 개수가 $k/2$ 보다 적다 ($0 \leq k' \leq k/2$)

→ Safe 관측치


Borderline-SMOTE

- 2. Danger 관측치에 대해서만 SMOTE를 적용
 - ✓ Danger 관측치 중에서 랜덤한 s 개 샘플을 생성 ($s < k$)




Borderline-SMOTE

- 2. Danger 관측치에 대해서만 SMOTE를 적용
 - ✓ Danger 관측치 중에서 랜덤한 s 개 샘플을 생성 ($s < k$)





Borderline-SMOTE

- 2. Danger 관측치에 대해서만 SMOTE를 적용
 - ✓ Danger 관측치 중에서 랜덤한 s 개 샘플을 생성 ($s < k$)




Borderline-SMOTE

- 2. Borderline-SMOTE의 관측치 생성 방식 (Danger 관측치 주변에 생성)




Borderline-SMOTE

- 2. Danger 관측치에 대해서만 SMOTE를 적용
 - ✓ Danger 관측치 중에서 랜덤한 s 개 샘플을 생성 ($s < k$)




Borderline-SMOTE

- 2. Danger 관측치에 대해서만 SMOTE를 적용
 - ✓ Danger 관측치 중에서 랜덤한 s 개 샘플을 생성 ($s < k$)




Borderline-SMOTE

- 2. Danger 관측치에 대해서만 SMOTE를 적용
 - ✓ 최종적으로 생성된 소수 클래스에 대한 관측치



Borderline-SMOTE


- Borderline-SMOTE 적용 결과




Borderline-SMOTE

■ → Danger 관측치


□ → 생성된 소수 클래스 관측치



(1) 원데이터



(2) Danger 관측치




(3) 생성된 소수 클래스 관측치


Adaptive Synthetic Sampling Approach (ADASYN)

- Borderline 인근 샘플링에 좀 더 집중하기 위한 방법

✓ 새로운 지표를 정의하여 사용



$$r_i = \Delta_i / K \quad i = 1, \dots, m$$



Δ_i : 소수 클래스에 속하는 관측치 x_i 의 주변 K 개중 다수 클래스 관측치의 수

m : 소수 클래스에 속하는 관측치의 총 개수

각 **소수** 클래스 관측치 주변에 얼마큼 많은


다수 클래스 관측치들이 있는가를 정량화 한 지표

Adaptive Synthetic Sampling Approach (ADASYN)

- 1. 소수 클래스에 속하는 모든 관측치들의 r_i 를 계산
 - ✓ 주변 k 개 관측치들을 탐색하여 r_i 를 구한다

— 이상
+ 정상


($k=5$)



Adaptive Synthetic Sampling Approach (ADASYN)

- 1. 소수 클래스에 속하는 모든 관측치들의 r_i 를 계산
 - ✓ 주변 k 개 관측치들을 탐색하여 r_i 를 구한다

— 이상
+ 정상
($k=5$)




Adaptive Synthetic Sampling Approach (ADASYN)

- 1. 소수 클래스에 속하는 모든 관측치들의 r_i 를 계산
 - ✓ 주변 k 개 관측치들을 탐색하여 r_i 를 구한다


— 이상
+ 정상

($k=5$)



Adaptive Synthetic Sampling Approach (ADASYN)

- 1. 소수 클래스에 속하는 모든 관측치들의 r_i 를 계산
 - ✓ 주변 k 개 관측치들을 탐색하여 r_i 를 구한다



소수 클래스 관측치	r_i
1	0.4
2	0
3	0
$\vdots$	$\vdots$
11	0.8
12	0.6
13	1

Adaptive Synthetic Sampling Approach (ADASYN)

- 1. 소수 클래스에 속하는 모든 관측치들의 r_i 를 계산
 - ✓ 주변 k 개 관측치들을 탐색하여 r_i 를 구한다

소수 클래스 관측치	r_i
1	0.4
2	0
3	0
⋮	⋮
11	0.8
12	0.6
13	1

전체 r_i 값으로
normalizing



$$\hat{r}_i = r_i / \sum_{i=1}^m r_i$$

소수 클래스 관측치	$\hat{r}_i$
1	0.1428
2	0
3	0
⋮	⋮
11	0.2857
12	0.2142
13	0.4

Adaptive Synthetic Sampling Approach (ADASYN)

- 2. r_i 를 평준화(Normalizing) 하여 $\hat{r}_i$ 계산

소수 클래스 관측치	r_i
1	0.4
2	0
3	0
$\vdots$	$\vdots$
11	0.8
12	0.6
13	1

전체 r_i 값으로
normalizing




$$\hat{r}_i = r_i / \sum_{i=1}^m r_i$$

소수 클래스 관측치	$\hat{r}_i$
1	0.1428
2	0
3	0
$\vdots$	$\vdots$
11	0.2857
12	0.2142
13	0.4

Adaptive Synthetic Sampling Approach (ADASYN)

- 3. $\hat{r}_i$ 에 생성하고자 하는 관측치 개수 G 를 곱한다.
 - ✓ 소수 클래스에 속한 관측치별 $\hat{r}_i$ 비율(%)로 관측치 생성

소수 클래스 관측치	r_i
1	0.1428
2	0
3	0
⋮	⋮
11	0.2857
12	0.2142
13	0.4



$\times G$


($G=100$)

소수 클래스 관측치	$\hat{r}_i$	
1	14.28 (14)	
2	0	
3	0	
⋮	⋮	
11	28.57 (29)	
12	21.42 (21)	
13	40	

* ($G = \text{다수 클래스 관측치 개수} - \text{소수 클래스 관측치 개수}$)이면, 최종 비율이 약 1:1이 된다

Adaptive Synthetic Sampling Approach (ADASYN)

- ADASYN 적용 결과



Adaptive Synthetic Sampling Approach (ADASYN)

- ADASYN 적용 결과

소수 클래스 주변의 **다수** 클래스의 수에
따라 유동적으로 생성이 가능



주변 다수 클래스가 많을 수록 많은 수의 관측치를 생성
=Borderline 주변일수록 더 많은 관측치를 생성

Adaptive Synthetic Sampling Approach (ADASYN)


- Borderline 집중 샘플링 방법

- ✓ 각 소수 클래스를 시드(seed)로 하여 할당된 개수만큼 SMOTE를 적용

— 이상

+ 정상

($k=5$, $G=100$)




Adaptive Synthetic Sampling Approach (ADASYN)

- Borderline 집중 샘플링 방법

- ✓ 각 소수 클래스를 시드(seed)로 하여 할당된 개수만큼 SMOTE를 적용

— 이상
+ 정상


($k=5$, $G=100$)



Adaptive Synthetic Sampling Approach (ADASYN)

- Borderline 집중 샘플링 방법


- ✓ SMOTE 방법을 활용하여 두 점 사이에 임의의 새로운 관측치를 생성



Adaptive Synthetic Sampling Approach (ADASYN)

- Borderline 집중 샘플링 방법

- ✓ 각 소수 클래스를 시드(seed)로 하여 할당된 개수만큼 SMOTE를 적용




— 이상
+ 정상
— 가상
 데이터

Adaptive Synthetic Sampling Approach (ADASYN)

- Borderline 집중 샘플링 방법


- ✓ 각 소수 클래스를 시드(seed)로 하여 할당된 개수만큼 SMOTE를 적용

— 이상
+ 정상
— 가상
 데이터




Adaptive Synthetic Sampling Approach (ADASYN)

- Borderline 집중 샘플링 방법
 - ✓ 최종적으로 생성된 소수 범주에 대한 관측치




Adaptive Synthetic Sampling Approach (ADASYN)

- ADASYN 샘플링 결과



Adaptive Synthetic Sampling Approach (ADASYN)

- ADASYN 샘플링 결과



오버샘플링의 특징 및 한계점



- 정보 손실이 없음
- 대부분의 경우 언더샘플링에 비해 높은 분류정확도를 보임



- 과적합 가능성
- 계산 시간이 증가
- 노이즈 또는 이상치에 민감

Summary

- ❑ 이번 시간에는 데이터 불균형 문제 중 오버샘플링을 배웠습니다.
- ❑ 실제 실험을 하다 보면 언더샘플링 보다는 오버샘플링에 대한 정확도 향상 효과를 자주 접하게 됩니다.
- ❑ 불균형 데이터 문제는 분류예측 학습모델에 안 좋은 영향을 끼치기 때문에 분류 학습모델 구축 전에 전처리 작업을 반드시 고려해야 합니다.
- ❑ 언더샘플링 기법 중에서 Resampling, SMOTE, Borderline-SMOTE, ADASYN 기법에 대해 배웠습니다.
- ❑ 실제 실험을 진행하면서 샘플링 알고리즘의 효과에 대해 경험해보기 바랍니다.