


Anomaly (Novelty) Detection I I

박성호

컴퓨터공학부




Agenda

1. Anomaly Detection
2. Density Estimation-based approaches
3. Distance-based approaches
4. Decision Boundary-based approaches
5. Reconstruction-based Approaches
6. 관련 연구사례 소개

재구축 기반 이상탐지

■ 재구축(Reconstruction) 이상탐지란?


✓ 이상탐지의 일반적인 형태



재구축 기반 이상탐지

■ 재구축(Reconstruction) 이상탐지란?

- ✓ 재구축 이상탐지의 일반적인 형태




재구축 기반 이상탐지

- 재구축(Reconstruction) 이상탐지란?
 - ✓ 재구축 이상탐지의 일반적인 형태

인코딩 (Encoding)

- 차원축소 -




Projection to lower
dimensional space

재구축 기반 이상탐지

- 재구축(Reconstruction) 이상탐지란?
 - ✓ 재구축 이상탐지의 일반적인 형태

디코딩 (Decoding)

- 차원복원 -




재구축 기반 이상탐지

- 재구축(Reconstruction) 이상탐지란?

- ✓ 재구축 이상탐지의 일반적인 형태

이상치 점수 계산
(Novelty score)



Novelty score 계산

차원 축소 (Dimensionality reduction)

- 변수 선택 (Feature selection)
- 변수 추출 (Feature extraction)

X_1	X_2	X_3	X_4	...	X_p
...	...	...	...	...	...
...	...	...	...	...	...



중요한 변수를 선택하자!

X_1	X_{12}	X_{19}	X_{29}
...	...	...	...
...	...	...	...

Feature selection



차원을 축소하자!

Z_1	Z_2	Z_3	Z_4
...	...	...	...
...	...	...	...

Feature extraction


PCA 개요

- PCA는 n 개의 관측치와 p 개의 변수로 구성된 데이터를 상관관계가 없는 k 개의 변수로 구성된 데이터 (n 개의 관측치)로 요약하는 방식으로, 이 때 요약된 변수는 기존 변수의 선형조합으로 생성됨
- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 데이터를 사영 (Projection) 시키는 기법
- 주요 목적
 - 데이터 차원 축소 ($n \text{ by } p \rightarrow n \text{ by } k, \text{ where } k \ll p$)
 - 데이터 시각화 및 해석

linear projection

PCA 기반 이상탐지

- Principal component analysis (PCA) 주성분분석
- PCA는?: **고차원** 데이터를 **저차원** 데이터로 변환하는 대표적인 기법
- PCA 정의: **직교선형 변환**을 통한 차원 축소 기법



PC: 변환 이후, 새로운 축
Principal component (주성분)


PCA 기반 이상탐지

- Principal component analysis (PCA) 주성분분석
- PCA는?: **고차원** 데이터를 **저차원** 데이터로 변환하는 대표적인 기법
- PCA 정의: **직교선형 변환**을 통한 차원 축소 기법

$T: \mathbb{R}^p \rightarrow \mathbb{R}^m$ 을 선형변환이라 하면,


$$T(X) = AX, \forall X \in \mathbb{R}^p$$

차원을 변경하는 선형변환



PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 **데이터를 사영 (Projection) 시키는 기법**




$$v \perp x^i - kv$$

$$(x^i - kv) \cdot v = (x^i - kv)^T \cdot v$$


$$(x^i)^T v - (kv)^T v = 0$$

$$\therefore \mathbf{k} = \frac{(\mathbf{x}^i)^T \mathbf{v}}{\mathbf{v}^T \mathbf{v}}$$



PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 **데이터를 사영 (Projection) 시키는 기법**



Pythagorean theorem

$$\therefore k = \frac{(x^i)^T v}{v^T v} = \text{constant}$$


$$\overline{ox^i}^2 = \overline{oz^i}^2 + \overline{z^i x^i}^2$$

$$\min_v \frac{1}{n} \sum_{i=1}^n \overline{z^i x^i}^2$$

손실을 최소화

PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 **데이터를 사영 (Projection) 시키는 기법**



$$\therefore k = \frac{(x^i)^T v}{v^T v} = \text{constant}$$

Pythagorean theorem

$$\overline{ox^i}^2 = \overline{oz^i}^2 + \overline{z^i x^i}^2$$

$$\min_v \frac{1}{n} \sum_{i=1}^n \overline{z^i x^i}^2$$


$$\max_v \frac{1}{n} \sum_{i=1}^n \overline{oz^i}^2$$

$$\max_v \frac{1}{n} \sum_{i=1}^n \left(\frac{(x^i)^T v}{v^T v} \right)^2 = \max_v \frac{1}{n} \sum_{i=1}^n \left((x^i)^T v \right)^2$$

subject to $v^T v = 1$

PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 데이터를 사영 (Projection) 시키는 기법



$$\therefore k = \frac{(x^i)^T v}{v^T v} = \text{constant}$$

Pythagorean theorem

$$\overline{ox^i}^2 = \overline{oz^i}^2 + \overline{z^ix^i}^2$$

$$\max_v \frac{1}{n} \sum_{i=1}^n \left(\frac{(x^i)^T v}{v^T v} \right)^2 = \max_v \frac{1}{n} \sum_{i=1}^n (z^i)^T z^i$$

$$\text{subject to } v^T v = 1$$

x^i : 평균을 뺀 값 (normalized X)




z^i : 평균=0

사영된 공간에서 분산을 최대화

주성분 (Principal Component; PC)


- 관측치(n)의 고유 분산을 최대한 보존하는 방향으로 변환하는 기저(basis)

어느 쪽이 사영(projection) 시킬 때,
퍼져 있는 정도를 잘 설명하는가?




PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 데이터를 사영 (Projection) 시키는 기법



PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 **데이터를 사영 (Projection) 시키는 기법**



$$\therefore k = \frac{(x^i)^T v}{v^T v} = \text{constant}$$

Pythagorean theorem

$$\overline{ox^i}^2 = \overline{oz^i}^2 + \overline{z^ix^i}^2$$

$$\max_v \frac{1}{n} \sum_{i=1}^n \left(\frac{(x^i)^T v}{v^T v} \right)^2 = \max_v \frac{1}{n} \sum_{i=1}^n \left((x^i)^T v \right)^2$$

subject to $v^T v = 1$

$$\max_v \frac{1}{n} \sum_{i=1}^n \left((x^i)^T v \right)^2 = \max_v \frac{1}{n} \sum_{i=1}^n (v^T x^i) \left((x^i)^T v \right) = \max_v v^T \left(\sum_{i=1}^n \frac{1}{n} x^i (x^i)^T \right) v$$

subject to $v^T v = 1$

PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 **데이터를 사영 (Projection) 시키는 기법**

$$\max_v v^T \left(\sum_{i=1}^n \frac{1}{n} x^i (x^i)^T \right) v = \max_v v^T \frac{1}{n} (X^T X) v$$

subject to $v^T v = 1$

$$\frac{1}{n} (X^T X) = \text{covariance Maxtrix of X}$$

x^i : 평균을 뺀 값
(normalized X)

$$\frac{1}{n} (X^T X) = \begin{bmatrix} \text{Var}[x_1] & \text{Cov}[x_1, x_2] & \dots & \text{Cov}[x_1, x_p] \\ \text{Cov}[x_2, x_1] & \text{Var}[x_2] & \dots & \text{Cov}[x_2, x_p] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[x_p, x_1] & \text{Cov}[x_p, x_2] & \dots & \text{Var}[x_p] \end{bmatrix}$$

PCA 원리

- 원래 데이터의 분산을 최대한 보존하는 새로운 축을 찾고, 그 축에 **데이터를 사영 (Projection) 시키는 기법**

$$\begin{aligned} & \max_V \frac{1}{n} V^T (X^T X) V \\ & \text{subject to } v_i^T v_i = 1 \text{ and } v_i^T v_j = 0, i \neq j \end{aligned}$$

$$\frac{1}{n} (X^T X) = \text{covariance Matrix of } X$$


x^i : 평균을 뺀 값
(normalized X)

$$\frac{1}{n} (X^T X) = \begin{bmatrix} \text{Var}[x_1] & \text{Cov}[x_1, x_2] & \dots & \text{Cov}[x_1, x_p] \\ \text{Cov}[x_2, x_1] & \text{Var}[x_2] & \dots & \text{Cov}[x_2, x_p] \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}[x_p, x_1] & \text{Cov}[x_p, x_2] & \dots & \text{Var}[x_p] \end{bmatrix}$$

PCA

Eigenvalues of the covariance matrix

= Variances of each principal component (각 주성분의 분산)



주성분 (Principal Component; PC)

• PCA의 novelty score 계산

✓ PCA formulation

$$\text{Max} \frac{1}{n} \mathbf{v}^T (\mathbf{X}^T \mathbf{X}) \mathbf{v}$$

$$\text{s.t.} \quad \mathbf{v}^T \mathbf{v} = 1$$

분산을 최대한 보존하는 방향으로 차원 축소

$\mathbf{v}$ 는 unit vector

Reconstruction Error = Anomaly Score

✓ 재구축 에러 (Reconstruction error)


$$\tilde{\mathbf{x}} = \mathbf{z} \mathbf{v}^T = \mathbf{v}^T \mathbf{x} \mathbf{v}$$

$$e(\mathbf{x}) = \|\mathbf{x} - \mathbf{v}^T \mathbf{x} \mathbf{v}\|^2$$

$$\hat{\mathbf{x}} = z_1 \mathbf{v}_1 + z_2 \mathbf{v}_2$$

여기서:



- $z_1 \mathbf{v}_1$: x 가 $\mathbf{v}_1$ 축으로 투영된 값을 원래 차원으로 복원.
- $z_2 \mathbf{v}_2$: x 가 $\mathbf{v}_2$ 축으로 투영된 값을 원래 차원으로 복원.
- $\hat{\mathbf{x}}$: 복원된 x 의 근사값.



Autoencoder 기반 이상탐지


▪ Autoencoder 배경

- ✓ “데이터와 학습되어야 하는 정보(Y or class) 사이의 괴리가 큰 경우”
- ✓ Deep structure is better!



Autoencoder 란?

- Y label 없이 X 만으로 학습하여 각 layer와 neuron 간 weights의 초기해 탐색



Autoencoder 기반 이상탐지

