

[Deep Learning Framework]

ML 핵심 개념


박성호

컴퓨터공학부

한국공학대학교


학습 목표

1. ML 기본 개념
2. 기본 NN 형태
3. 학습이란?



- Loss
- Optimization
- Decision Boundary
-

AI & ML & Deep Learning



인공지능? 머신러닝?

$$f(x)$$

Input



Output

(사진: <http://koreadailytimes.com/>)

인공지능은 입력값을 넣어주면 출력값이 나오는 함수 시스템

인공지능? 머신러닝?



인공지능은 입력값을 넣어주면 출력값이 나오는 시스템

인공지능? 머신러닝?

$$f(x)$$



Input



(사진: <http://koreadailytimes.com/>)



Output

인공지능은 입력값을 넣어주면 출력값이 나오는 시스템

인공지능? 머신러닝?


$$f(x)$$



Input




(사진: <http://koreadailytimes.com/>)



Output

인공지능은 입력값을 넣어주면 출력값이 나오는 시스템

인공지능? 머신러닝?



Input

$f(x)$




(사진: <http://koreadailytimes.com/>)



Output

인공지능은 입력값을 넣어주면 출력값이 나오는 시스템

인공지능? 머신러닝?



$$f(x) = x^2$$

파이썬 기반 함수 프로그래밍

```
def quadratic_function(x):  
    input = x  
    output = x**2  
    return output
```

인공지능은 입력값을 넣어주면 출력값이 나오는 함수 시스템


인공지능? 머신러닝?



인공지능은 입력값을 넣어주면 출력값이 나오는 시스템

기계학습 (Machine Learning)?


- Definition: an application of AI that provides systems the ability to automatically learn and improve from **experience (데이터)** without **being explicitly programmed (학습 로직)**



기계학습 (Machine Learning)?

일반적인 프로그래밍 방식과의 차이점

일반적인 컴퓨터 프로그램



머신러닝 프로그램

(3) Algorithm

(1) Data

**(2) Learning
(Computer)**

Training

Function


**Solving
(Computer)**

Testing

Output


Big Data

- ❖ Why Big Data Keeps Getting Bigger
- ❖ 연간 데이터를 생성시킬 수 있는 **디지털 요소들의 증가**



Big Data

❖ Why Big Data Keeps Getting Bigger




per minute

- Netflix users stream 694,444 hours of video
- Instagram users post 277,777 stories
- Youtube users watch 4,500,000 videos
- Twitter users send 511,200 tweets
- Skype users make 231,840 calls
-

What Kind of Data ?

- ❖ **Structured** and Unstructured
- ❖ Structured data is highly **organized**
- ❖ relational databases and spreadsheets (키와 값으로 구성된 테이블)
- ❖ 컬럼을 통해 데이터의 의미를 쉽게 파악



데이터 용어

정형 데이터

- 테이블과 같이 고정된 컬럼에 저장되는 데이터와 파일, 그리고 **행과 열**에 의해 **데이터의 속성이 구별되는** 스프레드시트 형태의 데이터

변수: 각 관측치의 특성치 (Variable, Feature, Factor)

관측치: sample
(Observation, Sample,
Pattern)

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa

데이터 용어

정형 데이터

이산형 변수 (Discrete Variable)

- 명목형 (범주형, Categorical): 여러 Class들 중 하나의 이름에 데이터를 분류할 수 있을 때 사용 – 예를 들어 사과, 배, 바나나 구분
- 순서형: 데이터가 속하는 Class들에 순서가 있는 경우 순서형 (ordinal) 데이터라고 한다. – 예를 들어 상, 중, 하 구분


연속형 변수 (Continuous Variable)

- 실수 형태의 연속적인 값을 가지고 있는 변수를 연속형 변수라 한다. – 예를 들어 키나 몸무게와 같은 변수


What Kind of Data ?

- ❖ Structured and **Unstructured**
- ❖ **cannot** be processed and analyzed using conventional tools and method
- ❖ 데이터의 의미를 쉽게 파악 x

Video



Signal (음파, 진동)



Text

Mode-wise Tensor Decompositions: Multi-dimensional Generalizations of CUR Decompositions

HanQin Cai

Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

HQCAI@MATH.UCLA.EDU

Keaton Hamm

Department of Mathematics
University of Texas at Arlington
Arlington, TX 76019, USA

KEATON.HAMM@UTA.EDU

Longxiu Huang

Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

HUANGL3@MATH.UCLA.EDU

Deanna Needell

Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

DEANNA@MATH.UCLA.EDU


Editor: Michael Mahoney

Abstract

Low rank tensor approximation is a fundamental tool in modern machine learning and data science. In this paper, we study the characterization, perturbation analysis, and an efficient sampling strategy for two primary tensor CUR approximations, namely Chidori and Fiber CUR. We characterize exact tensor CUR decompositions for low multilinear rank tensors. We also present theoretical error bounds of the tensor CUR approximations when (adversarial or Gaussian) noise appears. Moreover, we show that low cost uniform sampling is sufficient for tensor CUR approximations if the tensor has an incoherent structure. Empirical performance evaluations, with both synthetic and real-world datasets, establish the speed advantage of the tensor CUR approximations over other state-of-the-art low multilinear rank tensor approximations.

Keywords: tensor decomposition, low-rank tensor approximation, CUR decomposition, randomized linear algebra, hyperspectral image compression


Unstructured Data - Image



변수: 각 관측치의 특성치 (Variable, Feature, Factor)

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa
9	4.4	2.9	1.4	0.2	setosa
10	4.9	3.1	1.5	0.1	setosa

딥 러닝 (Deep Learning) - 인공 신경망의 구조




비정형 데이터로부터 의미 있는 정형 데이터 형태로 변환해주는 기능을 내포

어떻게? 앞으로 배울 내용

Unstructured Data - Text


```
Out[4]:
```

	id	document	label
0	8112052	어릴때보고 지금다시봐도 재밌어요 ㅋㅋ	1
1	8132799	디자인을 배우는 학생으로, 외국디자이너와 그들이 일군 전통을 통해 발전해가는 문화산...	1
2	4655635	폴리스스토리 시리즈는 1부터 뉴까지 버릴게 하나도 없음.. 최고.	1
3	9251303	와.. 연기가 진짜 개쩔구나.. 지루할거라고 생각했는데 몰입해서 봤다.. 그래 이런...	1
4	10067386	안개 자욱한 밤하늘에 떠 있는 초승달 같은 영화.	1



변수: 각 관측치의 특성치 (Variable, Feature, Factor)

딥 러닝 (Deep Learning) - 인공 신경망의 구조




비정형 데이터로부터 의미 있는 정형 데이터 형태로 변환해주는 기능을 내포

어떻게? 앞으로 배울 내용

기계학습 (Machine Learning)?

일반적인 프로그래밍 방식과의 차이점

일반적인 컴퓨터 프로그램



머신러닝 프로그램

(3) Algorithm

(1) Data

**(2) Learning
(Computer)**

Training


Function

**Solving
(Computer)**

Testing


Output

기계학습 범주




기계학습 방법 범주 (문제 유형)

❖ 문제 상황(Task)에 따라 크게 4가지로 분류



지도학습 데이터



독립변수 (Independent variable)

예측변수 (Explanatory variable)

인풋변수 (Input variable)

종속변수 (Dependent variable)

반응변수 (Response variable)

아웃풋변수 (Output variable)






지도학습에 사용되는 데이터

중고차 데이터

X Y


모델	주행거리	마력	용량	가격
TOYOTA Corolla 2.0 D4D HATCHB TERRA 2/3-Doors	46,986	90	2,000	13,500
TOYOTA Corolla 1800 T SPORT VVT I 2/3-Doors	19,700	192	1,800	21,500
TOYOTA Corolla 1.9 D HATCHB TERRA 2/3-Doors	71,138	69	1,900	12,950
TOYOTA Corolla 1.8 VVTL-i T-Sport 3-Drs 2/3-Doors	31,461	192	1,800	20,950
TOYOTA Corolla 1.8 16V VVTI 3DR T SPORT BNS 2/3-Doors	43,610	192	1,800	19,950
TOYOTA Corolla 1.6 VVTI Linea Terra Comfort 2/3-Doors	21,716	110	1,600	17,950
TOYOTA Corolla 1.6 16v L.SOL 2/3-Doors	25,563	110	1,600	16,750
TOYOTA Corolla 1.6 16V VVT I 3DR TERRA 2/3-Doors	64,359	110	1,600	16,950
TOYOTA Corolla 1.6 16V VVT I 3DR SOL AUT4 2/3-Doors	43,905	110	1,600	16,950
TOYOTA Corolla 1.6 16V VVT I 3DR SOL 2/3-Doors	56,349	110	1,600	15,950
TOYOTA Corolla 1.4 VVTI Linea Terra 2/3-Doors	9,750	97	1,400	12,950
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	27,500	97	1,400	14,750
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	49,059	97	1,400	13,950
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	44,068	97	1,400	16,750
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	46,961	97	1,400	13,950
TOYOTA Corolla 2.0 D4D 90 5DR TERRA COMFORT 4/5-Doors	110,404	90	2,000	16,950
TOYOTA Corolla 2.0 D4D 90 5DR TERRA COMFORT 4/5-Doors	100,250	90	2,000	16,950
TOYOTA Corolla 2.0 D4D 90 5DR SOL 4/5-Doors	84,000	90	2,000	19,000
TOYOTA Corolla 2.0 D4D 90 5DR TERRA 4/5-Doors	79,375	90	2,000	17,950
TOYOTA Corolla 1.4 16V VVT I 5DR TERRA COMFORT 4/5-Doors	75,048	97	1,400	15,800

지도학습이란 데이터 인과관계 **모델링**



지도학습 (Supervised Learning)

- ❖ 학습데이터로 부터 Input (x)와 Output (y)의 관계를 설명하는 함수 (f)를 찾는 방법론
- ❖ 종속변수 y 가 범주형이면 classification, 연속형이면 regression



지도학습 예시 (회귀 Regression, 문제)

중고차 데이터

x

y

모델	주행거리	마력	용량	가격
TOYOTA Corolla 2.0 D4D HATCHB TERRA 2/3-Doors	46,986	90	2,000	13,500
TOYOTA Corolla 1800 T SPORT VVT I 2/3-Doors	19,700	192	1,800	21,500
TOYOTA Corolla 1.9 D HATCHB TERRA 2/3-Doors	71,138	69	1,900	12,950
TOYOTA Corolla 1.8 VVTL-i T-Sport 3-Drs 2/3-Doors	31,461	192	1,800	20,950
TOYOTA Corolla 1.8 16V VVTI 3DR T SPORT BNS 2/3-Doors	43,610	192	1,800	19,950
TOYOTA Corolla 1.6 VVTI Linea Terra Comfort 2/3-Doors	21,716	110	1,600	17,950
TOYOTA Corolla 1.6 16v L.SOL 2/3-Doors	25,563	110	1,600	16,750
TOYOTA Corolla 1.6 16V VVT I 3DR TERRA 2/3-Doors	64,359	110	1,600	16,950
TOYOTA Corolla 1.6 16V VVT I 3DR SOL AUT4 2/3-Doors	43,905	110	1,600	16,950
TOYOTA Corolla 1.6 16V VVT I 3DR SOL 2/3-Doors	56,349	110	1,600	15,950
TOYOTA Corolla 1.4 VVTI Linea Terra 2/3-Doors	9,750	97	1,400	12,950
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	27,500	97	1,400	14,750
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	49,059	97	1,400	13,950
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	44,068	97	1,400	16,750
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	46,961	97	1,400	13,950
TOYOTA Corolla 2.0 D4D 90 5DR TERRA COMFORT 4/5-Doors	110,404	90	2,000	16,950
TOYOTA Corolla 2.0 D4D 90 5DR TERRA COMFORT 4/5-Doors	100,250	90	2,000	16,950
TOYOTA Corolla 2.0 D4D 90 5DR SOL 4/5-Doors	84,000	90	2,000	19,000
TOYOTA Corolla 2.0 D4D 90 5DR TERRA 4/5-Doors	79,375	90	2,000	17,950
TOYOTA Corolla 1.4 16V VVT I 5DR TERRA COMFORT 4/5-Doors	75,048	97	1,400	15,800



지도학습 예시 (회귀 Regression, 문제)

- ❖ 종속변수 (y), 독립변수 (x)
- ❖ 관측치, 샘플, Observation

The diagram illustrates a dataset for regression analysis. A table contains 5 rows and 4 columns. The first three columns are grouped under the variable x (independent variables), and the fourth column is labeled y (dependent variable). The number of columns is labeled p , and the number of rows is labeled n . The second row is highlighted with a red border.

x			y
p			
Bedrooms	Sq. feet	Neighborhood	Sale price
3	2000	Normaltown	\$250,000
2	800	Hipsterton	\$300,000
2	850	Normaltown	\$150,000
1	550	Normaltown	\$78,000
4	2000	Skid Row	\$150,000

n

지도학습 예시 (분류 Classification, 문제)

❖ 종속변수 (y), 독립변수 (x)

❖ 관측치, 샘플, Observation


The diagram shows a table with 5 rows and 4 columns. The first three columns are grouped under the label x (independent variables), and the fourth column is labeled y (dependent variable). A bracket labeled p spans the first three columns, indicating the number of features. A bracket labeled n spans all four columns of the table, indicating the number of observations. The second row is highlighted with a red border.

x			y
p			
Bedrooms	Sq. feet	Neighborhood	Sale price
3	2000	Normaltown	High
2	800	Hipsterton	Low
2	850	Normaltown	High
1	550	Normaltown	Low
4	2000	Skid Row	High


지도학습 예시 (분류 Classification, 문제)

❖ 종속변수 (y), 독립변수 (x)

❖ Note: 이미지 하나가 샘플이며, 이미지에 모든 pixel이 독립변수가 되고 범주 (클래스)가 종속변수가 됨



x



y

airplane

automobile

bird

cat

deer

dog

frog


horse

ship

truck

지도학습 (Supervised Learning)

- 학습데이터로부터 $X \rightarrow Y$ 의 관계를 설명하는 함수 (f)를 찾는 방법론
- 종속변수 y 가 범주형이면 분류(classification), 연속형이면 회귀(regression)



- 연속형 데이터: 데이터를 자체를 숫자로 표현
예) 가격, 길이, 압력, 두께, ...
- 범주형 데이터: 원칙적으로 숫자로 표시할 수 없는 데이터
예) 제품불량여부 (양품/불량), 보험사기여부(정상/비정상), ...

Machine Learning Algorithms OR Methods




What Kind of Data ?

❖ Structured and Unstructured



Deep Learning의 역사

- Deep learning의 역사 = Artificial Neural Network의 역사
- 2006년 Hinton에 의해 많은 레이어를 학습할 수 있게 됨과 동시에 성능향상을 이룸
- 이전에는 2개 이상의 레이어 학습이 불가능



인공신경망 Artificial Neural Networks

$$Y = f(X),$$



- 기본이 되는 모델의 형태, 정보를 처리하는 복잡한 형태? 인간의 뇌?

(사진: <https://qph.fs.quoracdn.net/main-qimg-ddef9699237de8236be0f3becf25ffd3>)

인공신경망 Artificial Neural Networks

$f(\mathbf{X}) = \text{Brain}$



사진1

뉴런(뇌신경세포) 조합




사진2

단일뉴런





사진3

사진1: <https://qph.fs.quoracdn.net/main-qimg-ddef9699237de8236be0f3becf25ffd3>

사진2: <http://www.creaf.uab.es/master/Intranet/MaterialsProfessors/MetodesEstadistics/RobertBenavente/Teoria/TDSIG%20Neural%20Networks.pdf>

사진3: <https://training.seer.cancer.gov/anatomy/nervous/tissue.html>


인공신경망 Artificial Neural Networks



- 각 뉴런은 수상돌기를 통해 입력신호를 받아서 축색돌기를 통해 다른 뉴런으로 출력신호를 보낸다.
- **출력신호는 일정한 전기 신호 용량을 넘어설 때 발생**
- Axon: 축색돌기
- Dendrite: 수상돌기

인공신경망 Artificial Neural Networks

단일뉴런




- 각 뉴런은 수상돌기를 통해 다른 뉴런에서 입력신호를 받아서 축삭돌기를 통해 다른 뉴런으로 신호를 보낸다.
- Axon: 축삭돌기
- Dendrite: 수상돌기

Perceptron

Input Layer
(Dendrite)


Input Layer



- ANN 모델은 생물학적인 뉴런을 수학적으로 모델링한 것.

Linear and Logistic Regression & ANN (Perceptron)

- 가장 간단한 신경망 모델은 logistic regression / linear regression과 같다



For classification,

$$\hat{Y} = \text{Activation}(W_1X_1 + W_2X_2 + W_3X_3 + b)$$

For regression,


$$\hat{Y} = W_1X_1 + W_2X_2 + W_3X_3 + b$$

W : weight, 학습해야 할 모델의 파라미터

회귀 Perceptron = 선형 회귀 (Linear Regression)

$$Y = f(X) + \varepsilon(\text{오차}) = w_1 X + w_0 + \varepsilon(\text{오차})$$


X	Y
170	175
165	160
180	181
175	177
154	156.5
165.3	166
...	



선형 회귀는 X와 Y의 관계를 선형 형태로 모델링

단순 회귀 Perceptron 학습 예시!

$$Y = f(X) + \varepsilon(\text{오차}) = w_1 X + w_0 + \varepsilon(\text{오차})$$



X와 Y의 관계를 나타내는 직선은 무수히 많음
X와 Y의 관계를 잘 설명하는 최적의 선형 모델링 찾아야함

학습이란??

$$Y = f(X) + \varepsilon = w_1 X + w_0 + \varepsilon$$

$$Y = \hat{f}(X) + e = \hat{w}_1 X + \hat{w}_0 + e$$

$$Y \approx \hat{f}(X) = \hat{w}_1 X + \hat{w}_0$$

- 모델의 **파라미터 (Parameter)**
 - 선형 회귀 모델의 **계수**

머신러닝 모델을 학습 (Learning)

선형 회귀 모델의 최적 파라미터를 찾자

선형 회귀 모델의 최적 파라미터를 추정 (Estimation)하자

회귀 Perceptron – 여러 개 인풋

$$Y \approx \hat{f}(X) = \mathbf{w}_1 X_1 + \mathbf{w}_2 X_2 + \cdots + \mathbf{w}_p X_p + \mathbf{w}_0$$

Y	$p + 1$				
	X_1	X_2	...	X_p	X_0
y^1	x_1^1	x_2^1	...	x_p^1	1
y^2	x_1^2	x_2^2	...	x_p^2	1
y^3	x_1^3	x_2^3	...	x_p^3	1
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	$\vdots$
y^n	x_1^n	x_2^n	...	x_p^n	1

Y
X

회귀 Perceptron - 여러 개 인풋

중고차 데이터

$$\hat{f}(x) \approx y$$

x : 독립변수, 입력변수
 y : 종속변수, 출력변수

Input 변수 =
자동차특성 x

y Output 변수 = 목적

주행거리	마력	용량
46,986	90	2,000
19,700	192	1,800
71,138	69	1,900
31,461	192	1,800
43,610	192	1,800
21,716	110	1,600
25,563	110	1,600
64,359	110	1,600
43,905	110	1,600
56,349	110	1,600
9,750	97	1,400
27,500	97	1,400
49,059	97	1,400
44,068	97	1,400

가격
13,500
21,500
12,950
20,950
19,950
17,950
16,750
16,950
16,950
15,950
12,950
14,750
13,950
16,750

회귀 Perceptron - 여러 개 인풋

$$Y \approx \hat{f}(X) = w_1 \text{거리} + w_2 \text{마력} + w_3 \text{용량} + w_0$$

x : 독립변수, 입력변수
 y : 종속변수, 출력변수

Input 변수 =
자동차특성 x


주행거리	마력	용량
46,986	90	2,000
19,700	192	1,800
71,138	69	1,900
31,461	192	1,800
43,610	192	1,800
21,716	110	1,600
25,563	110	1,600
64,359	110	1,600
43,905	110	1,600
56,349	110	1,600
9,750	97	1,400
27,500	97	1,400
49,059	97	1,400
44,068	97	1,400

y Output 변수 = 목적

가격
13,500
21,500
12,950
20,950
19,950
17,950
16,750
16,950
16,950
15,950
12,950
14,750
13,950
16,750

가장 간단한 형태의 Artificial Neural Networks (Perceptron)

- 가장 간단한 신경망 모델은 logistic regression / linear regression과 같다



For classification,

$$\hat{Y} = \text{Activation}(W_1X_1 + W_2X_2 + W_3X_3 + b)$$

For regression,

$$\hat{Y} = \hat{F}(x) = W_1X_1 + W_2X_2 + W_3X_3 + b$$

W : weight, 학습해야 할 모델의 파라미터



- 어떻게 파라미터를 찾는가?
- 좋고 나쁨을 어떻게 측정할 것인가?

모델의 성능 평가와 손실함수 (Loss Function)

- ❖ 우리는 종속변수 (y) 와 독립변수 (x) 사이의 관계를 **잘** 설명하게끔 모델을 학습시켜야 (함수를 찾아야) 한다.
- ❖ 여기서 **잘** 설명한다는 것은 모델로부터 나온 결과와 실제 결과 간의 차이가 (오차가) 작다는 것을 의미한다.

실제값	A 예측	B 예측
10	11	5
5	4	7
7	8	3

$$MSE = \frac{1}{3} \sum_{i=1}^3 (y - \hat{y})^2$$

MSE: Mean Squared Error의 약자로 Regression의 일반적인 성능 평가 함수
 $\hat{y}$: 모델에 독립변수를 넣었을 때 출력된 값 $\hat{y} = f(x)$

모델의 성능 평가와 손실함수 (Loss Function)

- ❖ 우리는 종속변수 (y) 와 독립변수 (x) 사이의 관계를 **잘** 설명하게끔 모델을 학습시켜야 (함수를 찾아야) 한다.
- ❖ 여기서 **잘** 설명한다는 것은 모델로부터 나온 결과와 실제 결과 간의 차이가 (오차가) 작다는 것을 의미한다.

실제값	A 예측	B 예측
10	11	5
5	4	7
7	8	3

$$MSE = \frac{1}{3} \sum_{i=1}^3 (y - \hat{y})^2$$

A: 1 B: 15

어떤 모델이 더 좋은 모델일까요?

모델의 성능 평가와 손실함수 (Loss Function)

- ❖ 우리는 종속변수 (y) 와 독립변수 (x) 사이의 관계를 **잘** 설명하게끔 모델을 학습시켜야 (함수를 찾아야) 한다.
- ❖ 여기서 **잘** 설명한다는 것은 모델로부터 나온 결과와 실제 결과 간의 차이가 (오차가) 작다는 것을 의미한다.

실제값	A 예측	B 예측
10	11	5
5	4	7
7	8	3

$$MSE = \frac{1}{3} \sum_{i=1}^3 (y - \hat{y})^2$$

A: 1 B: 15

어떤 모델이 더 좋은 모델일까요?

모델의 성능 평가와 손실함수 (Loss Function)

- ❖ 우리는 종속변수 (y) 와 독립변수 (x) 사이의 관계를 **잘** 설명하게끔 모델을 학습시켜야 (함수를 찾아야) 한다.
- ❖ 여기서 **잘** 설명한다는 것은 모델로부터 나온 결과와 실제 결과 간의 차이가 (오차가) 작다는 것을 의미한다.

실제범주	A 예측	B 예측
상	상	하
하	상	하
상	상	하

$$Error = \frac{1}{3} \sum_{i=1}^3 I(y, \hat{y})$$

$\hat{y}$: 모델에 독립변수를 넣었을 때 출력된 범주 $\hat{y} = f(x)$
 $I(y, \hat{y})$: $y, \hat{y}$ 이 다르면 (모델 예측이 틀리면) 1 아니면 0

모델의 성능 평가와 손실함수 (Loss Function)

- ❖ 우리는 종속변수 (y) 와 독립변수 (x) 사이의 관계를 **잘** 설명하게끔 모델을 학습시켜야 (함수를 찾아야) 한다.
- ❖ 여기서 **잘** 설명한다는 것은 모델로부터 나온 결과와 실제 결과 간의 차이가 (오차가) 작다는 것을 의미한다.

실제범주	A 예측	B 예측
상	상	하
하	상	하
상	상	하

$$Error = \frac{1}{3} \sum_{i=1}^3 I(y, \hat{y})$$

A: 33% B: 67%

어떤 모델이 더 좋은 모델일까요?

모델의 성능 평가와 손실함수 (Loss Function)

- ❖ 우리는 종속변수 (y) 와 독립변수 (x) 사이의 관계를 **잘** 설명하게끔 모델을 학습시켜야 (함수를 찾아야) 한다.
- ❖ 여기서 **잘** 설명한다는 것은 모델로부터 나온 결과와 실제 결과 간의 차이가 (오차가) 작다는 것을 의미한다.

실제범주	A 예측	B 예측
상	상	하
하	상	하
상	상	하

$$Error = \frac{1}{3} \sum_{i=1}^3 I(y, \hat{y})$$

A: 33% **B: 67%**

어떤 모델이 더 좋은 모델일까요?

모델의 성능 평가와 손실함수 (Loss Function)

- ❖ 일반적으로 머신러닝 모델들은 앞서 설명한 오차 함수를 **Loss Function**으로 정의하고 이 **Loss Function**을 최소화하는 방향으로 함수를 최적화 시킨다.

Minimize Loss Function

Learning is Optimization

학습이란? => 파라미터 추정 = 최적화문제 풀기

먼저, 최적화(optimization) 문제란 어떤 목적함수(objective function)의 함수값을 최적화(최대화 또는 최소화)시키는 파라미터(변수) 조합을 찾는 문제를 말합니다.

다루고자 하는 최적화 문제는 별도의 제약조건이 있는 경우와 없는 경우가 존재

$$\begin{array}{ll}\underset{x}{\text{minimize}} & f(x) \\ \text{subject to} & g_i(x) \leq 0, \quad i = 1, \dots, m \\ & h_j(x) = 0, \quad j = 1, \dots, p\end{array}$$

where

- $f: \mathbb{R}^n \rightarrow \mathbb{R}$ is the **objective function** to be minimized over the n -variable vector x ,

최적화(optimization) 문제는 크게 최대화(maximization) 문제와 최소화(minimization) 문제로 나눌 수 있는데 목적함수가 이윤, 점수(score) 등인 경우에는 최대화 문제, 비용(cost), 손실(loss), 에러(error) 등인 경우에는 최소화 문제

학습이란? => 파라미터 추정 – Loss function


<https://scikit-learn.org/stable/modules/classes.html#module-sklearn.metrics>

<code>metrics.explained_variance_score(y_true, ...)</code>	Explained variance regression score function.
<code>metrics.max_error(y_true, y_pred)</code>	The max_error metric calculates the maximum residual error.
<code>metrics.mean_absolute_error(y_true, y_pred, *)</code>	Mean absolute error regression loss.
<code>metrics.mean_squared_error(y_true, y_pred, *)</code>	Mean squared error regression loss.
<code>metrics.mean_squared_log_error(y_true, y_pred, *)</code>	Mean squared logarithmic error regression loss.
<code>metrics.median_absolute_error(y_true, y_pred, *)</code>	Median absolute error regression loss.
<code>metrics.mean_absolute_percentage_error(...)</code>	Mean absolute percentage error (MAPE) regression loss.
<code>metrics.r2_score(y_true, y_pred, *, [...])</code>	R^2 (coefficient of determination) regression score function.
<code>metrics.mean_poisson_deviance(y_true, y_pred, *)</code>	Mean Poisson deviance regression loss.
<code>metrics.mean_gamma_deviance(y_true, y_pred, *)</code>	Mean Gamma deviance regression loss.
<code>metrics.mean_tweedie_deviance(y_true, y_pred, *)</code>	Mean Tweedie deviance regression loss.
<code>metrics.d2_tweedie_score(y_true, y_pred, *)</code>	D^2 regression score function, fraction of Tweedie deviance explained.
<code>metrics.mean_pinball_loss(y_true, y_pred, *)</code>	Pinball loss for quantile regression.
<code>metrics.d2_pinball_score(y_true, y_pred, *)</code>	D^2 regression score function, fraction of pinball loss explained.
<code>metrics.d2_absolute_error_score(y_true, ...)</code>	D^2 regression score function, fraction of absolute error explained.

단순 회귀 Perceptron 학습 예시!

$$Y = f(X) + \varepsilon(\text{오차}) = w_1 X + w_0 + \varepsilon(\text{오차})$$

$$Y = \hat{f}(X) + e(\text{잔차}) = \hat{w}_1 X + \hat{w}_0 + e$$




단순 회귀 Perceptron 학습 (파라미터 추정)

X	Y
170	175
165	160
180	181
175	177
154	156.5
165.3	166
...	

$\hat{f}(X)$



X	Y	$\hat{f}(X)$	e
170	175	170	5
165	160	163	-3
180	181	179	2
175	177	175	2
154	156.5	160	-0.5
165.3	166	166	0
...			



최적의 선형 회귀
모델은 주어진 데이터의
잔차 (e)를 최소화

단순 회귀 Perceptron 학습 (파라미터 추정)

X	Y	$\hat{f}(X)$	e
170	175	170	5
165	160	163	-3
180	181	179	2
175	177	175	2
154	156.5	160	-0.5
165.3	166	166	0
...			

최적의 선형 회귀 모델은 주어진 데이터의 잔차 (e)를 최소화

1. 손실함수 또는 목적함수 정의:
주어진 데이터에 대한 총 에러(잔차)를 정량화

$$\sum_{i=1}^n e_i = e_1 + e_2 + \dots + e_n$$

$$\sum_i e_i^2 = e_1^2 + e_2^2 + \dots + e_n^2 = \text{Squared Error}$$

Cost Function=Loss Function=Objective Function

단순 회귀 Perceptron 학습 (파라미터 추정)

X	Y	$\hat{f}(X)$	e
170	175	170	5
165	160	163	-3
180	181	179	2
175	177	175	2
154	156.5	160	-0.5
165.3	166	166	0
...			

1. 손실 함수 또는 목적함수 정의:

주어진 데이터에 대한 총 에러(잔차)를 정량화

$$\sum_i^n e_i^2 = e_1^2 + e_2^2 + \dots + e_n^2 = \text{Squared Error}$$

2. 비용함수 또는 목적함수이용해 최적화 문제로 변환

$$\begin{aligned} & \text{minimize}_{\hat{w}_1, \hat{w}_0} \sum_i^n e_i^2 \\ & \text{minimize}_{\hat{w}_1, \hat{w}_0} \sum_i^n (y_i - \hat{f}(x_i))^2 \\ & = \text{minimize}_{\hat{w}_1, \hat{w}_0} \sum_i^n (y_i - (\hat{w}_1 x_i + \hat{w}_0))^2 \end{aligned}$$

선형 회귀 학습 (파라미터 추정)

1. 비용함수 또는 목적함수 정의:

$$Loss(\hat{\mathbf{w}}_1, \hat{\mathbf{w}}_0) = \sum_i^n e_i^2 = \sum_i^n \left(y^i - (\hat{\mathbf{w}}_1 x^i + \hat{\mathbf{w}}_0) \right)^2$$

2. 비용함수 또는 목적함수이용해 최적화 문제로 변환

$$\text{minimize}_{\hat{\mathbf{w}}_1, \hat{\mathbf{w}}_0} Loss(\hat{\mathbf{w}}_1, \hat{\mathbf{w}}_0) = \text{minimize} \sum_i^n \left(y^i - (\hat{\mathbf{w}}_1 x^i + \hat{\mathbf{w}}_0) \right)^2$$

3. 최적화 문제 풀기



- 어떻게 파라미터를 찾는가?
- 좋고 나쁨을 어떻게 측정할 것인가?