

Chapter 1. 선형회귀

방 수 식 교수
(bang@tukorea.ac.kr)

한국공학대학교 전자공학부

2023년도 2학기
머신러닝의 이해

■ 벡터(Vector)

- 샘플을 특징 벡터로 feature vector 표현 **Input data**
- 예) Iris 데이터에서 꽃받침의 길이, 꽃받침의 너비, 꽃잎의 길이, 꽃잎의 너비라는 4개의 특징이 각각 5.1, 3.5, 1.4, 0.2인 샘플

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$$




그림 3-2 iris의 세 가지 품종(왼쪽부터 Setosa, Versicolor, Virginica)

- 여러 개의 특징 벡터를 첨자로 구분

$$\mathbf{x}_1 = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 4.9 \\ 3.0 \\ 1.4 \\ 0.2 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 4.7 \\ 3.2 \\ 1.3 \\ 0.2 \end{pmatrix}, \dots, \mathbf{x}_{150} = \begin{pmatrix} 5.9 \\ 3.0 \\ 5.1 \\ 1.8 \end{pmatrix}$$


Input data 1

Input data 2


Input data 3

■ iris 데이터

- 특징이 4개이므로 4차원 특징 공간을 형성
- 150개 샘플 각각은 4차원 특징 공간의 한 점



(a) 4차원 특징 공간(가상의 그림)



(b) 꽃잎 길이 축을 제외한 3차원 특징 공간

그림 3-5 iris 데이터를 특징 공간에 그리기

**특징이 많을수록 사람이 다차원 특징 공간에서 분석하는 것은 불가능
=> Machine은 가능하다. (행렬 연산을 통해)**

■ 행렬 (Matrix)

- 여러 개의 벡터를 담음
- 훈련집합 (Training set)을 담은 행렬
- 예) Iris 데이터에 있는 150개의 샘플을 행렬 $\mathbf{X}$ 로 표현

$$\mathbf{X} = \begin{pmatrix} 5.1 & 3.5 & 1.4 & 0.2 \\ 4.9 & 3.0 & 1.4 & 0.2 \\ 4.7 & 3.2 & 1.3 & 0.2 \\ 4.6 & 3.1 & 1.5 & 0.2 \\ \vdots & \vdots & \vdots & \vdots \\ 6.2 & 3.4 & 5.4 & 2.3 \\ 5.9 & 3.0 & 5.1 & 1.8 \end{pmatrix} = \begin{pmatrix} x_{1,1} & x_{1,2} & x_{1,3} & x_{1,4} \\ x_{2,1} & x_{2,2} & x_{2,3} & x_{2,4} \\ x_{3,1} & x_{3,2} & x_{3,3} & x_{3,4} \\ x_{4,1} & x_{4,2} & x_{4,3} & x_{4,4} \\ \vdots & \vdots & \vdots & \vdots \\ x_{149,1} & x_{149,2} & x_{149,3} & x_{149,4} \\ x_{150,1} & x_{150,2} & x_{150,3} & x_{150,4} \end{pmatrix}$$

← 행 row

↑
열 column

- 행렬 $\mathbf{A}$ 의 전치행렬 $\mathbf{A}^T$ *Transpose matrix*

$$\mathbf{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{pmatrix}, \quad \mathbf{A}^T = \begin{pmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{pmatrix}$$

예를 들어, $\mathbf{A} = \begin{pmatrix} 3 & 4 & 1 \\ 0 & 5 & 2 \end{pmatrix}$ 라면 $\mathbf{A}^T = \begin{pmatrix} 3 & 0 \\ 4 & 5 \\ 1 & 2 \end{pmatrix}$

- Iris의 설계 행렬을 전치행렬 표기에 따라 표현하면,

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_{150}^T \end{pmatrix}$$

■ 행렬 연산

- 행렬 곱셈 $\mathbf{C} = \mathbf{AB}$, 이때 $c_{ij} = \sum_{k=1,s} a_{ik} b_{kj}$

2*3 행렬 $\mathbf{A} = \begin{pmatrix} 3 & 4 & 1 \\ 0 & 5 & 2 \end{pmatrix}$ 와 3*3행렬 $\mathbf{B} = \begin{pmatrix} 2 & 0 & 1 \\ 1 & 0 & 5 \\ 4 & 5 & 1 \end{pmatrix}$ 을 곱하면 2*3 행렬 $\mathbf{C} = \mathbf{AB} = \begin{pmatrix} 14 & 5 & 24 \\ 13 & 10 & 27 \end{pmatrix}$

$6+4+4$ $0+0+5$ $3+20+1$

- 교환법칙 성립하지 않음: $\mathbf{AB} \neq \mathbf{BA}$
- 분배법칙과 결합법칙 성립: $\mathbf{A}(\mathbf{B} + \mathbf{C}) = \mathbf{AB} + \mathbf{AC}$ 이고 $\mathbf{A}(\mathbf{BC}) = (\mathbf{AB})\mathbf{C}$

■ 벡터의 내적

벡터의 내적 $\mathbf{a} \cdot \mathbf{b} = \mathbf{a}^T \mathbf{b} = \sum_{k=1,d} a_k b_k \leftarrow \text{스칼라}$

$\mathbf{x}_1 = \begin{pmatrix} 5.1 \\ 3.5 \\ 1.4 \\ 0.2 \end{pmatrix}$ 와 $\mathbf{x}_2 = \begin{pmatrix} 4.9 \\ 3.0 \\ 1.4 \\ 0.2 \end{pmatrix}$ 의 내적 $\mathbf{x}_1 \cdot \mathbf{x}_2$ 는 37.49

회귀(Regression) 란? Linear "Regression"



여러 개의 독립변수와 한 개의 종속변수 간의 상관관계를 모델링하는 기법

- 독립변수 (Independent Variable) 예측 모델 만들기
 - 다른 변수의 변화와 관계없이 독립적으로 변하는 값

- 종속변수 (Dependent Variable)
 - 다른 변수의 변화에 따라 변하는 값

- 예) 추의 무게에 따라 늘어나는 용수철의 길이

독립변수
Input

종속변수
Output

훅(Hooke)의 법칙


$$F = kx$$

$$F = \frac{1}{k}x$$

F: 용수철의 무게 [N]

k: 탄성 계수

x: 늘어난 길이 [m]



[그림 1] 데이터 그래프

회귀 Regression → 숫자값

분류 Classification → 분류해줌

연속된 데이터용

ex) 개- 고양이 분류

탄성 계수를 구하고 싶다!!

How??

선형 회귀(Linear Regression)



- 선형 조합(Linear Combination)으로 모델링하는 회귀 기법

- 단순 선형 회귀 (Simple Linear Regression)

➤ 하나의 x 값 만으로 y 값을 예측할 때


Ex) $y = w_0x + w_1$

weight

가중치

특징수 M 개 선형회귀

→ 가중치 $M+1$ 개 (bias도 가중치에 포함)



[그림 1] 데이터 그래프

- 다중 선형 회귀 (Multiple Linear Regression)

➤ y 값을 예측하기 위해 여러가지 x 가 사용될 때

Ex) $y = w_0x_0 + w_1x_1 + w_2x_2 + \dots + w_{M-1}x_{M-1} + w_M$

가중치

가중치

가중치


bias

비용 함수(Cost Function) = Loss Function



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- 모든 입력에 대해 예측값 ($\hat{y}$)^{변동}과 실제값(y)^{고정}의 차이를 나타낸 함수
- 머신러닝 회귀분석의 목표: Cost Function을 최소화 하는 것



[그림 1] 데이터 그래프

$$\sum_{n=0}^5 (\hat{y}_n - y_n)$$

차이를 모두 양의 값으로 표현하고 싶다.

N : 데이터 수

$$\sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2$$

절대값 안한 이유
→ 미분하려고

값이 너무 크니 평균을 취하자

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2$$

Mean Square Error
평균 제곱 오차

Cost Function의 최소화



(목표) 최대한 $\hat{y} \simeq y$ 을 만족하는 적절한 w_0 와 w_1 을 찾는다.

(수정된 목표) 평균제곱오차를 최소화하는 w_0 와 w_1 를 찾는다.

수학적 표현

$$(w_0^*, w_1^*) = \boxed{\arg \min_{(w_0, w_1)}} \epsilon_{MSE} \neq \min \bar{\epsilon}_{MSE}$$

Arguments of the minimum

Arguments: 함수의 입력

=> 즉, ϵ_{MSE} 를 최소로 만드는 입력값 자체를 의미
 (w_0, w_1)

최적화 되었다는 뜻


(수학적 목표)

$$(w_0^*, w_1^*) = \arg \min_{(w_0, w_1)} \frac{1}{N} \sum_{n=0}^{N-1} \overbrace{(w_0 x_n + w_1 - y_n)^2}^{\uparrow}$$

Analytic Solution



$$\epsilon_{MSE}(w_0, w_1) = \frac{1}{N} \sum_{n=0}^{N-1} (w_0 x_n + w_1 - y_n)^2$$



$$\frac{\partial}{\partial w_0} \epsilon_{MSE}(w_0, w_1) = 0$$

$$\frac{\partial}{\partial w_1} \epsilon_{MSE}(w_0, w_1) = 0$$



$$w_0^* = \frac{\frac{1}{N} \sum_{n=0}^{N-1} y_n \left(x_n - \frac{1}{N} \sum_{i=0}^{N-1} x_i \right)}{\frac{1}{N} \sum_{n=0}^{N-1} x_n^2 - \left(\frac{1}{N} \sum_{n=0}^{N-1} x_n \right)^2}$$


$$w_1^* = \frac{1}{N} \sum_{n=0}^{N-1} (y_n - w_0^* x_n)$$

Analytic Solution



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

데이터 번호	무게 (g)	늘어난 길이 (cm)
1	5	11.66
2	6	13.10
3	7	13.79
4	8	16.71
5	9	17.74
6	10	18.70



Analytic Solution $\hat{y} = 1.4875x + 4.1274$



직접 계산해보기

경사하강법(Gradient Decent Method) *Optimizer Solver*



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- 대부분의 Cost function은 Analytic solution을 구할 수 없음.
 - 머신러닝에서는 수치적으로 접근하는 방법을 사용




■ 미분에 의한 최적화

■ 미분의 정의

$$f'(x) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x) - f(x)}{\Delta x}, \quad f''(x) = \lim_{\Delta x \rightarrow 0} \frac{f'(x + \Delta x) - f'(x)}{\Delta x}$$

- 1차 도함수 $f'(x)$ 는 함수의 기울기, 즉 값이 커지는 방향을 지시함
- 따라서 $-f'(x)$ 방향에 목적함수의 최저점이 존재



$$y = f(x) = x^2 - 4x + 3$$

$$y' = f'(x) = 2x - 4$$

그림 2-24 간단한 미분 예제

■ 편미분

- 독립변수가 여러 개인 함수에 대한 미분 개념을 적용할 때 사용
- 미분값이 이루는 벡터를 **그레디언트(Gradient)**라 부름
- 여러 가지 표기: $\nabla f, \frac{\partial f}{\partial \mathbf{x}}, \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}\right)^T$
- 예)

$$\left. \begin{aligned} f(\mathbf{x}) &= f(x_1, x_2) = \left(4 - 2.1x_1^2 + \frac{x_1^4}{3}\right)x_1^2 + x_1x_2 + (-4 + 4x_2^2)x_2^2 \\ \nabla f = f'(\mathbf{x}) &= \frac{\partial f}{\partial \mathbf{x}} = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}\right)^T = (2x_1^5 - 8.4x_1^3 + 8x_1 + x_2, 16x_2^3 - 8x_2 + x_1)^T \end{aligned} \right\}$$

■ 머신러닝에서의 편미분

- 매개변수 집합 θ 에 독립변수(특징)들이 있으므로 편미분을 사용

■ 연쇄법칙

- 합성함수 $f(x) = g(h(x))$ 의 미분

$$\left. \begin{aligned} f'(x) &= g'(h(x))h'(x) \\ f'(x) &= g'(h(i(x)))h'(i(x))i'(x) \end{aligned} \right\}$$

- 예) $f(x) = 3(2x^2 - 1)^2 - 2(2x^2 - 1) + 5$ 일 때 $h(x) = 2x^2 - 1$ 로 두면,

$$f'(x) = \underbrace{(3 * 2(2x^2 - 1) - 2)}_{g'(h(x))} \underbrace{(2 * 2x)}_{h'(x)} = 48x^3 - 32x$$

■ 다층 퍼셉트론은 합성함수

- $\frac{\partial o_i}{\partial u_{23}^1}$ 를 계산할 때 연쇄법칙 적용
- 인공신경망 파트에서 자세히 설명




그림 2-26 다층 퍼셉트론은 합성함수


경사하강법(Gradient Decent Method)




지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- 최소값에서 접선의 기울기에 해당하는 미분 계수는 0
 - 여러 번의 반복 (iteration)을 통해 미분 계수가 0이 되는 지점을 찾는다.

- 미분 계수 (Gradient)는 언제나 현재 위치에서 함수값이 커지는 방향을 가리키므로, 미분 계수의 반대 방향으로 이동하면 최소값을 찾을 수 있음
 - 즉 Gradient에 마이너스(-)를 취하여 더한다.



α가 없을때:



발산할 위험

Learning Rate > 0

$$\boxed{\text{New}} w_0[t+1] = \boxed{\text{Old}} w_0[t] - \boxed{\alpha} \frac{\partial}{\partial w_0} \epsilon_{MSE}(\boxed{\text{Old}} w_0, w_1)$$

$$w_1[t+1] = w_1[t] - \alpha \frac{\partial}{\partial w_1} \epsilon_{MSE}(w_1, w_2)$$

방향: 접선의 기울기와 반대
방향으로

경사하강법(Gradient Decent Method)




$$\boxed{\overset{\text{New}}{w_0[t+1]}} = \boxed{\overset{\text{Old}}{w_0[t]}} - \overset{\text{Learning Rate}}{\alpha} \frac{\partial}{\partial w_0} \epsilon_{MSE}(\boxed{\overset{\text{Old}}{w_0}}, \boxed{\overset{\text{Old}}{w_1}})$$

- 1) w_0 와 w_1 에 대해서 임의의 값을 설정 => Initialization(초기화)
- 2) t 지점에서 Cost Function에 대한 미분 계수(기울기)를 구함
- 3) 기울기의 반대 방향으로 point를 $\alpha \times$ 기울기의 크기 만큼 이동시킴. ($t+1$ 로 이동)
- 4) Stop 조건 확인
 - 4-1) Stop 조건에 만족할 경우: 현재의 값을 최종 값으로 선택
 - 4-2) Stop 조건에 만족하지 않을 경우, step 2)로 돌아감

❖ Stop 조건

- 더 이상 변수가 변하지 않는다. (미분 값이 0)
- 변화량이 매우 작다. (미분 값이 매우 작다)



학습률(Learning Rate)



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.


- 학습률 (Learning Rate)
 - 경사 하강법에서 미분 계수 앞에 곱해져 이동 거리를 결정하는 변수
 - 미분 계수의 크기는 최소값에서 멀어질수록 커지는 성질을 가짐
 - 학습률을 곱하지 않을 경우 발산 가능
 - 적절한 값을 찾아야 머신러닝의 학습 성공이 가능
 - 하이퍼 파라미터(Hyper-parameter)의 최적화

머신러닝 설계자가 직접 세팅하는 값

최적화 공식 X

강 감으로 해야 됨

: 학습률, 학습 반복 횟수, Stop 조건 등



경사하강법의 선형회귀 적용




지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.


Optimal Solution

$$\hat{y} = 1.4875x + 4.1274$$

- 초기값: $w_0[0] = 2$ 와 $w_1[0] = 2.5$
- Learning Rate: $\alpha = 0.015$
- 3000회 반복 시: $w_0 = 1.4902$, $w_1 = 4.1063$




[그림 3] 경사하강법의 단계별 매개변수 값의 변화, $\alpha = 0.01$



주로, 사람이 판단 할 때는
MSE 가 수렴하는 것을 확인

[그림 4] 단계별 평균제곱오차의 변화



Error에 대한 편미분



$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2$$

예측값 참값 $\Rightarrow$ 고정값 $\Rightarrow$ 상수

- 1차 다항식 모델

$$\hat{y}_n = w_0 x_0 + w_1 x_1 + w_2 x_2$$

$\swarrow$ Dummy Term (= 1)

$$\frac{\partial}{\partial w_0} \epsilon_{MSE}(w_0, w_1 \dots) = \frac{2}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n) x_0$$

$\nwarrow$ 편미분 $\swarrow$ 손미분

$$\frac{\partial}{\partial w_1} \epsilon_{MSE}(w_0, w_1 \dots) = \frac{2}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n) x_1$$

$\nwarrow$ 편미분 $\swarrow$ 손미분

$\Rightarrow \frac{\partial \text{cost}}{\partial \vec{w}} = \epsilon_{MSE}$

$\searrow$ 비용함수

$\searrow$ 요소곱 (not 행렬곱!)

$$\vdots$$

$$= \frac{1}{N} \sum_{n=0}^{N-1} ((\vec{f}_n - \vec{y}_n) \cdot \vec{x})$$

눈으로 직접 확인하는 경사하강법



MATLAB 활용

$$\boxed{\text{New}} \quad w_0[t+1] = \boxed{\text{Old}} \quad w_0[t] - \boxed{\alpha} \frac{\partial}{\partial w_0} \epsilon_{MSE}(\boxed{\text{Old}} \quad w_0, w_1)$$

Learning Rate

$$w_1[t+1] = w_1[t] - \alpha \frac{\partial}{\partial w_1} \epsilon_{MSE}(w_0, w_1)$$

$$\frac{\partial}{\partial w_0} \epsilon_{MSE}(w_0, w_1) = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n) x$$

$$\frac{\partial}{\partial w_1} \epsilon_{MSE}(w_0, w_1) = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)$$

데이터 번호	무게 (g)	늘어난 길이 (cm)
1	5	11.66
2	6	13.10
3	7	13.79
4	8	16.71
5	9	17.74
6	10	18.70

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2$$

예측값 참값 => 고정값 => 상수

최적의 회귀선을 찾고 싶음

↳ 회귀선의 오차 함수 Cost Function

↳ Cost Function의 오차 평균: ϵ_{MSE}

↳ 학습률을 조정해서 Cost Function의 최적 입력값을 찾음

↳ Learning Rate

다차원 데이터로의 확장



단일 변수 대한 Cost Function: $\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (w_0 \boxed{x_n} + w_1 - y_n)^2$
 변수가 여러 개라면? 단일 변수 (용수철 무게)

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2$$

$$= \frac{1}{N} \sum_{n=0}^{N-1} (w_0 \boxed{x_{0,n}} + w_1 \boxed{x_{1,n}} + \dots + w_{M-1} \boxed{x_{M-1,n}} + w_M - \boxed{y_n})^2$$

속도 질량 온도 거리

n : 측정된 데이터 수에 대한 Index

M : 입력 데이터 Type 수 (데이터 차원 수)

Notation에 대한 개념
확실하게 이해 필요

$x_{m,n}$: n 번째 데이터
 m 번째 특징

N 대신 n : m 이랑 같음

데이터 번호	입력	출력
0	$x_{0,0}, x_{1,0}, \dots, x_{m,0}, \dots, x_{M-1,0}$	y_0
1	$x_{0,1}, x_{1,1}, \dots, x_{m,1}, \dots, x_{M-1,1}$	y_1
$\vdots$	$\vdots$	$\vdots$
n	$x_{0,n}, x_{1,n}, \dots, x_{m,n}, \dots, x_{M-1,n}$	y_n
$\vdots$	$\vdots$	$\vdots$
$N-1$	$x_{0,N-1}, x_{1,N-1}, \dots, x_{m,N-1}, \dots, x_{M-1,N-1}$	y_{N-1}

다차원 데이터를 위한 벡터 표현



$$\begin{aligned}\epsilon_{MSE} &= \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 \\ &= \frac{1}{N} \sum_{n=0}^{N-1} (w_0 x_{0,n} + w_1 x_{1,n} + \dots + w_{M-1} x_{M-1,n} + w_M - y_n)^2\end{aligned}$$

$$\hat{y} = w_0 x_0 + w_1 x_1 + \dots + w_{M-1} x_{M-1} + \boxed{w_M x_M}$$

→ 불임으로서 벡터 연산으로 변환 가능
→ 항상 1
핵심 트릭

$$\hat{y} = \begin{matrix} \mathbf{w}^T \end{matrix} \begin{matrix} \mathbf{x} \\ \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{M-1} \\ x_M \end{bmatrix} \end{matrix} = \mathbf{w}^T \mathbf{x}$$

← dummy term

**복잡했던 식을
벡터의 곱으로
간단하게 표현**

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (\mathbf{w}^T \mathbf{x}_n - y_n)^2$$

다차원 입력데이터에 대한 Cost Function

=> Cost Function 이 최소가 되는 $\mathbf{w} = [w_0 \ w_1 \ w_2 \ \dots \ w_M]$ 가 Optimal Solution

다차원 데이터에 대한 Analytic Solution



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (w^T x_n - y_n)^2$$

편미분을 통한 해석해 구하기

$$\begin{aligned} \frac{\partial}{\partial w_m} \epsilon_{MSE} &= \frac{2}{N} \sum_{n=0}^{N-1} (w^T x_n - y_n) \frac{\partial}{\partial w_m} w^T x_n \\ &= \frac{2}{N} \sum_{n=0}^{N-1} (w^T x_n - y_n) x_{m,n} = 0 \text{ 이 되는 해} \end{aligned}$$

$$\begin{aligned} m=0 \text{ 일 때, } & \sum_{n=0}^{N-1} (w^T x_n - y_n) x_{0,n} = 0 \\ m=1 \text{ 일 때, } & \sum_{n=0}^{N-1} (w^T x_n - y_n) x_{1,n} = 0 \\ & \vdots \\ m=M-1 \text{ 일 때, } & \sum_{n=0}^{N-1} (w^T x_n - y_n) x_{M-1,n} = 0 \\ m=M \text{ 일 때, } & \sum_{n=0}^{N-1} (w^T x_n - y_n) x_{M,n} = 0 \end{aligned}$$

$$\sum_{n=0}^{N-1} (w^T x_n - y_n) x_n^T = [0 \ 0 \ \cdots \ 0 \ 0]$$

다차원 데이터에 대한 Analytic Solution



$$\begin{aligned} \sum_{n=0}^{N-1} (w^T x_n - y_n) x_n^T &= [0 \ 0 \ \cdots \ 0 \ 0] \\ &= \sum_{n=0}^{N-1} (w^T x_n x_n^T - y_n x_n^T) = w^T \underbrace{\sum_{n=0}^{N-1} x_n x_n^T}_{\textcircled{1}} - \underbrace{\sum_{n=0}^{N-1} y_n x_n^T}_{\textcircled{2}} = [0 \ 0 \ \cdots \ 0 \ 0] \end{aligned}$$

$$\mathbf{x} = \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_{M-1} \\ x_M \end{bmatrix}$$

① $\sum_{n=0}^{N-1} x_n x_n^T$ $M=2, N=3$ 인 경우

$$\begin{aligned} \sum_{n=0}^2 x_n x_n^T &= \sum_{n=0}^2 \begin{bmatrix} x_{0,n} \\ x_{1,n} \\ x_{2,n} \end{bmatrix} [x_{0,n} \ x_{1,n} \ x_{2,n}] \\ &= \sum_{n=0}^2 \begin{bmatrix} x_{0,n}^2 & x_{0,n}x_{1,n} & x_{0,n}x_{2,n} \\ x_{1,n}x_{0,n} & x_{1,n}^2 & x_{1,n}x_{2,n} \\ x_{2,n}x_{0,n} & x_{2,n}x_{1,n} & x_{2,n}^2 \end{bmatrix} \end{aligned}$$

다차원 데이터에 대한 Analytic Solution



이전 강좌 복습

$$\sum_{n=0}^2 x_n x_n^T = \sum_{n=0}^2 \begin{bmatrix} x_{0,n} \\ x_{1,n} \\ x_{2,n} \end{bmatrix} \begin{bmatrix} x_{0,n} & x_{1,n} & x_{2,n} \end{bmatrix}$$

$$= \sum_{n=0}^2 \begin{bmatrix} x_{0,n}^2 & x_{0,n}x_{1,n} & x_{0,n}x_{2,n} \\ x_{1,n}x_{0,n} & x_{1,n}^2 & x_{1,n}x_{2,n} \\ x_{2,n}x_{0,n} & x_{2,n}x_{1,n} & x_{2,n}^2 \end{bmatrix}$$

$$= \begin{bmatrix} x_{0,0}^2 & x_{0,0}x_{1,0} & x_{0,0}x_{2,0} \\ x_{1,0}x_{0,0} & x_{1,0}^2 & x_{1,0}x_{2,0} \\ x_{2,0}x_{0,0} & x_{2,0}x_{1,0} & x_{2,0}^2 \end{bmatrix} + \begin{bmatrix} x_{0,1}^2 & x_{0,1}x_{1,1} & x_{0,1}x_{2,1} \\ x_{1,1}x_{0,1} & x_{1,1}^2 & x_{1,1}x_{2,1} \\ x_{2,1}x_{0,1} & x_{2,1}x_{1,1} & x_{2,1}^2 \end{bmatrix} + \begin{bmatrix} x_{0,2}^2 & x_{0,2}x_{1,2} & x_{0,2}x_{2,2} \\ x_{1,2}x_{0,2} & x_{1,2}^2 & x_{1,2}x_{2,2} \\ x_{2,2}x_{0,2} & x_{2,2}x_{1,2} & x_{2,2}^2 \end{bmatrix}$$

$$= \begin{bmatrix} x_{0,0} & x_{0,1} & x_{0,2} \\ x_{1,0} & x_{1,1} & x_{1,2} \\ x_{2,0} & x_{2,1} & x_{2,2} \end{bmatrix} \begin{bmatrix} x_{0,0} & x_{1,0} & x_{2,0} \\ x_{0,1} & x_{1,1} & x_{2,1} \\ x_{0,2} & x_{1,2} & x_{2,2} \end{bmatrix}$$

$$= X^T X$$

$$X = \begin{bmatrix} x_{0,0} & x_{1,0} & \cdots & x_{M-1,0} & x_{M,0} \\ x_{0,1} & x_{1,1} & \cdots & x_{M-1,1} & x_{M,1} \\ \vdots & \vdots & & \vdots & \vdots \\ x_{0,N-1} & x_{1,N-1} & \cdots & x_{M-1,N-1} & x_{M,N-1} \end{bmatrix}$$

다차원 데이터에 대한 Analytic Solution



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

$$\textcircled{2} \sum_{n=0}^{N-1} y_n x_n^T \quad M=2, N=3 \text{인 경우}$$

$$\begin{aligned} \sum_{n=0}^2 y_n x_n^T &= \sum_{n=0}^2 y_n [x_{0,n} \ x_{1,n} \ x_{2,n}] \\ &= \sum_{n=0}^2 [y_n x_{0,n} \ y_n x_{1,n} \ y_n x_{2,n}] \\ &= [y_0 x_{0,0} \ y_0 x_{1,0} \ y_0 x_{2,0}] + [y_1 x_{0,1} \ y_1 x_{1,1} \ y_1 x_{2,1}] + [y_2 x_{0,2} \ y_2 x_{1,2} \ y_2 x_{2,2}] \\ &= [y_0 \ y_1 \ y_2] \begin{bmatrix} x_{0,0} & x_{1,0} & x_{2,0} \\ x_{0,1} & x_{1,1} & x_{2,1} \\ x_{0,2} & x_{1,2} & x_{2,2} \end{bmatrix} \\ &= y^T X \end{aligned}$$

$$y = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{bmatrix}$$

다차원 데이터에 대한 Optimal Solution



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

$$\sum_{n=0}^{N-1} (w^T x_n - y_n) x_n^T = [0 \ 0 \ \cdots \ 0 \ 0]$$



데이터 수에 대한 Summation 계산을
행렬 계산으로 한번에 계산 가능해짐

$$w^T X^T X - y^T X = [0 \ 0 \ \cdots \ 0 \ 0]$$

$$\begin{aligned} (w^T X^T X - y^T X)^T &= (w^T X^T X)^T - (y^T X)^T \\ &= (X^T X)^T w - X^T y \\ &= X^T X w - X^T y = [0 \ 0 \ \cdots \ 0 \ 0] \end{aligned}$$

$$X^T X w = X^T y$$

$$w = \boxed{(X^T X)^{-1}} X^T y$$

역행렬이 항상 존재한다는 것을 보장 할 수 없음

즉, 수치적 접근을 통한 최적해 (Optimal Solution) 을 구하는 것이 일반적

- 비용 함수(Cost Function)

- $cost(a, b) = \epsilon_{MSE}(a, b) = \frac{1}{N} \sum_{n=0}^{N-1} (ax_i + b - y_i)^2$

- $\rightarrow cost(W) = l\epsilon_{MSE}(W) = \frac{1}{N} \sum_{n=0}^{N-1} (W^T X^{(i)} - Y^{(i)})^2$

- 경사하강법 (Gradient Decent Method) : *백행렬 항산 존재 X 이기 때문*

- $a_{new} = a_{old} - \alpha \left. \frac{\partial cost(a,b)}{\partial a} \right|_{(a_{old}, b_{old})}$


- $b_{new} = b_{old} - \alpha \left. \frac{\partial cost(a,b)}{\partial b} \right|_{(a_{old}, b_{old})}$

- $\rightarrow W_{new} = W_{old} - \alpha \left. \frac{\partial cost(W)}{\partial W} \right|_{W_{old}}$

선형 기저함수 모델



■ 선형 기저함수 모델(Linear Basis Function Model)



대표적 기저함수 모델




지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- Polynomial Basis Function(다항식 기저함수) $\phi_k(x) = x^k$

- Gaussian Basis Function(가우시안 기저함수) $\phi_k(x) = e^{-\frac{1}{2} \left(\frac{x - \mu_k}{\sigma} \right)^2}$

✱ 추가적 공부 필요



Basis: 5개

← 원래 피싱색 Basis 5개
↓
선행회귀 돌리면 Basis에 가중치
↓
이렇게 변함

Colored bands are the true and measured components

출처: <https://pythonmachinelearning.pro/using-neural-networks-for-regression-radial-basis-function-networks/>

기저함수 개수 K에 따른 파라미터 설정




지능형 예측·진단 연구실
Intelligent Prognostics Research Center

■ Gaussian Basis Function(가우시안 기저함수)

- k번째 가우스 함수의 평균


$$\mu_k = x_{\min} + \frac{x_{\max} - x_{\min}}{K-1} k, \quad k=0, 1, \dots, K-1$$



$$\phi_k(x) = e^{-\frac{1}{2} \left(\frac{x - \mu_k}{\sigma} \right)^2}$$



(데이터가 평균에서 얼마나 퍼져있는지)

99% 일 때





- 모든 가우스 함수의 분산

$$\sigma = \frac{x_{\max} - x_{\min}}{K-1}$$




기저함수	μ_k	σ
① $\phi_0(x)$	5	5
② $\phi_1(x)$	10	
③ $\phi_2(x)$	15	


기저함수가 많을수록 분산↓




① 기저함수 세팅




② 기저함수 중독 (선형회귀)



③ 다 더하기



④ Bias로 위아래로 움직임



기저함수 수(K)에 따른 결과 비교



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.


$$\hat{y} = 27.02 e^{-\frac{1}{2} \left(\frac{x-5}{5} \right)^2} + 3.46 e^{-\frac{1}{2} \left(\frac{x-10}{5} \right)^2} + 39.08 e^{-\frac{1}{2} \left(\frac{x-15}{5} \right)^2} - 23.82$$

$\phi_0(x)$ $\phi_1(x)$ $\phi_2(x)$


$$w = \begin{bmatrix} 27.02 \\ 3.46 \\ 39.08 \\ -23.82 \end{bmatrix}$$

기저함수 개수 $K \propto \frac{1}{\text{분산 } \delta}$

$K = 3$



$K = 8$



$K=100$ 일 때:
향후 새 데이터 (노이즈) 이 들어올 때
 $K=8$ 보다 오차가 커질

MSE가 작다고 무조건 좋은 것일까?

단점: 향후 새 데이터가 들어올 때
오차가 커질 수 있음

선형 기저함수 모델의 Analytic Solution



- 비용함수: 평균제곱오차

$$\epsilon_{MSE} = \frac{1}{N} \sum_{n=0}^{N-1} (\hat{y}_n - y_n)^2 = \frac{1}{N} \sum_{n=0}^{N-1} (\phi(x_n) - y_n)^2$$

$$\phi(x_n) = \begin{bmatrix} \phi_0(x_n) \\ \phi_1(x_n) \\ \vdots \\ \phi_{K-1}(x_n) \\ \phi_K(x_n) \end{bmatrix}$$

- N개의 훈련 데이터 입력에 대한 행렬

$$\Phi = \begin{bmatrix} \phi_0(x_0) & \phi_1(x_0) & \cdots & \phi_{K-1}(x_0) & \phi_K(x_0) \\ \phi_0(x_1) & \phi_1(x_1) & \cdots & \phi_{K-1}(x_1) & \phi_K(x_1) \\ \vdots & \vdots & & \vdots & \vdots \\ \phi_0(x_{N-1}) & \phi_1(x_{N-1}) & \cdots & \phi_{K-1}(x_{N-1}) & \phi_K(x_{N-1}) \end{bmatrix}$$

- N개의 훈련 데이터 출력에 대한 벡터

$$\mathbf{y} = \begin{bmatrix} y_0 \\ y_1 \\ \vdots \\ y_{N-1} \end{bmatrix}$$

- Analytic Solution

$$\mathbf{w} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{y}$$



다중 선형회귀 모델과 비교

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$