

Chap.2 모델의 검증과 평가 (Model Test and Evaluation)

방 수 식 교수
(bang@tukorea.ac.kr)

한국공학대학교 전자공학부

2023년도 2학기
머신러닝의 이해

머신러닝의 목표와 모델





지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

■ 머신러닝 모델

- 입력(Input)에 따라 출력(Output)을 생산 => 전달함수

■ 머신러닝의 목표

- 입력에 따른 출력이 실측값과 동일한 결과를 만드는 전달함수(모델) 도출



■ 오차(Error)

- 전체 데이터에 대해, 실측값 – 모델의 예측값
- 다양한 측정 방법이 가능하며 일반적으로 $[0,1]$ 사이의 값을 갖도록 설계

■ 평균 제곱 오차 (Mean squared error, MSE)

- 머신러닝 모델의 대표적인 성능 평가 기준
- 데이터 세트 $D = \{(\mathbf{x}_0, y_0), (\mathbf{x}_1, y_1), \dots, (\mathbf{x}_{N-1}, y_{N-1})\}$
- 모델 f 의 이상적인 성능은 $f(\mathbf{x}) = y$, 즉 예측값이 실제값과 동일
 - 실제로는 오차 발생

○ 정의

$$\epsilon_{MSE}(f; D) = \frac{1}{N} \sum_{n=0}^{N-1} (f(\mathbf{x}_n) - y_n)^2$$

Training set과 Test set



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

■ Training set

- 모델을 학습(Training)하기 위한 데이터 set
= 경량화 방법 => Weight의 Update

$$\overset{\text{New}}{w_0[t+1]} = \overset{\text{Old}}{w_0[t]} - \overset{\text{Learning Rate}}{\alpha} \frac{\partial}{\partial w_0} \epsilon_{MSE}(\overset{\text{Old}}{w_0}, w_1)$$

■ Test set

- 모델을 평가(Test)하기 위한 데이터 set => 결정된 Weight로 모델 평가

MNIST Data

전체 데이터 set

비율은 일반적으로 6:4 or 7:3

모의고사 역할

Training set

진짜 시험 역할

Test set

Test set에는 Training set이 포함되면 안됨 (의미가 없기 때문)

0 Class
1 Class
⋮
총 10개의 클래스

이 비율은 Class를 의미

Class 비율이 7:3으로

Training Set은 전체 Data를 Class별로

Shuffle 후 Random하게 뽑음

Classification(분류) 모델에서의 평가



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

○ 오차율



- 모든 데이터 중 잘못 분류한 데이터의 비율

$$P_{err}(f; D) = \frac{1}{N} \sum_{n=0}^{N-1} I(f(x_n) \neq y_n) \quad \frac{\text{잘못한 개수}}{\text{총 데이터}}$$

○ 정확도

- 모든 데이터 중 성공적으로 분류한 데이터의 비율

$$P_{acc}(f; D) = \frac{1}{N} \sum_{n=0}^{N-1} I(f(x_n) = y_n) = 1 - P_{err}(f; D)$$



분류는 데이터를 서로 **구별**하는 것

회귀는 데이터에 대한 경향을 **예측**하는 것

Precision(정밀도) & Recall(재현율)



예시) 머신러닝 기반 코로나 검출 모델

표준!

Confusion Matrix

		모델의 예측 결과	
		양성 (Positive)	음성 (Negative)
데이터의 실제 결과	양성 (Positive)	진짜 양성 (TP, True Positive)	가짜 음성 (FN, False Negative)
	음성 (Negative)	가짜 양성 (FP, False Positive)	진짜 음성 (TN, True Negative)

전체 데이터의 수 $N = TP + FP + TN + FN$

• 정확도 = $\frac{TP + TN}{N}$

• 오차율 = $1 - \frac{TP + TN}{N} = \frac{FP + FN}{N}$

↑ 클래스 2개 : Binary Classification

↘ Diagonal 외에는 다 잘못 예측한거

- TP(True Positive): 실제 양성을 머신러닝 모델이 양성으로 판별
- FP(False Positive): 실제 음성을 머신러닝 모델이 양성으로 판별
- FN(False Negative): 실제 양성을 머신러닝 모델이 음성으로 판별
- TN(True Negative): 실제 음성을 머신러닝 모델이 음성으로 판별

Precision(정밀도) & Recall(재현율)



- $$Precision = \frac{TP}{TP+FP}$$

➤ 모델이 양성으로 분류한 것 중 실제 양성 비율

- $$Recall = \frac{TP}{TP+FN}$$

➤ 실제 양성 중 모델의 양성 판별 비율

		모델의 예측 결과	
		양성 (Positive)	음성 (Negative)
데이터의 실제 결과	양성 (Positive)	진짜 양성 (TP, True Positive)	가짜 음성 (FN, False Negative)
	음성 (Negative)	가짜 양성 (FP, False Positive)	진짜 음성 (TN, True Negative)

두 지표가 둘다 높은 모델이 일반적으로 좋은 모델 (항상은 아님)

Unbalanced Data

- 예시) 코로나 데이터 100 건에 대해서 실제 양성인 5명, 음성이 95명일 때,
정확도가 높다고 잘된 모델은 아닐 수 있음

		모델의 예측 결과	
		양성 (Positive)	음성 (Negative)
데이터의 실제 결과	양성 (Positive)	0	5
	음성 (Negative)	1	94

- Accuracy(정확도): 94 %
- Precision: 0 %
- Recall: 0 %

Precision(정밀도) & Recall(재현율)



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- 예시) 코로나 데이터 100 건에 대해서 실제 양성이 95명, 음성이 5명일 때,
1차적 문제: Data Unbalance(데이터 불균형)

		모델의 예측 결과	
		양성 (Positive)	음성 (Negative)
데이터의 실제 결과	양성 (Positive)	95	0
	음성 (Negative)	5	0

- Accuracy: 95 %

- Precision: 95 %

???

- Recall: 100 %



- Specificity(특이도) = $\frac{TN}{FP+TN}$ => 위의 예제에서 Specificity: 0 %

- FPR(False positive rate) = $1 - \text{Specificity} = 1 - \frac{TN}{FP+TN} = \frac{FP}{FP+TN}$

Recall 이 높으면서 FPR 이 낮은 모델 => Good 모델


ROC Curve



- Recall이 높으면서 FPR이 낮은 모델을 찾는 법

➢ FPR vs Recall 그래프, x축, x=1의 면적이 넓을 수록 좋다.

분류 기준 값(Threshold)을 변경하면서 Curve를 plot
=> Logistic Regression에서 자세히 설명




		모델의 예측 결과	
		양성 (Positive)	음성 (Negative)
데이터의 실제 결과	양성 (Positive)	진짜 양성 (TP, True Positive)	가짜 음성 (FN, False Negative)
	음성 (Negative)	가짜 양성 (FP, False Positive)	진짜 음성 (TN, True Negative)

모델 D는 어떤 모델을 의미하는 건가?

Multi-Class Classification



Confusion Matrix (혼동행렬)




■ 다중 분류(Multi-class Classification) 문제에서의 모델 평가

➤ Precision과 Recall의 조화평균

➤
$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

전체 class에 대한 precision과 recall은
각 class에 대한 평균값



둘 다 높아야 h(조화평균)가 크다

F1 Score 예제



- 아래 혼동행렬에 대해 F1 Score 를 구해보자

$$\text{Precision} = \frac{TP}{TP+FP}, \text{Recall} = \frac{TP}{TP+FN}$$

predictions (output) →

	A	B	C	D
A	9	1	0	0
B	1	15	3	1
C	5	0	24	1
D	0	4	1	15

actual class (input) ↓

A class에 대한 TP = 9

A class에 대한 FP = 6

A class에 대한 Precision = 9/15

A class에 대한 Recall = 9/10

predictions (output) →

	A	B	C	D
A	9	1	0	0
B	1	15	3	1
C	5	0	24	1
D	0	4	1	15

actual class (input) ↓

A class에 대한 FN = 1


[복습] 기저함수 수(K)에 따른 결과 비교




지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

$$\hat{y} = 27.02 \underbrace{e^{-\frac{1}{2}\left(\frac{x-5}{5}\right)^2}}_{\phi_0(x)} + 3.46 \underbrace{e^{-\frac{1}{2}\left(\frac{x-10}{5}\right)^2}}_{\phi_1(x)} + 39.08 \underbrace{e^{-\frac{1}{2}\left(\frac{x-15}{5}\right)^2}}_{\phi_2(x)} - 23.82 \quad w = \begin{bmatrix} 27.02 \\ 3.46 \\ 39.08 \\ -23.82 \end{bmatrix}$$

$K = 3$



$K = 8$



MSE가 작다고 무조건 좋은 것일까?

■ 훈련 오차 vs. 일반화 오차

- 일반화 오차를 줄이는 것이 궁극적 목표임
- 그러나, 훈련 과정에서는 훈련 데이터만 경험할 수 있음
 - 실전 데이터를 경험할 수 없음
- 훈련 데이터의 학습을 통해 일반화 성능을 최대화해야 함
 - 머신러닝의 근본적 문제의 원인
- 두 가지 중 하나의 문제에 빠질 위험이 있음
 - 학습 능력이 부족하거나 => 과소적합의 문제 (underfitting)
 - 학습이 과하거나... => 과적합의 문제 (overfitting)

편향되어있거나


ex) 사람을 구별하는 machine 에 백인 사진으로 Training

→ 흑인, 동양인 넣으면 인식 못함

Underfitting vs Overfitting



- 다음 중 바람직한(일반화된) fitting line은?




Underfitting (과소적합)



- 학습능력이 부족한 경우

- 추의 무게와 용수철의 관계

- 최적 매개변수를 찾았지만, 모델 자체의 학습 능력이 부족함



- 이 모델에 따르면, 추의 무게가 무한하면 길이도 무한해짐

Underfitting 이 일어난 원인은 무엇인가?

- 이미지 분류 문제



훈련 데이터



새로운 데이터

학습기 예측 결과

→ 이것은 나뭇잎이다.


이유

→ 초록색 둥근 모양은 나뭇잎이다.

Overfitting (과대적합)




- 학습이 과도한 경우
 - 추의 무게와 용수철의 관계
 - 훈련 데이터를 완벽하게 학습한 모델



- 이 모델은 훈련 데이터만 정확하게 맞춤
- 훈련 오차는 최소이나, 일반화 오차는 커짐

Overfitting 이 일어난 원인은 무엇인가?

- 이미지 분류 문제



- 학습기 예측 결과
→ 이것은 나뭇잎이 아니다.
이유
→ 나뭇잎의 테두리는 톱니 모양이다.

훈련 데이터 새로운 데이터


Training 데이터 증가




지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- Training을 위한 데이터를 늘리면 일반화에 유리


✓ 기저함수 모델 12개
12차 $\Rightarrow w_0 + w_1x + w_2x^2 + \dots + w_{12}x^{12}$ 12차



(a) 훈련집합의 크기 = 20



(b) 훈련집합의 크기 = 40




(c) 훈련집합의 크기 = 60

데이터를 더 이상 수집하기 힘든 경우?

Data Augmentation




- MNIST에 Affine Transformation(이동, 회전, 크기)을 적용



Training Set에는 넣어도 되지만

Test Set에는 X


- 비선형 변환




모델을 어떻게 검증하며 학습할 것인가?



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.





Hold-out Validation



update에 사용


Training set을 한번 더 나누자
모델 검증을 위해!!



or Test Set = Validation Set
이 방법도 있음

현재 모델이 잘 update 되고 있는지
(중간 평가 역할) 확인 (update 자체에는 사용x)

$$f_{cost_A} < f_{cost_B}$$




바뀌어마다 weight 다 저장 → 나중에 가장 높은 정확도를 가진 weight 시점에 스톱

Training set vs Validation set vs Test set



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- **Original Set**
 - 머신러닝에 활용되는 전체 데이터 집합
- **Training Set**
 - 머신러닝 모델 학습(Weight Update)에 사용되는 데이터 집합
- **Validation Set**
 - 모델 학습 도중 모델을 중간평가(검증) 하기위한 데이터 집합
 - Weight update에는 활용되지 않음 *Overfitting이 언제 되는지 확인하는 데 사용됨*
- **Test Set**
 - 최종적으로 학습된 모델의 성능을 평가하기 위한 데이터 집합




각 데이터 set 간에 공통된 데이터는 존재하지 않아야 함 공통되면 노의미 21

K-fold Cross Validation $\times$ 안함



- 장점: 모델 학습을 위한 데이터 수를 확보할 수 있다.
- 단점: k 값에 따라 연산량이 많아진다. **Validation set으로 나누지 않아도 된다.**




❖ Leave one out cross validation(LOOCV): K 와 데이터 수가 같을 경우를 지칭

그 외 방법 (Dropout)




■ Dropout 기법



- 입력층과 은닉층의 노드 중 일정 비율을 임의로 선택하여 제거
- 남은 부분 신경망을 학습
- 많은 부분 신경망을 만들고, 예측 단계에서 앙상블 결합하는 기법으로 볼 수 있음



(a) 원래 신경망(4-4-4-2 구조)



(b) 드롭아웃된 3개의 신경망 예시



신경망에서 다시 설명할 예정