

여기가 가장 중요함

# Chap.4 인공 신경망 (Artificial Neural Network)

---

방 수 식 교수  
(bang@tukorea.ac.kr)


한국공학대학교 전자공학부

2023년도 2학기  
머신러닝의 이해


# 신경망 (Neural Network)



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.



Neuron



Neural Network in Brain

- 축색종단에서의 도파민(신경전달물질) 분비 여부
  - 전달된 신호의 강도에 따라 결정됨
  - 즉, 신호의 강도가 임계값을 넘으면 도파민 분비 → **활성화**
  - 신호의 강도가 임계값을 넘지 않으면 도파민 분비되지 않음 → **비활성화**


## ■ Neuron의 핵심 기능

### ○ 전파(Propagation) 기능

- 신호(도파민)를 받아 전달


### ○ 활성화(Activation) 기능

- 신호의 강도에 따라 신호 활성화 유무를 결정



## ■ Artificial Neuron(인공 뉴런)



- Neuron 세포를 모방하여 설계




# Artificial Neuron



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.



- 전파(Propagation) 기능
  - 입력과 Weights 들의 선형 조합을 전파
- 활성화(Activation) 기능
  - 선형 조합의 크기에 따라 다음 뉴런에 전달할 지 여부를 결정






# Logistic Regression과의 비교




## Artificial Neuron의 관점에서의 Logistic Regression

- 일반적인 Logistic Regression 모델




- Sigmoid 함수를 Activation Function으로 사용하는 Artificial Neuron과 동일한 구조




## ■ 퍼셉트론 (Perceptron)

- 입력층과 출력층 만으로 구성된 Single-Layer Neural Network
  - Neural Network의 기본 구성 단위
  - Binary Classification 시스템 (출력이 0 or 1)
  - (예) 입력 속성이 2개인 Perceptron



## ■ 퍼셉트론 (Perceptron)

- Node: 해당 Node로 들어온 모든 값을 더한 다음 **Activation Function**을 통과시킨 값을 출력
  - Input node의 Activation Function:  $f(x)=x$  (별도표기하지 않음)
- 화살표: 화살표 위에 적힌 weight만큼 곱 연산을 수행
  - 별도 표기가 없는 화살표의 weight는 1




분류해야하는 Class가 3개 이상이라면? → 구간을 더 잘게 나누면 됨  
ex) 0 ~ 1/3, 1/3 ~ 2/3, 2/3 ~ 1  
but 너무 자세한 단점 2/3 ~ 1

# Multi-Class Classification in Single Layer



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.



## One-Hot Encoding (범주형 Class의 이진화)

- 확률론적 접근 + 기계가 인식 가능한 숫자

✓ Binary Class: 음성 or 양성 => 0 or 1

✓ Multi-Class: 개 or 고양이 or 말 => 100 or 010 or 001

(y<sub>0</sub>, y<sub>1</sub>, y<sub>2</sub>)

① Class 수 확인

② Class 수만큼 0으로 채움

③ 1 넣기

④ 100 (A) = t<sub>1</sub>

010 (B) = t<sub>2</sub> => Class

3개 클래스의




One Hot Encoding

# Single Layer Neural Network의 한계



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.


- Single Layer Neural Network의 한계
  - 단층 신경망은 로지스틱 회귀의 성능과 동일
  - 속성 공간의 “선형 분할”만 가능
    - Decision Boundary가 선형적



# Multi-Layer Neural Network



- Two-Layer Neural Network  $\hat{y}_0: (x_0 v_{00} + \dots$  를 Sigmoid에 넣은 것,  $\dots$  를 Sigmoid에 넣은 것




- Input layer (입력층) Neural Network 장점: 비선형적 결과 도출 가능
  - 2 Input: 일반노드 2개 + 더미노드 1개 <= 데이터의 Input 속성 수에 의해 결정
- Hidden Layer (은닉층)
  - 일반노드 2개 + 더미노드 1개 <= 모델 설계자가 결정 (Hyper-parameter)
- Output Layer (출력층)
  - 3-Class: 일반노드 3개 <= 데이터의 Output class 수에 의해 결정

# Multi-Layer Neural Network



## Node 별 입출력 계산

$v_{01}$  : 0번째 노드 → 1번째 노드의 weight



### Hidden Layer 입출력 관계

$$\alpha_0 = v_{00}x_0 + v_{10}x_1 + v_{20}x_2$$

$$\alpha_1 = v_{01}x_0 + v_{11}x_1 + v_{21}x_2$$

$$b_0 = f_1(\alpha_0)$$

$$b_1 = f_1(\alpha_1) \quad b_2 = 1$$

$x_2 = 1$

### Output Layer 입출력

$$\beta_0 = w_{00}b_0 + w_{10}b_1 + w_{20}b_2$$

$$\beta_1 = w_{01}b_0 + w_{11}b_1 + w_{21}b_2$$

$$\beta_2 = w_{02}b_0 + w_{12}b_1 + w_{22}b_2$$

$$\hat{y}_0 = f_2(\beta_0)$$

$$\hat{y}_1 = f_2(\beta_1)$$

$$\hat{y}_2 = f_2(\beta_2)$$

Input ↔ Hidden 사이의 weight :  $v$

$$\text{Input} \cdot \vec{v} = \alpha$$

$$\text{Sigmoid}(\alpha) = b$$

$$b \cdot \vec{w} = \beta$$

$$\text{Sigmoid}(\beta) = y$$

## Artificial Neural Network(ANN) 모델의 학습 목표

$\hat{y}_0 \approx y_0, \hat{y}_1 \approx y_1, \hat{y}_2 \approx y_2$ 를 만족하는 최적 매개변수를 찾는다.

$$\bigcirc \xrightarrow{n} \bigcirc : V_{nk} \quad \oplus \text{극제표준: } \bigcirc \xrightarrow{n} \bigcirc : V_{kn}$$



# Two-Layer Neural Network의 일반화



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## 2-Input, 3-Class with 2-Hidden node

*Dummy node는 일반적으로 카운팅하지 않음.*

### Hidden Layer 입출력

$x_2 = 1$

$$\left. \begin{aligned} \alpha_0 &= v_{00}x_0 + v_{10}x_1 + v_{20}x_2 \\ \alpha_1 &= v_{01}x_0 + v_{11}x_1 + v_{21}x_2 \end{aligned} \right\}$$

$$b_0 = f_1(\alpha_0) \quad \vec{b} = f(\vec{\alpha})$$

$$b_1 = f_1(\alpha_1)$$

$$b_2 = 1$$

### Output Layer 입출력

$$\beta_0 = w_{00}b_0 + w_{10}b_1 + w_{20}b_2$$

$$\beta_1 = w_{01}b_0 + w_{11}b_1 + w_{21}b_2$$


$$\beta_2 = w_{02}b_0 + w_{12}b_1 + w_{22}b_2$$

$$\hat{y}_0 = f_2(\beta_0)$$

$$\hat{y}_1 = f_2(\beta_1)$$

$$\hat{y}_2 = f_2(\beta_2)$$

## M-Input, Q-Class with L-Hidden node



$M$ : 특징수

$L$ : 은닉노드수

$Q$ : 클래스수

$L$ 개

$$\begin{bmatrix} \alpha_0 \\ \alpha_1 \end{bmatrix} = \begin{bmatrix} v_{00} & \dots \\ v_{01} & \dots \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ x_2 \end{bmatrix}$$

$\Rightarrow \vec{v} \cdot \vec{x} = \vec{\alpha}$

$\sqrt{L \text{ by } M+1}$

$M+1$ 개



# Two-Layer Neural Network의 일반화



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## 2-Input, 3-Class with 2-Hidden node

*Dummy node는 일반적으로 카운팅하지 않음.*

### Hidden Layer 입출력 $x_2 = 1$

$$\alpha_0 = v_{00}x_0 + v_{10}x_1 + v_{20}x_2$$

$$\alpha_1 = v_{01}x_0 + v_{11}x_1 + v_{21}x_2$$

$$b_0 = f_1(\alpha_0)$$

$$b_1 = f_1(\alpha_1)$$

$$b_2 = 1$$

### Output Layer 입출력

$$\beta_0 = w_{00}b_0 + w_{10}b_1 + w_{20}b_2$$

$$\beta_1 = w_{01}b_0 + w_{11}b_1 + w_{21}b_2$$

$$\beta_2 = w_{02}b_0 + w_{12}b_1 + w_{22}b_2$$

$$\hat{y}_0 = f_2(\beta_0)$$

$$\hat{y}_1 = f_2(\beta_1)$$

$$\hat{y}_2 = f_2(\beta_2)$$

## M-Input, Q-Class with L-Hidden node

### Hidden Layer 입출력 $x_M = 1$

$$\alpha_l = v_{0l}x_0 + v_{1l}x_1 + \cdots + v_{Ml}x_M = \sum_{m=0}^M v_{ml}x_m$$
$$l = 0, 1, \dots, L-1$$

$$b_l = f_1(\alpha_l) = f_1\left(\sum_{m=0}^M v_{ml}x_m\right) \quad b_L = 1$$

### Output Layer 입출력

$$\beta_q = w_{0q}b_0 + w_{1q}b_1 + \cdots + w_{Lq}b_L$$

$$= \sum_{l=0}^L w_{lq}b_l, \quad q = 0, 1, \dots, Q-1$$

$$\hat{y}_q = f_2(\beta_q) = f_2\left(\sum_{l=0}^L w_{lq}b_l\right)$$

# Two-Layer Neural Network의 일반화



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

- 1개의 데이터에 대해:  $M$ -Input,  $Q$ -Class with  $L$ -Hidden node 연산의 행렬화

## Hidden Layer 입력

$$\alpha_l = v_{0l}x_0 + v_{1l}x_1 + \cdots + v_{Ml}x_M = \sum_{m=0}^M v_{ml}x_m$$

$l = 0, 1, \dots, L-1$

$x_M = 1$

## Hidden Layer 출력

$$b_l = f_1(\alpha_l) = f_1\left(\sum_{m=0}^M v_{ml}x_m\right) \quad b_L = 1$$

$$\begin{aligned} b_0 &= f_1(\alpha_0) \\ b_1 &= f_1(\alpha_1) \\ &\vdots \\ b_l &= f_1(\alpha_l) \\ &\vdots \\ b_{L'} &= f_1(\alpha_{L'}) \\ b_L &= 1 \end{aligned} \quad \Rightarrow \quad \mathbf{b} = \begin{bmatrix} f_1(\alpha_0) \\ f_1(\alpha_1) \\ \vdots \\ f_1(\alpha_l) \\ \vdots \\ f_1(\alpha_{L'}) \\ 1 \end{bmatrix}$$

$(L+1 \text{ by } 1)$

$L' = L - 1$  일 때,

$$\begin{aligned} \alpha_0 &= v_{00}x_0 + v_{10}x_1 + \cdots + v_{M0}x_M \\ \alpha_1 &= v_{01}x_0 + v_{11}x_1 + \cdots + v_{M1}x_M \\ &\vdots \\ \alpha_l &= v_{0l}x_0 + v_{1l}x_1 + \cdots + v_{Ml}x_M \\ &\vdots \\ \alpha_{L'} &= v_{0L'}x_0 + v_{1L'}x_1 + \cdots + v_{ML'}x_M \end{aligned}$$

$L$ 개



$\alpha$  ( $L$  by  $1$ )

$v$  ( $L$  by  $M+1$ )

$$\begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_l \\ \vdots \\ \alpha_{L'} \end{bmatrix} = \begin{bmatrix} v_{00} & v_{10} & \cdots & v_{M0} \\ v_{01} & v_{11} & \cdots & v_{M1} \\ \vdots & \vdots & \ddots & \vdots \\ v_{0l} & v_{1l} & \ddots & v_{Ml} \\ \vdots & \vdots & \ddots & \vdots \\ v_{0L'} & v_{1L'} & \cdots & v_{ML'} \end{bmatrix} \begin{bmatrix} x_0 \\ x_1 \\ \vdots \\ x_M \end{bmatrix}$$

$M+1$ 개  
(dummy)



$$\alpha = vx$$

# Two-Layer Neural Network의 일반화



- 1개의 데이터에 대해:  $M$ -Input,  $Q$ -Class with  $L$ -Hidden node 연산의 행렬화

Output Layer 입출력

$$\beta_q = w_{0q}b_0 + w_{1q}b_1 + \cdots + w_{lq}b_l + w_{Lq}b_L$$

$$= \sum_{l=0}^L w_{lq}b_l, \quad q = 0, 1, \dots, Q-1$$

$$\hat{y}_q = f_2(\beta_q) = f_2\left(\sum_{l=0}^L w_{lq}b_l\right)$$

$$\vec{x} \vec{v} = \vec{z}$$

$$\Downarrow$$

$$f(\vec{z}) = \vec{b}$$

$$\Downarrow$$

$$\vec{b} \vec{w} = \vec{\beta}$$

$Q' = Q - 1$  일 때,

$\beta$  ( $Q$  by 1)

$w$  ( $Q$  by  $L+1$ )

$b$  ( $L+1$  by 1)

$$\begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_q \\ \vdots \\ \beta_{Q'} \end{bmatrix} = \begin{bmatrix} w_{00} & w_{10} & \cdots & w_{L0} \\ w_{01} & w_{11} & \cdots & w_{L1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{0q} & w_{1q} & \ddots & w_{Lq} \\ \vdots & \vdots & \ddots & \vdots \\ w_{0Q'} & w_{1Q'} & \cdots & w_{LQ'} \end{bmatrix} \begin{bmatrix} f_1(\alpha_0) \\ f_1(\alpha_1) \\ \vdots \\ f_1(\alpha_l) \\ \vdots \\ f_1(\alpha_{L'}) \\ 1 \end{bmatrix}$$

$\Downarrow$   
 $\beta = wb$

( $Q$  by 1)

$$\hat{y} = \begin{bmatrix} \hat{y}_0 \\ \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_q \\ \vdots \\ \hat{y}_{Q-1} \end{bmatrix} = \begin{bmatrix} f_2(\beta_0) \\ f_2(\beta_1) \\ f_2(\beta_2) \\ \vdots \\ f_2(\beta_l) \\ \vdots \\ f_2(\beta_{Q-1}) \end{bmatrix}$$

# Two-Layer Neural Network의 일반화



## ■ N개의 데이터

| 데이터<br>번호 | 입력                                                     | 출력                                                     |
|-----------|--------------------------------------------------------|--------------------------------------------------------|
|           | $x_0, \dots, x_m, \dots, x_{M-1}$                      | $y_0, \dots, y_q, \dots, y_{Q-1}$                      |
| 0         | $x_{00}, \dots, x_{m0}, \dots, x_{(M-1)0}$             | $y_{00}, \dots, y_{q0}, \dots, y_{(Q-1)0}$             |
| $\vdots$  | $\vdots$                                               | $\vdots$                                               |
| $n$       | $x_{0n}, \dots, x_{mn}, \dots, x_{(M-1)n}$             | $y_{0n}, \dots, y_{qn}, \dots, y_{(Q-1)n}$             |
| $\vdots$  | $\vdots$                                               | $\vdots$                                               |
| $N-1$     | $x_{0(N-1)}, \dots, x_{m(N-1)}, \dots, x_{(M-1)(N-1)}$ | $y_{0(N-1)}, \dots, y_{q(N-1)}, \dots, y_{(Q-1)(N-1)}$ |

❖ n번째 데이터에 대해서 (n은 0부터 N-1까지의 정수)

$\alpha$  (L by 1)

$v$  (L by M+1)

$\rightarrow$  weight = machine이라 볼 수 있는데,

$$\begin{bmatrix} \alpha_{0n} \\ \alpha_{1n} \\ \vdots \\ \alpha_{ln} \\ \vdots \\ \alpha_{L'n} \end{bmatrix} = \begin{bmatrix} v_{00} & v_{10} & \dots & v_{M0} \\ v_{01} & v_{11} & \dots & v_{M1} \\ \vdots & \vdots & \ddots & \vdots \\ v_{0l} & v_{1l} & \dots & v_{Ml} \\ \vdots & \vdots & \ddots & \vdots \\ v_{0L'} & v_{1L'} & \dots & v_{ML'} \end{bmatrix}$$

$x$  (M+1 by 1)

$$\begin{bmatrix} x_{0n} \\ x_{1n} \\ \vdots \\ x_{Mn} \end{bmatrix}$$

데이터가 달라지는 게

Machine이 달라지는 게

아니기 때문에

weight에는 n이 반영됨

weight는 update 할 때만 바뀐다

❖ Training 관점: n-1 번째 데이터로부터 업데이트 된 weights

## ▪ Error Backpropagation (오차 역전파) 알고리즘

- 경사하강법 기반  $\rightarrow$  지금까지의 경사하강법은 좀 다름
- 개별 훈련 데이터에 대해서 알고리즘 적용
- 설정한 Cost Function로부터 모델의 예측값과 실측값 간의 Error 값으로부터 역으로 전파되면서 Weight를 업데이트함

✓ 본 강의자료에서는 Activation Function은 Sigmoid, Cost Function은 MSE 기준으로 설명

기존의 Gradient Descent (경사하강법):  $W_{new} = W_{old} - \alpha \frac{\partial f_{cost}}{\partial W_{old}}$   
batch size: N

뉴 - GD: SGD:  $W_{new} = W_{old} - \alpha \frac{\partial f_{cost}}{\partial W_{old}}$   
batch size: 1

Stochastic

ex) 데이터 100개  
GD: Update 1번 (모든 데이터의 평균으로 업데이트)  
SGD: Update 100번 (각 데이터마다 업데이트)

이래서 나온 개념  
Batch Size  
c) 평균할 데이터 개수  
2^n 개로 잡는게 좋음  
GPU의 연산 유닛이 2^n 개이기 때문

모든 데이터의 평균


데이터 1개만

# Error Back-Propagation 알고리즘




지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## Step 1) Forward-propagation (순전파)를 통한 예측값 도출



활성화함수  $f_1$ 과  $f_2$ 는 Sigmoid 함수로 선택하였다고 가정




- 예측값 계산 과정: Forward-propagation (순전파)
- Weight 업데이트 과정: Back-propagation(역전파)

# Error Back-Propagation 알고리즘



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

Step 2) 경사하강법을 통한 Weight 업데이트 (Weight 개별적 업데이트)



❖ Cost Function을 MSE로 설정하였을 때, n번째 데이터에 대해서

목적: [이 둘의 차이]를 최소화

$$v_{ml} \leftarrow v_{ml} - \eta \frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n)$$

$$w_{lg} \leftarrow w_{lg} - \eta \frac{\partial}{\partial w_{lg}} \epsilon_{MSE}(n)$$

일단, 특정 weight에 대한 편미분 고려

$$\epsilon_{MSE}(n) = \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn})^2$$

[미분해야 하므로 정답값 대신 제공]  
 $\frac{1}{Q}$  값이라도 Learning Rate에서 조절가능




# Error Back-Propagation 알고리즘




지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## Step 2-1) 경사하강법에서의 도함수 계산



Forward-propagation 에  
사용한 weight (Old)

$$\begin{aligned} \text{New } v_{ml} &\leftarrow \text{Old } v_{ml} - \eta \frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) \\ \text{New } w_{lq} &\leftarrow \text{Old } w_{lq} - \eta \frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) \end{aligned}$$



(함성값 부분)

$$\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} \cdot \frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} \cdot \frac{\partial \beta_{qn}}{\partial w_{lq}}$$

Sigmoid 미분  $\hat{y}(1-\hat{y})$

$$\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}}$$



# Error Back-Propagation 알고리즘



- $\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n)$  구하기

$$\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) = \underbrace{\frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}}}_{1 \text{ 항}} \cdot \underbrace{\frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}}}_{2 \text{ 항}} \cdot \underbrace{\frac{\partial \beta_{qn}}{\partial w_{lq}}}_{3 \text{ 항}}$$

우변 1항

$$\begin{aligned} \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} &= \frac{\partial}{\partial \hat{y}_{qn}} \sum_{j=0}^{Q-1} (\hat{y}_{jn} - y_{jn})^2 \\ &= \frac{\partial}{\partial \hat{y}_{qn}} \left\{ (\hat{y}_{0n} - y_{0n})^2 + \cdots + (\hat{y}_{qn} - y_{qn})^2 + \cdots + (\hat{y}_{(Q-1)n} - y_{(Q-1)n})^2 \right\} \\ &= 2(\hat{y}_{qn} - y_{qn}) \end{aligned}$$

우변 2항

$$\frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} = \frac{\partial}{\partial \beta_{qn}} f(\beta_{qn}) = f(\beta_{qn}) (1 - f(\beta_{qn})) = \hat{y}_{qn} (1 - \hat{y}_{qn})$$

(참고) 시그모이드 함수의 미분

$$f'(x) = f(x)(1 - f(x))$$

# Error Back-Propagation 알고리즘



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

- $\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n)$  구하기

우변 3항

$$\frac{\partial}{\partial w_{lq}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} \cdot \frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} \cdot \frac{\partial \beta_{qn}}{\partial w_{lq}}$$


$$\frac{\partial \beta_{qn}}{\partial w_{lq}} = \frac{\partial}{\partial w_{lq}} \sum_{j=0}^L w_{jq} b_{jn} = \frac{\partial}{\partial w_{lq}} (w_{0q} b_{0n} + \dots + w_{lq} b_{ln} + \dots + w_{Lq} b_{Ln}) = b_{ln}$$

최종


$$\frac{\partial \epsilon_{MSE}(n)}{\partial w_{lq}} = \frac{\partial \epsilon_{MSE}(n)}{\partial \hat{y}_{qn}} \cdot \frac{\partial \hat{y}_{qn}}{\partial \beta_{qn}} \cdot \frac{\partial \beta_{qn}}{\partial w_{lq}}$$

$$= 2(\hat{y}_{qn} - y_{qn}) \hat{y}_{qn} (1 - \hat{y}_{qn}) b_{ln}$$

$$= \delta_{qn} b_{ln}$$



$\delta_{qn}$ :  $q$ 번째 output node에 대해,  
 $2 * \text{output} * (\text{output} - \text{target}) * (1 - \text{output})$



# Error Back-Propagation 알고리즘



- $\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n)$  구하기

$$\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}}$$

우변 1항

$$\frac{\partial \epsilon_{MSE}}{\partial \hat{y}} \times \frac{\partial \hat{y}}{\partial \beta} \times \frac{\partial \beta}{\partial b}$$

Linear Combination

Sigmoid 미분

$$\frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} = \frac{\partial}{\partial b_{ln}} \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn})^2 = 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \frac{\partial \hat{y}_{qn}}{\partial b_{ln}}$$

$$= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \frac{\partial}{\partial b_{ln}} f \left( \sum_{j=0}^L w_{jq} b_{jn} \right)$$

$$= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \frac{\partial}{\partial b_{ln}} f(w_{0q} b_{0n} + \dots + w_{lq} b_{ln} + \dots + w_{Lq} b_{Ln})$$


$$= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) f \left( \sum_{j=0}^L w_{jq} b_{jn} \right) \left( 1 - f \left( \sum_{j=0}^L w_{jq} b_{jn} \right) \right) w_{lq}$$

$$= 2 \sum_{q=0}^{Q-1} (\hat{y}_{qn} - y_{qn}) \hat{y}_{qn} (1 - \hat{y}_{qn}) w_{lq}$$

$$= \sum_{q=0}^{Q-1} \delta_{qn} w_{lq}$$

$l$  번째 Hidden Node와 연결된 weight들과 Output Node를 고려하게 됨.

→



✓는 모든 노드에 영향을 받아서  
△를 붙여야됨

# Error Back-Propagation 알고리즘



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

- $\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n)$  구하기

우변 2항

$$\frac{\partial}{\partial v_{ml}} \epsilon_{MSE}(n) = \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}}$$

$$\frac{\partial b_{ln}}{\partial \alpha_{ln}} = \frac{\partial}{\partial \alpha_{ln}} f(\alpha_{ln}) = f(\alpha_{ln})(1 - f(\alpha_{ln})) = b_{ln}(1 - b_{ln})$$

Sigmoid 미분


우변 3항

$$\frac{\partial \alpha_{ln}}{\partial v_{ml}} = \frac{\partial}{\partial v_{ml}} \sum_{j=0}^M v_{jl} x_{jn} = \frac{\partial}{\partial v_{ml}} (\cancel{v_{0l} x_{0n}} + \dots + v_{ml} x_{mn} + \dots + \cancel{v_{Ml} x_{Mn}}) = x_{mn}$$

(편미분이라)

최종


$$\begin{aligned} \frac{\partial \epsilon_{MSE}(n)}{\partial v_{ml}} &= \frac{\partial \epsilon_{MSE}(n)}{\partial b_{ln}} \cdot \frac{\partial b_{ln}}{\partial \alpha_{ln}} \cdot \frac{\partial \alpha_{ln}}{\partial v_{ml}} \\ &= \sum_{q=0}^{Q-1} \delta_{qn} w_{lq} b_{ln}(1 - b_{ln}) x_{mn} \end{aligned}$$



- $v_{ml}$  통과 전 입력값  $\Rightarrow x_{mn}$
- $v_{ml}$  통과 후 지나게 되는 모든 Node  $\Rightarrow$  1번째 Hidden node, 모든 Output Node

## ■ 전체 알고리즘 적용 순서

- 1) 신경망 모델 설계 (Hidden Layer 수, Node 수, 활성화 함수, Learning Rate 등)
- 2) 설계된 모델에 따른 Weight Matrix 생성 및 초기화 (랜덤으로 Weight 넣고 Forward Propagation)  
Weight는 음수 가능
- # 3) N개의 훈련 데이터 Shuffle
- 4) 0부터 N-1번째 데이터에 대해 순차적으로 오차 역전파 알고리즘 적용 (1 epoch)
  - for n번째 데이터 모든 데이터를 다 하면 1 epoch
    - (순전파) n-1에서 업데이트 된 Weight로부터 예측값  $\hat{y}_{qn}$  계산
    - (역전파) 실제값(Target)과 예측값(Output) 간의 오차로부터 Weight  
~~× 업데이트  $\Rightarrow$  주의사항: Input layer에 가까운 weight부터 업데이트~~
- 5) 업데이트 된 weight로부터 accuracy 계산
- 6) 사용자가 입력한 epoch 수 만큼 3~4) 반복



# Two-Layer Neural Network 적용 예시




지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## • 데이터

### ○ 2입력 3클래스 분류 데이터

- 입력 속성: 출석률, 시험성적
- 출력 속성: 학점 (A, B, C)

신경망 손실 함수는 반드시 나옴



☆ 손실 함수: 초기 weight 후  
F.P 후 weight 후 weight 변화  
+ Confusion Matrix까지

| 데이터<br>번호 | 입력  |      | 출력 |
|-----------|-----|------|----|
|           | 출석률 | 시험성적 | 학점 |
| 0         | 76  | 98   | A  |
| 1         | 65  | 94   | A  |
| 2         | 80  | 86   | A  |
| 3         | 89  | 74   | A  |
| 4         | 55  | 77   | A  |
| 5         | 30  | 79   | B  |
| 6         | 39  | 64   | B  |
| 7         | 38  | 63   | B  |
| 8         | 45  | 49   | B  |
| 9         | 80  | 42   | B  |
| 10        | 68  | 7    | C  |
| 11        | 64  | 8    | C  |
| 12        | 21  | 26   | C  |
| 13        | 15  | 14   | C  |
| 14        | 11  | 12   | C  |



One-Hot Encoding

| 데이터<br>번호 | 입력  |      | 출력    |       |       |
|-----------|-----|------|-------|-------|-------|
|           | 출석률 | 시험성적 | $y_0$ | $y_1$ | $y_2$ |
| 0         | 76  | 98   | 1     | 0     | 0     |
| 1         | 65  | 94   | 1     | 0     | 0     |
| 2         | 80  | 86   | 1     | 0     | 0     |
| 3         | 89  | 74   | 1     | 0     | 0     |
| 4         | 55  | 77   | 1     | 0     | 0     |
| 5         | 30  | 79   | 0     | 1     | 0     |
| 6         | 39  | 64   | 0     | 1     | 0     |
| 7         | 38  | 63   | 0     | 1     | 0     |
| 8         | 45  | 49   | 0     | 1     | 0     |
| 9         | 80  | 42   | 0     | 1     | 0     |
| 10        | 68  | 7    | 0     | 0     | 1     |
| 11        | 64  | 8    | 0     | 0     | 1     |
| 12        | 21  | 26   | 0     | 0     | 1     |
| 13        | 15  | 14   | 0     | 0     | 1     |
| 14        | 11  | 12   | 0     | 0     | 1     |





# Two-Layer Neural Network 적용 예시



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## ■ 학습 성공 시,



Confusion Matrix

|              | dolphin       | fish          | noise        |               |
|--------------|---------------|---------------|--------------|---------------|
| dolphin      | 128<br>38.6%  | 0<br>0.0%     | 0<br>0.0%    | 100%<br>0.0%  |
| fish         | 4<br>1.2%     | 111<br>33.4%  | 0<br>0.0%    | 96.5%<br>3.5% |
| noise        | 4<br>1.2%     | 2<br>0.6%     | 83<br>25.0%  | 93.3%<br>6.7% |
|              | 94.1%<br>5.9% | 98.2%<br>1.8% | 100%<br>0.0% | 97.0%<br>3.0% |
| Output Class | dolphin       | fish          | noise        | Target Class  |

Confusion Matrix

|            | anger | happiness | fear  | sadness | neutral |
|------------|-------|-----------|-------|---------|---------|
| anger      | 0.81  | 0.054     | 0.12  | 0       | 0.014   |
| happiness  | 0.11  | 0.7       | 0.019 | 0       | 0.17    |
| fear       | 0.025 | 0.062     | 0.8   | 0       | 0.11    |
| sadness    | 0     | 0         | 0.033 | 0.9     | 0.066   |
| neutral    | 0.02  | 0.07      | 0.05  | 0.01    | 0.85    |
| True label | anger | happiness | fear  | sadness | neutral |

Predicted label

**Confusion Matrix로 나타내 보자**

acc ↑  
보통 이 그래프로 씬  
epoch

Confusion Matrix (모델 성능을 표현하는 가장 보편적 방법)





# Two-Layer Neural Network 적용 예시



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

- 학습 실패 시,



위의 결과를 Confusion Matrix로 나타내 보자

# Softmax Function 살짝만 하셈



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

## 다중 분류를 위한 Softmax Function


$$o_j = \frac{e^{s_j}}{\sum_{i=1,c} e^{s_i}} \rightarrow \frac{e^{\beta}}{\sum e^{\beta}} : \text{총 합이 1이어야 함}$$

$\hat{y}$ : sigmoid 통과한 값의 영셋

정확도 비교: 0, 1로 바꿔서 비교

## 동작 예시

- softmax는 max를 모방(출력 노드의 중간 계산 결과  $s_i^L$ 에서 최댓값은 더욱 활성화하고 작은 값은 억제 accuracy: 제발 크게 1로, 클래스를 맞췄는지 판별)
- 모두 더하면 1이 되어 확률 모방



$\hat{y}$   
로지스틱 시그모이드  
아로 업데이트

0.8808

max

0.0

softmax

아님아로

0.0

0.1131

| A | B | C |
|---|---|---|
| 1 | 0 | 0 |
| 0 | 1 | 0 |
| 0 | 0 | 1 |

0.7685

0.0

0.0508

$$\frac{e^4}{e^2 + e^{1.2} + e^4} \rightarrow 0.9820$$

1.0

0.8360

# Softmax Function



## ▪ Softmax를 출력함수로 사용할 때의 Cost Function

### • Cross-Entropy



❖ 이진분류 => 
$$\epsilon_{CEE} = -\frac{1}{N} \sum_{n=0}^{N-1} \{y_n \ln p_n + (1 - y_n) \ln(1 - p_n)\}$$

$$\{y_n \ln p_n + (1 - y_n) \ln(1 - p_n)\}$$

$$= \{y_{0,n} \ln p_{0,n} + (y_{1,n}) \ln(p_{1,n})\}$$


$$= \sum_{k=0}^1 y_{k,n} \ln p_{k,n} \Rightarrow \sum_{k=0}^{K-1} y_{k,n} \ln(p_{k,n})$$

$$\epsilon_{CEE} = -\frac{1}{N} \sum_{n=0}^{N-1} \sum_{k=0}^{K-1} y_{i,n} \ln(p_{i,n})$$



<https://www.youtube.com/watch?v=aircAruvnKk>

## Neural Networks





From the  
ground up

# Deep Learning으로의 확장



지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

$f(z)$ 가 0~1일때  
 $f(z)(1-f(z))$   
는 0~0.25  
→ Hidden Layer가  
많아지면  
애플  
업데이트할때 값이 너무 작아짐  
→ Gradient Vanishing



Node의 활성화 함수가 모두 동일하다고 했을 때,  
 $w1$ 을 update 하기 위해서는 활성화 함수의 도함수를 3번 곱한 값이 들어감.




# Deep Learning으로의 확장




지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.

Sigmoid 함수



Sigmoid의 도함수




**"Gradient Vanishing Problem"** →

도함수를 곱할수록 값이 작아져  
Weight Update가 잘 이뤄지지 않음.  
=> Hidden Layer가 많을수록 불리

Leaky ReLU  
애같은거도 있음

ReLU 함수

Gradient Vanishing 문제를  
해결하기 위해 제안된 활성화 함수  
ReLU




미분은 안되지만  
코드를 쳐보니까 잘됨

애는 선형이라  
그냥 Logistic

$$f(x) = \begin{cases} 0 & x < 0 \\ x & x \geq 0 \end{cases} \quad f(x) = \max(0, x)$$

dReLU(x)/dx



Hidden Layer가 많아도,  
즉, Neural Network가 Deep해져도  
Weight를 업데이트 할 수 있음

# Dropout (고급 머신러닝에서)




지능형 예측·진단 연구실  
Intelligent Prognostics & Diagnostics Lab.


## Dropout (드롭아웃)

- 신경망의 일부 Node를 랜덤으로 비활성화하며 훈련시키는 기법
- Regularization (Overfitting을 방지하기 위해 사용)

일반화 성능 ↑



(a) Standard Neural Net



(b) After applying dropout.


각 node가 존재할 확률  $p$

통상 알려진 default 입력층: 0.8  
은닉층: 0.5

출력층은?



## Dropout에서의 Training 단계



$l$ 번째 은닉층의  $j$ 번째 노드의 연산:

$$z_j^l = \tau_l(s_j^l)$$

$$\text{이때 } s_j^l = \mathbf{u}_j^l \mathbf{z}^{l-1}$$

$\Rightarrow$

드롭아웃 적용:

$$z_j^l = \tau_l(s_j^l)$$

$$\text{이때 } \begin{cases} \tilde{\mathbf{z}}^{l-1} = \mathbf{z}^{l-1} \odot \boldsymbol{\pi}^{l-1} \\ s_j^l = \mathbf{u}_j^l \tilde{\mathbf{z}}^{l-1} \end{cases}$$

Boolean 배열  $\boldsymbol{\pi}$ 에 노드 제거 여부를 표시

*Boolean 배열: 배열 내부에 True or False 만 존재*

# Dropout



## Dropout에서의 Test 단계

- 가중치에 생존 비율( $p$ )을 곱하여 전방 계산
- 학습 과정에서 가중치가 생존 비율( $p$ ) 만큼만 참여했기 때문

