

Chap.5 결정 트리 (Decision Tree)

방 수 식 교수
(bang@tukorea.ac.kr)




한국공학대학교 전자공학부

2023년도 2학기
머신러닝의 이해

결정 트리 (Decision Tree)



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.




NN 대비 DT의 장점과 단점은?

결정 트리 (Decision Tree)



■ 분류 트리 (Classification Tree) 예시





결정 트리 (Decision Tree)



용어 정리

- Split criterion: node를 분할하기 위한 기준
- Parent node: node before split
- Child node: node after split
- Root node: Parent node가 없는 node
- Leaf node: Child node가 없는 node



DT 구성



Tree 구성 과정 설명을 위한 데이터

속성

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	흔탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	진녹색	말림	흔탁	선명함	움푹 패임	단단함	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	예
5	연녹색	말림	흔탁	선명함	움푹 패임	단단함	예
6	청록색	약간 말림	흔탁	선명함	약간 패임	물렁함	예
7	진녹색	약간 말림	흔탁	약간 흐림	약간 패임	물렁함	예
8	진녹색	약간 말림	흔탁	선명함	약간 패임	단단함	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	아니오
12	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
13	청록색	약간 말림	흔탁	약간 흐림	움푹 패임	단단함	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	아니오
15	진녹색	약간 말림	흔탁	선명함	약간 패임	물렁함	아니오
16	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	아니오

데이터 출력 y

Data : 17개
Class : 2개
특징 : 6개


데이터 입력 x

(문자열 → 숫자로)
신경망: 청 : 3
진 : 2 (데이터)
연 : 1 (가공)
:
:
Hidden
색 0-
꼭 0-
소 0-
줄 0-
배 0-
감 0-
○ 수박
1: 예
0: 아니오

DT: 문자열 그대로 넣음

■ Step 1) 어떤 속성을 Root node로 선택할 것인가?

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	훈탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	지녹색	말림	호탁	서명함	오목 패임	다단함	예
⋮							



Root node 선정 기준
↓

■ 접근 방법

- 데이터 집합의 Complexity를 줄이는 방향으로 노드를 선택
- 즉, Complexity가 높은 속성부터 Partitioning(분할)하는 것이 유리

but 어떻게 Complexity를 결정할 것인가?

정보 엔트로피 (Information Entropy)



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- 정보 엔트로피 (Information entropy) ^(Complexity) 데이터가 복잡함 = 데이터가 풍부해져있음
 - 특정 데이터 집합이 갖는 정보의 양 (복잡도의 양)

$$Ent(D) = - \sum_{k=0}^{K-1} p_k \log_2 p_k$$

$\nearrow 0 \sim 1$ $\nearrow -\infty \sim 0$
 사건 $\underbrace{\log_2 p_k}_{\text{사건의 가치}}$

$Ent(D): \infty \sim 0$
 희소한 사건일수록 가치 높음

- p_k ($k = 0, 1, \dots, K - 1$)
 - 데이터 집합 D의 k번째 클래스에 해당하는 데이터의 비율
 - 집합 D의 데이터 개수를 $|D|$, k번째 클래스에 해당하는 데이터의 개수를 $|D_k|$ 라 하면, $p_k = \frac{|D_k|}{|D|}$
 - (예) 출력 속성 “잘 익은 수박”에 대한 관찰 데이터

n	잘 익은 수박
0	예 → 1
1	예
2	아니오 → 0
3	예
4	아니오

- 전체데이터는 총 5개
 - $D = \{0, 1, 2, 3, 4\}$
- 클래스는 총 2개 (아니오=0, 예=1), 즉 $K = 2$
- 각 클래스에 해당하는 데이터의 비율

→ ○ $p_0 = \frac{2}{5}, p_1 = \frac{3}{5}$

- 정보 엔트로피 (Information entropy)

- 엔트로피의 물리적 의미

- 일반적으로 엔트로피는 “복잡도” 또는 “정보량” 으로 해석됨
 - 데이터의 관점에서 복잡도와 정보량은 같은 개념
 - 복잡도가 높을수록 그 데이터에 들어있는 정보의 양도 많아짐
 - (예) 사슴벌레를 “성별”의 속성으로 관찰한 데이터
 - “성별”에 대한 클래스는 암컷=0, 수컷=1, 두 종류임. 즉 $K = 2$

↓ 엔트로피 더 높음 = 가치가 더 높음

[데이터 집합 1]

n	성별
0	암컷
1	수컷
2	수컷
3	수컷
4	수컷
5	수컷

[데이터 집합 2]

n	성별
0	암컷
1	수컷
2	암컷
3	수컷
4	수컷
5	암컷

정보 엔트로피 (Information Entropy)



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- (예) 사슴벌레를 “성별”의 속성으로 관찰한 데이터
 - “성별”에 대한 클래스는 암컷=0, 수컷=1, 두 종류임. 즉 $K = 2$

[데이터 집합 1] 암: 0
수: 1

n	성별
0	암컷
1	수컷
2	수컷
3	수컷
4	수컷
5	수컷

$$p_0 = \frac{1}{6}, p_1 = \frac{5}{6}$$

$$Ent(D) = -p_0 \log_2 p_0 - p_1 \log_2 p_1 = -\frac{1}{6} \log_2 \frac{1}{6} - \frac{5}{6} \log_2 \frac{5}{6} = 0.65$$

[데이터 집합 2]

n	성별
0	암컷
1	수컷
2	암컷
3	수컷
4	수컷
5	암컷

$$p_0 = \frac{3}{6}, p_1 = \frac{3}{6}$$

$$Ent(D) = -p_0 \log_2 p_0 - p_1 \log_2 p_1 = -\frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} = 1$$

정보 엔트로피 (Information Entropy)





지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- 특정 클래스 데이터가 갖는 정보의 양 (복잡도의 양)
 - (예) 클래스가 2개인 경우, 즉 $K = 2$

$$Ent(D) = - \sum_{k=0}^1 p_k \log_2 p_k = -p_0 \log_2 p_0 - p_1 \log_2 p_1$$

(Binary Classification
일때만)



다양한 데이터가
골고루 있어야 복잡하다.

각 클래스에 골고루
데이터가 있어야 정보가 많다.

“복잡도 = 정보량”

■ Step 1) 어떤 속성을 Root node로 선택할 것인가?

■ 접근 방법

- 데이터 집합의 Complexity를 줄이는 방향으로 노드를 선택해 분할
- 즉, Complexity가 높은 속성부터 분할하는 것이 유리


Root → Root's Child node 했을 때 가장 엔트로피가 높은 걸로 하느게 유리



- ✓ (정보량의 측면) 데이터 집합을 특정 속성으로 분할했을 때
 - **가장 많은 정보를 얻을 수 있는 속성**을 우선적으로 분할
- ✓ (복잡도의 측면) 데이터 집합을 특정 속성으로 분할했을 때
 - **복잡도를 가장 많이 줄일 수 있는 속성**을 우선적으로 분할

▪ Step 1) 어떤 속성을 Root node로 선택할 것인가?

- 데이터 집합 분할을 통해 얻은 **정보 이득 (Information Gain)**
 - 데이터 집합 D 를 속성 m 로 분할했을때 (속성 a 의 클래스는 K 개)
 - 얻을 수 있는 정보량
 - 줄일 수 있는 복잡도



$$Gain(D, m) = Ent(D) - \sum_{v=0}^{K-1} \frac{|D^k|}{|D|} Ent(D^k)$$

- 즉, 분할 전 엔트로피와 분할 후 엔트로피의 차이
 - 여러 집합으로 분할되므로 분할 후 전체 엔트로피는 평균값을 계산

▪ Step 1) 어떤 속성을 Root node로 선택할 것인가?

- (예) 데이터 집합 D 를 속성 “색깔”로 분할했을 때
(분할 후 엔트로피) 속성 “색깔”의 클래스는 3개, 즉 $K = 3$, 청록=0, 진녹=1, 연록=2

$$D^0 = \{0, 3\}, D^1 = \{1, 2\}, D^2 = \{4\}$$

n	색깔	잘 익은 수박
0	청록	예
3	청록	예

$$p_0 = 0, p_1 = 1$$

$$Ent(D^0) = 0$$

n	색깔	잘 익은 수박
1	진녹	예
2	진녹	아니오

$$p_0 = \frac{1}{2}, p_1 = \frac{1}{2}$$

$$Ent(D^1) = 1$$

n	색깔	잘 익은 수박
4	연록	아니오

$$p_0 = 1, p_1 = 0$$

$$Ent(D^2) = 0$$

분할 후 평균 엔트로피 (일괄 평균이 아닌 데이터 수 비례 평균)

$$\frac{2}{5}Ent(D^0) + \frac{2}{5}Ent(D^1) + \frac{1}{5}Ent(D^2) = \frac{2}{5} = 0.4$$

(분할을 통해 얻은 정보 이득)

$$0.971 - 0.4 = 0.571$$

즉, 모든 입력 속성에 대해서 정보 이득을 계산하여, 정보이득이 가장 큰 속성을 Root node로 설정

Step 1) 어떤 속성을 Root node로 선택할 것인가?

Binary Classification 에서 반반: 엔트로피 1

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	훈탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	진녹색	말림	훈탁	선명함	움푹 패임	단단함	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	예
5	연녹색	말림	훈탁	선명함	움푹 패임	단단함	예
6	청록색	약간 말림	훈탁	선명함	약간 패임	물렁함	예
7	진녹색	약간 말림	훈탁	약간 흐림	약간 패임	물렁함	예
8	진녹색	약간 말림	훈탁	선명함	약간 패임	단단함	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	아니오
12	연녹색	말림	훈탁	흐림	평평함	단단함	아니오
13	청록색	약간 말림	훈탁	약간 흐림	움푹 패임	단단함	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	아니오
15	진녹색	약간 말림	훈탁	선명함	약간 패임	물렁함	아니오
16	연녹색	말림	훈탁	흐림	평평함	단단함	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	아니오


Root node 정보 엔트로피

$$Ent(D) = - \sum_{k=0}^1 p_k \log_2 p_k$$

$$= -p_0 \log_2 p_0 - p_1 \log_2 p_1$$

$$p_0 = \frac{8}{17} : \text{양성 (잘 익은 수박)의 비율}$$

$$p_1 = \frac{9}{17} : \text{음성 (덜 익은 수박)의 비율}$$



$$Ent(D) = -p_0 \log_2 p_0 - p_1 \log_2 p_1 = -\frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} = 0.998$$

■ Step 1) 어떤 속성을 Root node로 선택할 것인가?

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	흔탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	진녹색	말림	흔탁	선명함	움푹 패임	단단함	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	예
5	연녹색	말림	흔탁	선명함	움푹 패임	단단함	예
6	청록색	약간 말림	흔탁	선명함	약간 패임	물렁함	예
7	진녹색	약간 말림	흔탁	약간 흐림	약간 패임	물렁함	예
8	진녹색	약간 말림	흔탁	선명함	약간 패임	단단함	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	아니오
12	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
13	청록색	약간 말림	흔탁	약간 흐림	움푹 패임	단단함	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	아니오
15	진녹색	약간 말림	흔탁	선명함	약간 패임	물렁함	아니오
16	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	아니오

• 각 속성의 정보 이득

색깔 속성이 가질 수 있는 속성값 = {청록, 진녹, 연녹}, V=3

데이터 집합 D

- 청록인 집합 $D^1 = \{1, 4, 6, 10, 13, 17\}$
- 진녹인 집합 $D^2 = \{2, 3, 7, 8, 9, 15\}$
- 연녹인 집합 $D^3 = \{5, 11, 12, 14, 16\}$

정록
예 / 아니오
1 4 6 10 13 17
=> 반반: 엔트로피 1

• D^1 의 정보 엔트로피

$$Ent(D^1) = - \sum_{k=0}^1 p_k \log_2 p_k = -p_0 \log_2 p_0 - p_1 \log_2 p_1 = -\frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} = 1$$

▪ Step 1) 어떤 속성을 Root node로 선택할 것인가?

- Root node 정보 엔트로피: $Ent(D) = 0.998$
- 분할된 각 노드의 정보 엔트로피: $Ent(D^1) = 1$
 $Ent(D^2) = 0.918$
 $Ent(D^3) = 0.722$
- 분할된 각 노드의 크기 비율: $\frac{|D^1|}{|D|} = \frac{6}{17}, \frac{|D^2|}{|D|} = \frac{6}{17}, \frac{|D^3|}{|D|} = \frac{5}{17}$

• “색깔” 속성의 정보 이득

$$\begin{aligned}
 Gain(D, \text{색깔}) &= Ent(D) - \sum_{v=1}^3 \frac{|D^v|}{|D|} Ent(D^v) \\
 &= 0.998 - \left(\frac{6}{17} \times 1 + \frac{6}{17} \times 0.918 + \frac{5}{17} \times 0.722 \right) = 0.109
 \end{aligned}$$

“색깔”로 나뉠 때 얻는 엔트로피 감소
 ↓
 전속의 엔트로피
 ↑
 평균 엔트로피

■ Step 1) 어떤 속성을 Root node로 선택할 것인가?

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	흔탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	진녹색	말림	흔탁	선명함	움푹 패임	단단함	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	예
5	연녹색	말림	흔탁	선명함	움푹 패임	단단함	예
6	청록색	약간 말림	흔탁	선명함	약간 패임	물렁함	예
7	진녹색	약간 말림	흔탁	약간 흐림	약간 패임	물렁함	예
8	진녹색	약간 말림	흔탁	선명함	약간 패임	단단함	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	아니오
12	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
13	청록색	약간 말림	흔탁	약간 흐림	움푹 패임	단단함	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	아니오
15	진녹색	약간 말림	흔탁	선명함	약간 패임	물렁함	아니오
16	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	아니오

• 모든 속성에 대한 정보 이득

$$Gain(D, \text{색깔}) = 0.109$$

$$Gain(D, \text{꼭지 모양}) = 0.143$$

$$Gain(D, \text{소리}) = 0.141$$

$$Gain(D, \text{줄무늬}) = 0.381$$

$$Gain(D, \text{배꼽 모양}) = 0.289$$


$$Gain(D, \text{촉감}) = 0.006$$

=> 줄무늬로 Root 하는게 유리

Root node에서 어느 속성으로 Partitioning 하는 것이 유리한가?


Step 2) 각 Child node에 대해 정보 이득을 다시 계산하여 분할 속성 선택

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	흔탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	진녹색	말림	흔탁	선명함	움푹 패임	단단함	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	예
5	연녹색	말림	흔탁	선명함	움푹 패임	단단함	예
6	청록색	약간 말림	흔탁	선명함	약간 패임	물렁함	예
7	진녹색	약간 말림	흔탁	약간 흐림	약간 패임	물렁함	예
8	진녹색	약간 말림	흔탁	선명함	약간 패임	단단함	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	아니오
12	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
13	청록색	약간 말림	흔탁	약간 흐림	움푹 패임	단단함	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	아니오
15	진녹색	약간 말림	흔탁	선명함	약간 패임	물렁함	아니오
16	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	아니오



특정 Node에서 더 이상의 분할이 필요한가?

- Step 3) 모든 Child node들에 대해 더 이상 분할이 필요하지 않으면, Stop



⇒ 소리, 배꼽 모양은 분류 안해도 된다는 뜻

더 이상 Partitioning 이 필요없는 node 를 Leaf node 지정

=> 해당 과정에 대한 Overfitting 가능성은?


Pruning (가지치기)



- 가지치기 (Pruning)

- 의사결정 트리 학습의 과적합 방지를 위한 수단
- 의사결정 트리의 학습과정
 - 노드의 분할을 반복하는 과정
 - 과도한 반복으로 많은 수의 가지를 생성함
 - 훈련 데이터에 과도하게 훈련된 트리 생성 가능성
- 자발적인 가지 자르기를 통한 Overfitting 위험 방지
- 사전 가지치기와 사후 가지치기

- Pruning



- 사전 가지치기 (pre-pruning)
 - 트리를 만드는 과정에서 가지치기 하는 방식
 - 어떤 노드의 분할 과정에서,
 - 노드의 분할이 일반화 성능을 향상시키는지 예측
 - 일반화 성능을 향상시킨다면 분할 진행
 - 그렇지 않다면 분할을 중지하고 해당 노드를 leaf node로 설정
- 사후 가지치기 (post-pruning) 연산량이 좀더 많지만 정확도 높음
 - 의사결정 트리가 완성된 후 가지치기 하는 방식
 - 완성된 트리에서 아래쪽 leaf node에 대해,
 - 해당 노드가 leaf node 바뀌었을 때 일반화 성능을 예측
 - 일반화 성능을 향상시킬 수 있다면 해당 노드를 leaf node로 설정

Pre-Pruning



Step 1) Training set과 Validation set으로 데이터 분리

Training set

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	훈탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	진녹색	말림	훈탁	선명함	움푹 패임	단단함	예
6	청록색	약간 말림	훈탁	선명함	약간 패임	물렁함	예
7	진녹색	약간 말림	훈탁	약간 흐림	약간 패임	물렁함	예
10	청록색	곧음	맑음	선명함	평평함	물렁함	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	아니오
15	진녹색	약간 말림	훈탁	선명함	약간 패임	물렁함	아니오
16	연녹색	말림	훈탁	흐림	평평함	단단함	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	아니오

Validation set

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	예
5	연녹색	말림	훈탁	선명함	움푹 패임	단단함	예
8	진녹색	약간 말림	훈탁	선명함	약간 패임	단단함	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	아니오
12	연녹색	말림	훈탁	흐림	평평함	단단함	아니오
13	청록색	약간 말림	훈탁	약간 흐림	움푹 패임	단단함	아니오

Step 2) Training set에 대해서 parent node의 속성 결정

Training set

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
1	청록색	말림	훈탁	선명함	움푹 패임	단단함	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	예
3	진녹색	말림	훈탁	선명함	움푹 패임	단단함	예
6	청록색	약간 말림	훈탁	선명함	약간 패임	물렁함	예
7	진녹색	약간 말림	훈탁	약간 흐림	약간 패임	물렁함	예
10	청록색	곧음	맑음	선명함	평평함	물렁함	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	아니오
15	진녹색	약간 말림	훈탁	선명함	약간 패임	물렁함	아니오
16	연녹색	말림	훈탁	흐림	평평함	단단함	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	아니오

루트 노드의 정보 엔트로피

$$p_1 = \frac{5}{10} : \text{양성 (잘 익은 수박)의 비율}$$

$$p_2 = \frac{5}{10} : \text{음성 (덜 익은 수박)의 비율}$$

$$Ent(D) = -\frac{5}{10} \log_2 \frac{5}{10} - \frac{5}{10} \log_2 \frac{5}{10} = 1$$

⇒ 비율이 5:5 이므로 Root node에서는 양성으로 분류하는 것으로 가정

모든 속성의 정보 이득

$$Gain(D, \text{색깔}) = 0.2755$$

$$Gain(D, \text{꼭지 모양}) = 0.1145$$

$$Gain(D, \text{소리}) = 0.1735$$

$$Gain(D, \text{줄무늬}) = 0.1735$$

$$Gain(D, \text{배꼽 모양}) = 0.2755$$

$$Gain(D, \text{촉감}) = 0$$

Root node의 Partitioning 속성

Pre-Pruning




지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.

- Step 3) Validation set을 활용하여 Partitioning 전과 후에 대한 정확도 계산

Validation set

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	잘 익은 수박
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	예
5	연녹색	말림	흔탁	선명함	움푹 패임	단단함	예
8	진녹색	약간 말림	흔탁	선명함	약간 패임	단단함	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	아니오
12	연녹색	말림	흔탁	흐림	평평함	단단함	아니오
13	청록색	약간 말림	흔탁	약간 흐림	움푹 패임	단단함	아니오

Root node Partitioning



각 Child node에 대한 분류 기준은 Training set에 대한 y값 비율을 보고 판단

Partitioning 전

- Root node에서는 항상 양성으로 분류
- Validation set에 대한 분류 정확도: 3/7

Partitioning 후

- Validation set에 대한 분류 정확도: 5/7


Partitioning 하는 것이 Validation set의 정확도가 좋다
⇒ Partitioning 진행 (즉, 가지치기를 하지 않음)

Partitioning 하는 것이 Validation set의 정확도가 좋지 않다.
⇒ Pre-pruning 진행

Pre-Pruning



- Step 4) 모든 Child node에 대해서 step 2~3 repeat



전체 노드의 데이터의 정확도
or
현재 하고 있는 노드의 정확도

분할 전: $\frac{2}{3}$
분할 후: $\frac{1}{3}$

Node 4는 완전히 분류 되었기 때문에 Partitioning을 애초에 고려하지 않음.

- 사전 가지치기

- 의사결정 트리의 많은 가지가 뺏어나가지 못하도록 함
- 장점
 - Overfitting의 위험 낮춤
 - 의사결정 트리의 훈련 및 검증 시간 단축(연산량 적음)
- 단점
 - 후속 분할에서 일반화 성능이 향상될 수 있는 가능성을 차단함
 - Underfitting 위험 높아짐


- [참고] Stop 조건을 활용한 Overfitting 방지

- 조건 1: Partitioning을 통한 정보 이득이 일정값 이하
- 조건 2: 해당 node의 데이터 수가 일정값 이하

이전까지는 Child node에서 완전히 분류가 가능할 때만 Leaf node로 설정

• Post-Pruning

- Training set과 Validation set으로 데이터를 분할
- Training set에 대해서 의사결정 트리를 먼저 완성시킴
- 가장 아래쪽의 Leaf node가 아닌 node부터 **역방향으로 진행**
 - 6번 노드에서 가지치기 시작
 - 6번 노드를 잘라낼 경우와 그렇지 않은 경우의 검증 성능 비교



Post-Pruning 검사 방식은 동일



지능형 예측·진단 연구실
Intelligent Prognostics & Diagnostics Lab.


트리 만들기
↓
Validation Set으로 깎힐거 검사

원래 가지 "색깔 = ?"의 검정 정확도

가지를 잘라내기 전: 57.1%

가지를 잘라낸 후: 71.4%

Post-pruning 진행



원래 가지 "줄무늬 = ?"의 검정 정확도

가지를 잘라내기 전: 42.9%

가지를 잘라낸 후: 57.1%

Post-pruning 진행

⑥: 정확도 50%

⑥'s Child: 정확도%

그 외 Node에서는 가지를 잘라내기 전의 정확도가 더 높기 때문에
Pruning을 하지 않음

- **Post-Pruning**

- 장점
 - 과적합과 과소적합의 위험이 낮아짐
- 단점
 - 훈련과 검증 시간이 길어짐 (연산량 많음)

속성 조건이 범주형이 아닌 수치형이라면?

수치형 속성 데이터 처리



- 수치형 속성에 대한 의사결정 트리
 - 이전 방법으로는 수치적인 연속값에 대해 분할할 수 없음
 - 연속값은 무한한 분할이 필요함
 - 수치형 속성을 범주형 속성으로 변환하여 사용

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	밀도	당도	잘 익은 수박
1	청록색	말림	훈탁	선명함	움푹 패임	단단함	0.697	0.460	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	0.774	0.376	예
3	진녹색	말림	훈탁	선명함	움푹 패임	단단함	0.634	0.264	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	0.608	0.318	예
5	연녹색	말림	훈탁	선명함	움푹 패임	단단함	0.556	0.215	예
6	청록색	약간 말림	훈탁	선명함	약간 패임	물렁함	0.403	0.237	예
7	진녹색	약간 말림	훈탁	약간 흐림	약간 패임	물렁함	0.481	0.149	예
8	진녹색	약간 말림	훈탁	선명함	약간 패임	단단함	0.437	0.211	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	0.666	0.091	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	0.243	0.267	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	0.245	0.057	아니오
12	연녹색	말림	훈탁	흐림	평평함	단단함	0.343	0.099	아니오
13	청록색	약간 말림	훈탁	약간 흐림	움푹 패임	단단함	0.639	0.161	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	0.657	0.198	아니오
15	진녹색	약간 말림	훈탁	선명함	약간 패임	물렁함	0.360	0.370	아니오
16	연녹색	말림	훈탁	흐림	평평함	단단함	0.593	0.042	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	0.719	0.103	아니오

직관적으로 어떻게 하면 수치형 속성이 범주형으로 바뀔까?

- **Bi-partition (이분법)** 일정 값 이상은 x, 이하는 y, "일정 값" 못찾기
 - 수치형 속성 a , 데이터 집합 D
 - 집합 D 의 데이터들이 속성 a 에 대해 갖는 값이 n 개이고, 크기 순으로 나열했을 때 $\{a^1, a^2, \dots, a^n\}$ 이라고 표시
 - 목표는 n 개의 값을 두 그룹으로 나누는 것
 - 즉, a^1 과 a^n 사이의 어떤 값을 분할점으로 할 것인가를 결정하는 것
 - 분할점의 후보들
 - $T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \leq i \leq n - 1 \right\}$
 - 최적의 분할점은?
 - 분할점을 기준으로 데이터 집합 D 를 두 집합으로 나누었을 때, 정보이득이 가장 커지는 값이 최적 분할점

수치형 속성 데이터 처리



• Bi-partition (이분법)

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	밀도	당도	잘 익은 수박
1	청록색	말림	흔탁	선명함	움푹 패임	단단함	0.697	0.460	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	0.774	0.376	예
3	진녹색	말림	흔탁	선명함	움푹 패임	단단함	0.634	0.264	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	0.608	0.318	예
5	연녹색	말림	흔탁	선명함	움푹 패임	단단함	0.556	0.215	예
6	청록색	약간 말림	흔탁	선명함	약간 패임	물렁함	0.403	0.237	예
7	진녹색	약간 말림	흔탁	약간 흐림	약간 패임	물렁함	0.481	0.149	예
8	진녹색	약간 말림	흔탁	선명함	약간 패임	단단함	0.437	0.211	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	0.666	0.091	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	0.243	0.267	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	0.245	0.057	아니오
12	연녹색	말림	흔탁	흐림	평평함	단단함	0.343	0.099	아니오
13	청록색	약간 말림	흔탁	약간 흐림	움푹 패임	단단함	0.639	0.161	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	0.657	0.198	아니오
15	진녹색	약간 말림	흔탁	선명함	약간 패임	물렁함	0.360	0.370	아니오
16	연녹색	말림	흔탁	흐림	평평함	단단함	0.593	0.042	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	0.719	0.103	아니오

{0.243, 0.245, 0.343, ..., 0.697, 0.719, 0.774}

○ 분할점의 후보들

$T_{\text{밀도}} = \{0.244, 0.294, \dots, 0.708, 0.746\}$

① 오류차순 정렬

② 하나씩 엔트로피 Gain 계산

수치형 속성 데이터 처리



• Bi-partition (이분법)

	밀도	잘익은 수 박	분할점 후보
D ₁	0.243	아니오	
	0.245	아니오	0.244
	0.343	아니오	0.294
	0.360	아니오	0.351
	0.403	예	0.381
D ₂	0.481	예	0.420
	0.556	예	0.459
	0.593	아니오	0.518
	0.608	예	0.574
	0.634	예	0.6
	0.634	예	0.621
	0.639	아니오	0.636
	0.657	아니오	0.648
	0.666	아니오	0.661
	0.697	예	0.681
	0.719	아니오	0.708
	0.774	예	0.746

- 분할 전 엔트로피

$$Ent(D) = -\frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} = 0.998$$

- 분할점 0.244로 분할한 후 엔트로피

$$D_1 = \{(0.243, \text{아니오})\}$$


$$D_2 = \{(0.245, \text{아니오}), (0.343, \text{아니오}), \dots, (0.774, \text{예})\}$$

$$Ent(D_1) = -0 \log_2 0 - 1 \log_2 1 = 0$$

$$Ent(D_2) = -\underbrace{\frac{8}{16} \log_2 \frac{8}{16}}_{\text{예}} - \underbrace{\frac{8}{16} \log_2 \frac{8}{16}}_{\text{아니오 (16개중 8개)}} = 1$$

- 분할점 0.224로 분할했을 때 정보이득

$$Gain(D, \text{밀도}, 0.224) = 0.998 - \frac{16}{17} \times 1 = 0.0568$$



• Bi-partition (이분법)

최적 정보이득 = 0.263

최적 분할점 = 0.381

	밀도	잘익은 수 박	분할점 후보
D ₁	0.243	아니오	
	0.245	아니오	0.244
	0.343	아니오	0.294
	0.360	아니오	0.351
D ₂	0.403	예	0.381
	0.481	예	0.420
	0.556	예	0.459
	0.593	아니오	0.518
	0.608	예	0.574
	0.634	예	0.6
	0.634	예	0.621
	0.639	아니오	0.636
	0.657	아니오	0.648
	0.666	아니오	0.661
	0.697	예	0.681
	0.719	아니오	0.708
	0.774	예	0.746

- 분할 전 엔트로피

$$Ent(D) = -\frac{8}{17} \log_2 \frac{8}{17} - \frac{9}{17} \log_2 \frac{9}{17} = 0.998$$

- 분할점 0.381로 분할한 후 엔트로피

$$D_1 = \{(0.243, \text{아니오}), (0.245, \text{아니오}), \dots, (0.360, \text{아니오})\}$$

$$D_2 = \{(0.403, \text{예}), (0.481, \text{예}), \dots, (0.774, \text{예})\}$$

D₁을 하나씩 늘려가면서 최적값 찾기

$$Ent(D_1) = -0 \log_2 0 - 1 \log_2 1 = 0 \quad \text{그 후 밀도의 평균값을 최적값으로}$$

$$Ent(D_2) = -\frac{8}{13} \log_2 \frac{8}{13} - \frac{5}{13} \log_2 \frac{5}{13} = 0.9612$$

- 분할점 0.381로 분할했을 때 정보이득

$$Gain(D, \text{밀도}, 0.224) = 0.998 - \frac{13}{17} \times 0.9612 = 0.263$$

수치형 속성 데이터 처리

• Bi-partition (이분법)

번호	색깔	꼭지 모양	소리	줄무늬	배꼽 모양	감촉	밀도	당도	잘 익은 수박
1	청록색	말림	훈탁	선명함	움푹 패임	단단함	0.697	0.460	예
2	진녹색	말림	둔탁	선명함	움푹 패임	단단함	0.774	0.376	예
3	진녹색	말림	훈탁	선명함	움푹 패임	단단함	0.634	0.264	예
4	청록색	말림	둔탁	선명함	움푹 패임	단단함	0.608	0.318	예
5	연녹색	말림	훈탁	선명함	움푹 패임	단단함	0.556	0.215	예
6	청록색	약간 말림	훈탁	선명함	약간 패임	물렁함	0.403	0.237	예
7	진녹색	약간 말림	훈탁	약간 흐림	약간 패임	물렁함	0.481	0.149	예
8	진녹색	약간 말림	훈탁	선명함	약간 패임	단단함	0.437	0.211	예
9	진녹색	약간 말림	둔탁	약간 흐림	약간 패임	단단함	0.666	0.091	아니오
10	청록색	곧음	맑음	선명함	평평함	물렁함	0.243	0.267	아니오
11	연녹색	곧음	맑음	흐림	평평함	단단함	0.245	0.057	아니오
12	연녹색	말림	훈탁	흐림	평평함	단단함	0.343	0.099	아니오
13	청록색	약간 말림	훈탁	약간 흐림	움푹 패임	단단함	0.639	0.161	아니오
14	연녹색	약간 말림	둔탁	약간 흐림	움푹 패임	단단함	0.657	0.198	아니오
15	진녹색	약간 말림	훈탁	선명함	약간 패임	물렁함	0.360	0.370	아니오
16	연녹색	말림	훈탁	흐림	평평함	단단함	0.593	0.042	아니오
17	청록색	말림	둔탁	약간 흐림	약간 패임	단단함	0.719	0.103	아니오

$$Gain(D, \text{색깔}) = 0.109$$

$$Gain(D, \text{꼭지 모양}) = 0.143$$

$$Gain(D, \text{소리}) = 0.141$$

$$Gain(D, \text{줄무늬}) = 0.381$$

$$Gain(D, \text{배꼽 모양}) = 0.289$$

$$Gain(D, \text{촉감}) = 0.006$$

$$Gain(D, \text{밀도}) = 0.263$$

$$Gain(D, \text{당도}) = 0.349$$


DT의 Decision Boundary




결정 트리의 결정 공간 이해

- 결정 공간 상에서 의사결정 트리의 결정 경계는 항상 좌표축과 평행을 이룸

번호	밀도	당도	잘 익은 수박	번호	밀도	당도	잘 익은 수박	번호	밀도	당도	잘 익은 수박
1	0.697	0.460	예	7	0.481	0.149	예	13	0.639	0.161	아니오
2	0.774	0.376	예	8	0.437	0.211	예	14	0.657	0.198	아니오
3	0.634	0.264	예	9	0.666	0.091	아니오	15	0.360	0.370	아니오
4	0.608	0.318	예	10	0.243	0.267	아니오	16	0.593	0.042	아니오
5	0.556	0.215	예	11	0.245	0.057	아니오	17	0.719	0.103	아니오
6	0.403	0.237	예	12	0.343	0.099	아니오				



수직형 데이터는 한 카테고리를
여러번 쓰기 가능



좌표축과 평행하지 않은 직선으로는
나눌 수 있을까?

DT의 Decision Boundary





- **Multivariate Decision Tree (다변량 결정 트리)** 안함

- 속성들의 선형 조합을 바탕으로 Partitioning 진행



OX 퀴즈 수준으로만

알아두셈





y값이 범주형이 아닌 수치형이라면?


- **Regression Tree (회귀 트리)** 기준: Tree를 나누는 기준을 Gain으로 판단
→ : SSE로 판단
 - Classification Tree에서의 Complexity: Information Entropy
 - Regression Tree에서의 Complexity: Sum of Squared error
(SSE: $\sum_{i=1}^n (y_i - \hat{y})^2$)
 - Gain: Parent node의 SSE와 Child nodes의 SSE 합을 비교
 - 최종 예측값은 Leaf node 데이터들의 실제값들의 평균



Regression Tree



Regression Tree



$$-1.2x_1 + x_2 < 0.1$$

$\swarrow \quad \searrow$

$\omega_2 \quad \omega_1$