

[NLP & Text Mining]

텍스트 벡터화 (Text Vectorization)

박성호

컴퓨터공학부


학습 목표

텍스트 Data 벡터화에 대해 알아보겠습니다.

- One-Hot Vector
- TF-IDF

Natural Language Processing

Text = "성호가 자연어처리 수업을 한다."



전처리1 - (형태소)


성호	-가	자연어	처리	수업	을-	하-	-ㄴ다
----	----	-----	----	----	----	----	-----



전처리2 - Post Tagging 및 명사 추출

성호	자연어	처리	수업
----	-----	----	----

"문장이 단어 목록 형태로 변환"



코멘트 분석



Natural Language Processing

코멘트(극성) 분석

급하게 먹느라 사진을 못찍었어요 전 근대 전시
안좋아하거든요 근대 다음에 도록조 뭐;


사장님
dmsd****님, 감사합니다.^^
제가 이해하기에 조금은 난해한 리뷰입니다.^^; 사진을
안좋아 하시지만 그런대로 입에 맞았고, 그래서 다음에
또 들려주시겠다는 말씀으로 이해하면 될까요?
못드시거나 입에 맞지 않는 재료들은 요청사항에
남겨주셔서 반영해서 만들어 보내드립니다.~ 다음에 꼭
다시 한번 들려주세요. 정말 맛있게 만들어
보내드릴게요.^^



제품을 추천/비추천/중립하는
코멘트 분석

문서분류 분석

✓ Spam mail filtering



문서요약

뉴스기사 요약, 법률문서 요약, 사업보고서 요약

정치면 뉴스

[정세균 국무총리가 21일 오전 서울시장에서 열린 코로나 19 대응 중앙재난안전대책본부(중대본) 회의에서 발언하고 있다.] "연립 뉴스정세균 국무총리는 21일 '코로나 19' 관련 하위조직정보 생성 및 유포행위에 무관용 원칙으로 법에 따라 엄정 대응하겠다고 말했다." "정 총리는 이날 서울시장에서 주재한 코로나 19 중앙재난안전대책본부 회의에서 '코로나 19 위기가 계속되는 상황에서 (사회적 거리 두기) 3단계 확장, '생활물 사재기 조장' 등 허위조작정보가 다시 기승을 부리고 있다'며 이렇게 말했다."

"정 총리는 '이러한 허위조작정보 유포행위는 불신과 혼란을 조장하고 방역 역량을 저해하는 사회악에 해당한다'며 '방호위, 경찰청 등은 이런 위법행위를 골짜지 추적해 엄벌하라'고 지시했다." "거리두기 3단계에는 선을 그었다." "정 총리는 '수도권 거리 두기 2.5단계'로 확산자 수가 양성은 좋지 않았으나 수도권과 고령 이동량 등이 감소세에 있고 공격적 진단검사 60살 이상 확산자 비율도 줄어드는 긍정적 신호가 있다'고 평가했다. " "그러면서 '거리 두기 단계 조정은 치밀하게 준비되고 마지막 카드가 되어야 한다. '갑 경 원칙대로 확실히 요양병원, 요양시설, 장시병원, 스키장 등에 대한 확산의 방역 대책이 필요하다'고 강조했다." "연립장사를 맞아 방역대책 강화도 주문했다." "정 총리는 '중수본(중앙사고수습본부)은 한층 강화된 연립연식 특별방역대책을 마련해 신속하게 시행해 달라'며 '고강도 방역대책에 따른 고통을 정부가 모른 척해서 도 안 되는 만큼 재정 투입은 합리적 지원대책을 검토하라'고 말했다."



1. 요약 문장 추출Task

"정 총리는 '이러한 허위조작정보 유포행위는 불신과 혼란을 조장하고 방역 역량을 저해하는 사회악에 해당한다'며 '방호위, 경찰청 등은 이런 위법행위를 골짜지 추적해 엄벌하라'고 지시했다." "거리두기 3단계에는 선을 그었다." "정 총리는 '수도권 거리 두기 2.5단계'로 확산자 수가 양성은 좋지 않았으나 수도권과 고령 이동량 등이 감소세에 있고 공격적 진단검사 60살 이상 확산자 비율도 줄어드는 긍정적 신호가 있다'고 평가했다. " "그러면서 '거리 두기 단계 조정은 치밀하게 준비되고 마지막 카드가 되어야 한다. '갑 경 원칙대로 확실히 요양병원, 요양시설, 장시병원, 스키장 등에 대한 확산의 방역 대책이 필요하다'고 강조했다." "연립장사를 맞아 방역대책 강화도 주문했다." "정 총리는 '중수본(중앙사고수습본부)은 한층 강화된 연립연식 특별방역대책을 마련해 신속하게 시행해 달라'며 '고강도 방역대책에 따른 고통을 정부가 모른 척해서 도 안 되는 만큼 재정 투입은 합리적 지원대책을 검토하라'고 말했다."


"정 총리는 '이러한 허위조작정보 유포행위는 불신과 혼란을 조장하고 방역 역량을 저해하는 사회악에 해당한다'며 '방호위, 경찰청 등은 이런 위법행위를 골짜지 추적해 엄벌하라'고 지시했다." "거리두기 3단계에는 선을 그었다." "정 총리는 '수도권 거리 두기 2.5단계'로 확산자 수가 양성은 좋지 않았으나 수도권과 고령 이동량 등이 감소세에 있고 공격적 진단검사 60살 이상 확산자 비율도 줄어드는 긍정적 신호가 있다'고 평가했다. " "그러면서 '거리 두기 단계 조정은 치밀하게 준비되고 마지막 카드가 되어야 한다. '갑 경 원칙대로 확실히 요양병원, 요양시설, 장시병원, 스키장 등에 대한 확산의 방역 대책이 필요하다'고 강조했다." "연립장사를 맞아 방역대책 강화도 주문했다." "정 총리는 '중수본(중앙사고수습본부)은 한층 강화된 연립연식 특별방역대책을 마련해 신속하게 시행해 달라'며 '고강도 방역대책에 따른 고통을 정부가 모른 척해서 도 안 되는 만큼 재정 투입은 합리적 지원대책을 검토하라'고 말했다."

문서분류 분석



지난 대 인공지능 번역대결


Natural Language Processing



“사람의 말을 컴퓨터 (계산기)에게 이해”

Natural Language Processing

Text = "성호가 자연어처리 수업을 한다."



전처리: 불필요한 것들 제거

성호	자연어	처리	수업
----	-----	----	----



단어의미를 컴퓨터에게 파악 할 수 있도록 해야함!

Natural Language Processing

Text = “성호가 자연어처리 수업을 한다.”



전처리: 불필요한 것들 제거

성호 자연어 처리 수업



단어의미를 컴퓨터에게 파악
할 수 있도록 해야함!

국어사전 Beta

처리

고급 검색

전체 단어 속담·관용구 뜻풀이 예문 맞춤법 표기법

T T T

단어 1,585

오른사전

처리 處理 [처리/처리] ★

1. 명사 사무나 사건 따위를 절차에 따라 정리하여 치르거나 마무리를 지음.
2. 명사 일정한 결과를 얻기 위하여 화학적 또는 물리적 작용을 일으킴.

표준국어대사전

처리²

명사 방언 '잠자리²'의 방언(경북).

고려대 한국어대사전

처리 處理 [처리/처리]

명사 농업 실험의 효과를 측정하여 서로 비교가 될 수 있도록 하는 방법. 포장 실험의 품종, 비료 사용량, 실내 실험의 온도 조건 따위를 이른다.

우리말샘

처리

부사 방언 처리. (전북)

전라북도 방언사전

철의² 鐵衣 [처리/처리]

1. 명사 쇠물이를 겹에 붙여 지은 갑옷.
2. 명사 쇠에 생기는 녹.

표준국어대사전

단어 더보기 >

Image - Vectorization

- 사람의 말을 컴퓨터 (계산기)에게 이해시키기 위한 기술 또는 학문



1 Wine Red	54 Viridian	99 Bronze
2 Old Red	56 Mint Green	101 Yellow Ochre
5 Cherry Pink	59 Pale Green	103 Potato Brown
6 Vivid Pink	61 Peacock Green	104 Brown Grey
7 Cosmos	63 Cerulean Blue	120 Black
9 Pale Pink	65 Ice Blue	BG- 1 Blue Grey
11 Carmine	67 Pastel Blue	BG- 3 Blue Grey
12 Coral Red	69 Prussian Blue	BG- 5 Blue Grey
14 Vermillion	71 Cobalt Blue	BG- 7 Blue Grey
21 Terra Cotta	73 Ultra Blue	BG- 9 Blue Grey
23 Orange	74 Brilliant Blue	CG- 1 Cool Grey
26 Pastel Peach	76 Sky Blue	CG- 3 Cool Grey
33 Melon Yellow	81 Deep Violet	CG- 5 Cool Grey
35 Lemon Yellow	83 Lavender	CG- 7 Cool Grey
37 Pastel Yellow	85 Vivid Purple	CG- 9 Cool Grey
41 Olive Green	87 Azalea Purple	WG- 1 Warm Grey
43 Deep Olive Green	89 Pale Purple	WG- 3 Warm Grey
46 Vivid Green	91 Natural Oak	WG- 5 Warm Grey
48 Yellow Green	92 Chocolate	WG- 7 Warm Grey
51 Dark Green	94 Brick Brown	WG- 9 Warm Grey




3-channel matrix

		Blue			
	Green	255	134	93	22
Red		255	134	202	22
		255	231	42	22
		123	94	83	2
		34	44	187	92
		34	76	232	124
		67	83	194	202

Text Vectorization – 정수 인코딩 또는 ID 부여


Text =

성호	자연어	처리	수업
----	-----	----	----



word_to_id = {성호: 0, 자연어: 1, 처리: 2, 수업: 3}

id_to_word = {0: 성호, 1: 자연어, 2: 처리, 3: 수업}



ID_Text =

0	1	2	3
---	---	---	---

Text Vectorization (Embedding)– One-Hot Encoding



Text = “성호가 자연어처리 수업을 한다.”

Text =

성호	자연어	처리	수업
----	-----	----	----

ID_Text =

0	1	2	3
---	---	---	---




Text Vectorization (Embedding)– One-Hot Encoding

고양이 = $[0,0,0,...,1,...,0] \in \mathbb{R}^{\text{백만}}$

강아지 = $[0,1,0,...,0,...,0] \in \mathbb{R}^{\text{백만}}$

유사도 Similarity

❖ 유클리디안 거리 (Euclidean Distance)



❖ Cosine 유사도




$$A \cdot B = |A| \cdot |B| \cdot \cos \Theta$$
$$\therefore \cos(\Theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

Text Vectorization (Embedding)– One-Hot Encoding

text1 = “강아지는 좋은 반려동물 입니다.”

text2 = “고양이는 훌륭한 애완동물 입니다.”



단어 벡터화


고양이 = $[0,0,0,...1,...0] \in \mathbb{R}^{\text{백만}}$

강아지 = $[0,1,0,...0,...0] \in \mathbb{R}^{\text{백만}}$

애완 = $[0,0,0,...0,...1] \in \mathbb{R}^{\text{백만}}$

반려 = $[1,0,0,...0,...0] \in \mathbb{R}^{\text{백만}}$


문장/문서 벡터화



Text Vectorization (Embedding)– One-Hot Encoding

text1 = “강아지 성격 관련” 책

text2 = “고양이 성격 관련” 책



단어 벡터화


고양이 = $[0,0,0,...,1,...,0] \in \mathbb{R}^{\text{백만}}$

강아지 = $[0,1,0,...,0,...,0] \in \mathbb{R}^{\text{백만}}$

애완 = $[0,0,0,...,0,...,1] \in \mathbb{R}^{\text{백만}}$

반려 = $[1,0,0,...,0,...,0] \in \mathbb{R}^{\text{백만}}$

문장/문서 벡터화



Text Vectorization (Embedding)– Term Frequency

① Bag of Words Hypothesis (백 오브 워즈 가정)


- 각 문서 내 단어의 빈도를 고려

별 헤는 밤
윤동주

문장1 : 별 하나에 추억과
문장2 : 별 하나에 사랑과
문장3 : 별 하나에 쓸쓸함과
문장4 : 별 하나에 동경과
문장5 : 별 하나에 시와
문장6 : 별 하나에 어머니, 어머니.



Term Frequency 기반의 벡터화



별	하나	에	추억	과	와	사랑	쓸쓸함	동경	시	어머니
6	6	6	1	4	11	1	1	1	1	2

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려



	별	하나	에	추억	과	와	사랑	쓸쓸함	동경	시	어머니
문장1	1	1	1	1	1	0	0	0	0	0	0
문장2	1	1	1	0	1	0	1	0	0	0	0
문장3	1	1	1	0	1	0	0	1	0	0	0
문장4	1	1	1	0	0	0	0	0	1	0	0
문장5	1	1	1	0	0	1	0	0	0	1	0
문장6	1	1	1	0	0	0	0	0	0	0	2

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려

	별	하나	에	추억	과	와	사랑	쓸쓸함	동경	시	어머니
문장1	1	1	1	1	1	0	0	0	0	0	0
문장2	1	1	1	0	1	0	1	0	0	0	0
문장3	1	1	1	0	1	0	0	1	0	0	0
문장4	1	1	1	0	0	0	0	0	1	0	0
문장5	1	1	1	0	0	1	0	0	0	1	0
문장6	1	1	1	0	0	0	0	0	0	0	2

❖ 유클리디안 거리 (Euclidean Distance)

$$d_{(X,Y)} = \sqrt{\sum_{i=1}^p (x_i - y_i)^2}$$

❖ Cosine 유사도



$$A \cdot B = |A| * |B| * \cos\Theta$$

$$\therefore \cos(\Theta) = \frac{A \cdot B}{\|A\| \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n (A_i)^2} \times \sqrt{\sum_{i=1}^n (B_i)^2}}$$

Text Vectorization (Embedding)

- ① Bag of Words Hypothesis (백 오브 워즈 가정)
- 각 문서 내 단어의 빈도를 고려

별 헤는 밤

윤동주

문장1 : 별 하나에 추억과
문장2 : 별 하나에 사랑과
문장3 : 별 하나에 쓸쓸함과
문장4 : 별 하나에 동경과
문장5 : 별 하나에 시와
문장6 : 별 하나에 어머니, 어머니,


	별	하나	에	추억	과	와	사랑	쓸쓸함	동경	시	어머니
문장1	1	1	1	1	1	0	0	0	0	0	0
문장2	1	1	1	0	1	0	1	0	0	0	0
문장3	1	1	1	0	1	0	0	1	0	0	0
문장4	1	1	1	0	0	0	0	0	1	0	0
문장5	1	1	1	0	0	1	0	0	0	1	0
문장6	1	1	1	0	0	0	0	0	0	0	2

	별	하나	에	추억	과	와	사랑	쓸쓸함	동경	시	어머니
문장1	1	1	1	1	1	0	0	0	0	0	0
문장2	1	1	1	0	1	0	1	0	0	0	0
문장3	1	1	1	0	1	0	0	1	0	0	0
문장4	1	1	1	0	0	0	0	0	1	0	0
문장5	1	1	1	0	0	1	0	0	0	1	0
문장6	1	1	1	0	0	0	0	0	0	0	2

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려



- 예: 논문 검색

	단어1	단어2	단어3	단어4	...	단어K
Doc1						
Doc2						
Doc3						
Doc4						
Doc5						




The complicated, evolving landscape of cancer
 Mining textual patterns in news, tweets, papers, and...
 This paper is a tutorial on Formal Concept Analysis (FCA) and its applications. FCA is an applied branch of Lattice Theory, a mathematical discipline which enables formalization of concepts as basic units of human thinking and analysing data in the object-attribute form. Originated in early 80s, during the last three decades, it became a popular human-centred tool for knowledge representation and data analysis with numerous applications. Since the tutorial was specially prepared for RuSSIR 2014, the covered FCA topics include Information Retrieval with a focus on visualisation aspects, Machine Learning, Data Mining and Knowledge Discovery, Text Mining and several others.

pattern quality assessment function, which avoids costly dependency parsing and generates high-quality patterns; (2) it identifies and groups synonymous meta patterns from multiple facets—their types, contexts, and extractions; and (3) it examines type distributions of entities in the instances extracted by each group of patterns, and looks for appropriate type levels to make discovered patterns precise. Experiments demonstrate that our proposed framework discovers high-quality typed textual patterns efficiently from different genres of massive corpora and facilitates information extraction.

Text Vectorization (Embedding)

- ① Bag of Words Hypothesis (백 오브 워즈 가정)
- 각 문서 내 단어의 빈도를 고려

	별	하나	에	추억	과	와	사랑	쓸쓸함	동경	시	어머니
문장1	1	1	1	1	1	0	0	0	0	0	0
문장2	1	1	1	0	1	0	1	0	0	0	0
문장3	1	1	1	0	1	0	0	1	0	0	0
문장4	1	1	1	0	0	0	0	0	1	0	0
문장5	1	1	1	0	0	1	0	0	0	1	0
문장6	1	1	1	0	0	0	0	0	0	0	2



Cosine 유사도
Similarity

도서 & 책 등 추천 시스템 (Recommender System)

검색

서명
인공지능

저자
Search

ISBN
Search

TITLE
AUTHOR

추천도서

내안의 빅데이터를 깨워라

(4차 산업혁명 현장 전문가가 알려주는) 빅데이터 분석과 활용

저자 : 고자기 오지 지음:전종훈 옮김

형구기호 4.73

요약

『파이썬으로 배우는 인공지능』은 인공지능을 활용하는 다양한 실제 사례와 인공지능 애플리케이션을 구현하는 데 필요한 여러 가지 알고리즘을 소개한다. 인공지능의 기본을 소개하고 데이터 마이닝 기법으로 인공지능의 핵심 구성 요소를 구현하는 다양한 방법



Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려
- 단순 빈도로 접근하기 때문에 기본적으로 모든 단어에 동일한 중요성을 부여
- 이/가'와 같은 조사가 10번 나오는 것은 '재미있는/ 훌륭한' 형용사 단어가 10번

	별	하나	에	추억	과	와	사랑	쓸쓸함	동경	시	어머니
문장1	1	1	1	1	1	0	0	0	0	0	0
문장2	1	1	1	0	1	0	1	0	0	0	0
문장3	1	1	1	0	1	0	0	1	0	0	0
문장4	1	1	1	0	0	0	0	0	1	0	0
문장5	1	1	1	0	0	1	0	0	0	1	0
문장6	1	1	1	0	0	0	0	0	0	0	2

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려

Word Weighting: Term-Frequency (TF)



Term frequency $tf_{t,d}$

✓ The number of times that the term t occurs in the document d

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	157	73	0	0	0	0
Brutus	4	157	0	1	0	0
Caesar	232	227	0	2	1	1
Calpurnia	0	10	0	0	0	0
Cleopatra	57	0	0	0	0	0
mercy	2	0	3	5	5	1
worser	2	0	1	1	1	0




Text Vectorization (Embedding)

- ① Bag of Words Hypothesis (백 오브 워즈 가정)
- 각 문서 내 단어의 빈도를 고려

Word Weighting: Document Frequency (DF)

- Document frequency df_t
 - ✓ The number of documents in which the term t appears.



	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	157	73	0	0	0	0
Brutus	4	157	0	1	0	0
Caesar	232	227	0	2	1	1
Calpurnia	0	10	0	0	0	0
Cleopatra	57	0	0	0	0	0
mercy	2	0	3	5	5	1
worser	2	0	1	1	1	0

DF	Antony	Brutus	Caesar	Calpurnia	Cleopatra	mercy	worser
	2	3	5	2	1	5	5

$IDF = \log\left(\frac{N}{DF}\right)$ (N:전체문서수, DF:문서빈도)




Text Vectorization (Embedding)

- ① Bag of Words Hypothesis (백 오브 워즈 가정)
- 각 문서 내 단어의 빈도를 고려

Word Weighting: Document Frequency (DF)

- Document frequency df_t
 - ✓ The number of documents in which the term t appears.




	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	157	73	0	0	0	0
Brutus	4	157	0	1	0	0
Caesar	...	...	...	...	...	...



$$IDF = \log\left(\frac{N}{DF}\right) \quad (N: \text{전체 문서 수}, DF: \text{문서 빈도})$$

DF

Antony	2
Brutus	3
Caesar	5
Calpurnia	2
Cleopatra	1
mercy	5
worser	5



IDF

Antony	$\log(6/2)$
Brutus	$\log(6/3)$
Caesar	$\log(6/5)$
Calpurnia	$\log(6/2)$
Cleopatra	$\log(6/1)$
mercy	$\log(6/5)$
worser	$\log(6/5)$

총 문서의 수(N)가 커
질수록 IDF가 기하급
수적으로 커지기 때
문에 로그를 사용

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려

Word Weighting: TF-IDF

$$TF-IDF = TF \times \log\left(\frac{N}{DF}\right) \quad (N: \text{전체 문서 수}, DF: \text{문서 빈도}, TF: \text{단어 빈도})$$

- TF-IDF는 모든 문서에서 자주 등장하는 단어는 중요도가 낮다고 판단하고, 특정 문서에만 자주 등장하는 단어는 중요도가 높다고 판단합니다.
- 빈도와 희소성을 모두 고려
- ✓ Best known weighting scheme in information retrieval
- ✓ Increases with the number of occurrences within a document
- ✓ Increases with the rarity of the term in the collection

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려

Word Weighting: TF-IDF $TF-IDF = TF \times \log\left(\frac{N}{DF}\right)$ (N:전체문서수, DF:문서빈도, TF:단어빈도)

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	157	73	0	0	0	0
Brutus	4	157	0	1	0	0
Caesar	232	227	0	2	1	1
Calpurnia	0	10	0	0	0	0
Cleopatra	57	0	0	0	0	0
mercy	2	0	3	5	5	1
worser	2	0	1	1	1	0



	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	5.25	3.18	0	0	0	0
Brutus	1.21	6.1	0	1	0	0
Caesar	8.59	2.54	0	1.51	0.25	0.35
Calpurnia	0	1.54	0	0	0	0
Cleopatra	2.85	0	0	0	0	0
mercy	1.51	0	1.9	0.12	5.25	0.88
worser	1.37	0	0.11	4.15	0.25	1.95

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려



14위 영어

총 단어수 : 17만개

산업혁명의 본고장의 언어라 온갖 학문부터 심지어는 스포츠에 이르기 까지 영어가 만들어진 곳이 없으며, 그 외 대영제국의 유산들과 미국이라는 초강대국의 힘까지 합쳐져 현재까지 공용어로 쓰이고 있는 언어이다.

영어의 경우 가장 쉬운건 문법이고 가장 어려운 것은 철자법이다.

영어는 추정컨데, 세계에서 철자와 발음 사이의 비일관성과 불일치가 제일 심한 언어다.

실제로 영어권 화자는 처음 보는 단어 혹은 비영어적인 명사 등은 서로 읽는법을 묻곤 한다.

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	5.25	3.18	0	0	0	0
Brutus	1.21	6.1	0	1	0	0
Caesar	8.59	2.54	0	1.51	0.25	0.35
Calpurnia	0	1.54	0	0	0	0
Cleopatra	2.85	0	0	0	0	0
mercy	1.51	0	1.9	0.12	5.25	0.88
worser	1.37	0	0.11	4.15	0.25	1.95

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	5.25	3.18	0	0	0	0
Brutus	1.21	6.1	0	1	0	0
Caesar	8.59	2.54	0	1.51	0.25	0.35
Calpurnia	0	1.54	0	0	0	0
Cleopatra	2.85	0	0	0	0	0
mercy	1.51	0	1.9	0.12	5.25	0.88
worser	1.37	0	0.11	4.15	0.25	1.95

1위 한국어

총 단어수 : 110만개

사전이 무색하다. 사전에 없는 말들이 웬만한 언어 단어들보다 많을 듯 하다.
한글 대신 한자 썼으면 우리말이 중국어나 일본어보다 더 어렵다고 알려졌을 가능성이 크다
합쇼체, 문어 서술식 해라체, 해요체 등 상황 관계에 따라 어미가 완전히 달라진다.

심지어 문어를 구어로 전달할 때에는 둘이 혼용되기도 한다.

그래서 심할 때에는 똑같은 내용의 구어임에도

합쇼체(토론 및 발표)

해요체(비격식적 자리에서 높임말로 전달)

해체(반말 및 친구 사이)

문어체 혼합형('~한다'식 서술 해라체로 된 내용을 읽으면서 상대에게 전달할 때)

이렇게 네 개도 나올 수 있다.

3. 형용사의 다양성(Diversity of adjectives)

YELLOW

노랗다(norata)

샷노랗다
(saennorata)

누랗다(nureota)

늪랗다
(nwireota)

노르스름하다
(noreuseureumhada)

한국어의 이런 다채로운 형용사들을 이해하기 어려워한다고 합니다.
These subtleties between variant adjectives are challenging for foreigners to comprehend.

Text Vectorization (Embedding)

① Bag of Words Hypothesis (백 오브 워즈 가정)

- 각 문서 내 단어의 빈도를 고려

Word Weighting: TF-IDF $TF-IDF = TF \times \log\left(\frac{N}{DF}\right)$ (N:전체문서수, DF:문서빈도, TF:단어빈도)

	Antony and Cleopatra	Julius Caesar	The Tempest	Hamlet	Othello	Macbeth
Antony	5.25	3.18	0	0	0	0
Brutus	1.21	6.1	0	1	0	0
Caesar	8.59	2.54	0	1.51	0.25	0.35
Calpurnia	0	1.54	0	0	0	0
Cleopatra	2.85	0	0	0	0	0
mercy	1.51	0	1.9	0.12	5.25	0.88
worser	1.37	0	0.11	4.15	0.25	1.95

<https://lefty0206.tistory.com/37>

- 한국어 단어 백만개
 - 영어 30만개~ (실제 백만개)
- Terms are axes of the space
 - Documents are points or vectors in this space
 - **Very high dimensional**: need to reduce the number of features!
 - **Sparseness**: most entries are zero

Text Vectorization (Embedding) – Dimension Reduction

- 특징
- 문서는 매우 다양한 Term 즉, 단어 또는 토큰들로 구성
- 전처리 이후 일부 Term만 실제 문서와 관련 있다.
 - 전처리: stop-words removal, stemming, lemmatization, etc

Term Variables	Documents			
Term 1	Document1 1	Document2	...	Document n
Term 2	Data			
⋮				
Term m				



- **Problem 1:** High dimensionality ($N. \text{ terms} \gg N. \text{ documents}$)
- **Problem 2:** Sparseness (Most elements in a term-document matrix are zero)


-> ()

Text Vectorization (Embedding) – Dimension Reduction

- 차원 축소 이유
 - Computational Efficient (저장, 리소스, 계산)
 - 분석 (Classification, Recommender system, etc) 의 질적 향상

- 변수 선택 (Feature selection)

- 변수 추출 (Feature extraction)



중요한 변수를 선택하자!

X_1	X_{12}	X_{19}	X_{29}
...	...	...	...
...	...	...	...

Feature selection

X_1	X_2	X_3	X_4	...	X_p
...	...	...	...	...	...
...	...	...	...	...	...




차원을 축소하자!

Z_1	Z_2	Z_3	Z_4
...	...	...	...
...	...	...	...

Feature extraction

Text Vectorization (Embedding) – Dimension Reduction

차원 축소 기법 범주




Text Vectorization (Embedding)

Term Variables	Documents			
Term 1	Document1 1	Document2	...	Document n
Term 2	Data			
⋮				
Term m				

≈

Term Variables	Documents			
V1	Document1 1	Document2	...	Document n
V2	Data			
⋮				
Vm'				

Text Vectorization (Embedding)



●파이썬 실습

1. Word-to-ID
2. One-Hot-Vector Encoding
3. Bag of Words
4. TF-Idf
5. Dimension Reduction - SVD
6. Down-Stream Task -Document Classification