

[NLP & Text Mining]


RNN

박성호

컴퓨터공학부

텍스트

- 문장은 단어로 구성되며 단어의 순서가 중요
- 감성분석



감성분석

- 기존에는 document term matrix를 구성하여 분류 모델 구축
- 문장의 순서를 고려하지 못함


모든 단어

	나는	잘	못	생겼다	Y
나는 잘 생겼다	1	1	0	1	긍정
나는 못 생겼다	1	0	1	1	부정

	나는	잘	못	생겼지만	너는	생겼다
나는 잘 생겼지만 너는 못 생겼다	1	1	1	1	1	1
너는 잘 생겼지만 나는 못 생겼다	1	1	1	1	1	1


RNN



- 순서를 고려할 수 있는 RNN 모델
- 현재의 정보를 미래에 반영



RNN (Recurrent Neural Networks)


- 순서를 고려할 수 있는 RNN 모델
- 현재의 정보를 미래에 반영





RNN

Recurrent neural networks share the same parameters (U, V, W) across all time steps.




- ❖ 순환 신경망(recurrent neural network, RNN)

$$f(\cdot) = \text{RNN Model}$$

설명 변수(X)

$f(X) = y$ 반응 변수(y)




순차 데이터(sequential data) 모델링을 위한 인공 신경망(neural network) 모델

❖ 순차 데이터(sequential data)

- 변수 간 or 관측치 간 순서가 있는 데이터

구글 트렌드 데이터: 검색어 '한화'



Raw data


시간	검색 건수
T=1	
...	...
T=10	
T=11	
...	...
T=20	
T=21	
...	...
T=30	

Time

❖ 순차 데이터(sequential data)

- 변수 간 or 관측치 간 순서가 있는 데이터

한화 주가 데이터 (2010년 ~ 2018년)





시간	주가
2010.1.1	...
...	...
2010.12. 31	...
...	...
...	...
...	...
2018.1.1	...
...	...
2018.12.31	...

Time

❖ 순차 데이터(sequential data)

- 변수 간 or 관측치 간 순서가 있는 데이터

텍스트 데이터-고객 여행상품 구매 후기 데이터

	리뷰	평점	시간
0	excellent service, great price, an...	5	
1	Comfortable seating with adequate ...	5	
2	I like Flix Bus. It seems like an ...	4	
3	Very good service, clean bus, big,...	4	
4	Great first trip! Great price, cle...	5	
5	It was a very bad trip. The bus de...	1	
6	Im first time by flibus, it's nic...	4	
7	Good way to travel	4	
8	Very fast, very cheap and rather c...	4	
9	Booked bus from Bayreuth in German...	1	

❖ 순차 데이터(sequential data)

- 변수 간 or 관측치 간 순서가 있는 데이터

텍스트 데이터-고객 제품 구매 후기 데이터

리뷰

평점

0	excellent service, great price, an...	5
1	Comfortable seating with adequate ...	5
2	I like Flix Bus. It seems like an ...	4
3	Very good service, clean bus, big,...	4
4	Great first trip! Great price, cle...	5
5	It was a very bad trip. The bus de...	1
6	Im first time by flibus, it's nic...	4
7	Good way to travel	4
8	Very fast, very cheap and rather c...	4
9	Booked bus from Bayreuth in German...	1




Time

	T=1	T=2	...	T=9	T=10	별점
리뷰 ₁	문장 1	문장 2	...	문장 9	문장 10	Y ₁
리뷰 ₂	문장 1	문장 2	...	문장 9	문장 10	Y ₂
...	...	...	...	...	...	...
리뷰 _n	문장 1	문장 2	...	문장 9	문장 10	Y _n

- ❖ 순차 데이터(sequential data)
 - 변수 간 or 관측치 간 순서가 있는 데이터

음성 데이터 - speech recognition



음소 단위



아 나 녕 히 사 게 요

❖ 순차 데이터(sequential data)

- 변수 간 or 관측치 간 순서가 있는 데이터

음소 단위

$$f(\cdot) = \text{RNN Model}$$




❖ 신경망(NN) vs 순환 신경망(RNN)

$f(\cdot)$ = Recurrent Neural Network

반응 변수

은닉층

설명 변수



→ y 를 잘 예측하는 방향으로.


→ 더 좋은 특징을 추출
Hidden state

→ 변수 2개를 조합

❖ 신경망(NN) vs 순환 신경망(RNN)

$f(\cdot)$ = Recurrent Neural Network

시간을 반영하는 것은 Hidden layer, 어떻게?



❖ 신경망(NN) vs 순환 신경망(RNN)


Hidden state를 통해 정보를 전달

$f(\cdot)$ = Recurrent Neural Network

반응 변수

은닉층

설명 변수



❖ 순환 신경망(RNN)


t 시점 x 데이터가 input되었을 때, t 시점 y를 예측

$f(\cdot) = \text{Recurrent Neural Network}$

반응 변수

은닉층


설명 변수



RNN


❖ RNN 구조

One-to-Many




**이미지
캡셔닝**
input: 이미지
output: 문장

Many-to-One




**문장분류
감성 분류**

Many-to-Many



기계번역
seq-to-seq과 관련
문장을 모두 입력 후
번역

Many-to-Many




초기 기계번역
현재는 동영상
데이터 분석

❖ RNN 구조

Many to Many RNN


Task: Time-series Forecasting



❖ RNN 구조

Many to Many RNN


Task: Language modeling



❖ RNN 구조

Many to Many RNN

Task: Machine Translation




❖ RNN 구조

Many to Many RNN

(한국어) 안녕하세요 조 박사님, 한화입니다.

Task: Machine Translation




(English) Hello Dr. Cho, This is Hanhwa.

❖ RNN 구조


One to Many RNN

Task: Image Captioning



❖ RNN 구조

Many to One RNN




나는	잘	못	생겼	다
1	0	0	0	0


RNN

❖ RNN 구조


Many to One RNN



Many to One RNN



- ❖ RNN: t 시점까지 전해온 정보와 t시점 데이터를 가지고 t 시점 Y를 예측
 - ❖ t 시점 이전 정보 반영 $\rightarrow W_{hh}$
 - ❖ t 시점 데이터 반영 $\rightarrow W_{xh}$
 - ❖ t 시점의 y를 예측 $\rightarrow W_{hy}$




학습의 대상(parameters): (W_{xh} , W_{hh} , W_{hy})

- ❖ RNN: t 시점까지 전해온 정보와 t시점 데이터를 가지고 t 시점 Y를 예측
 - ❖ t 시점 이전 정보 반영 $\rightarrow W_{hh}$
 - ❖ t 시점 데이터 반영 $\rightarrow W_{xh}$
 - ❖ t 시점의 y를 예측 $\rightarrow W_{hy}$

반응 변수

은닉층


설명 변수



학습의 대상: (W_{xh} , W_{hh} , W_{hy})


❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})

주목할 것: (W_{xh} , W_{hh} , W_{hy})에 t 가 없네? → 매 시점 같다!



❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})

주목할 것: (W_{xh} , W_{hh} , W_{hy})에 t 가 없네? → 매 시점 같다!



$$y_t = g(W_{hy}h_t)$$

... $g(\cdot) = \text{softmax}$


$$h_t = f_W(h_{t-1}, x_t)$$

... $f(\cdot) = \tanh$

$$h_t = f(W_{hh}h_{t-1} + W_{xh}x_t)$$


새로운 Hidden state 이전 Hidden state t 시점 input 데이터

❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})



❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})

- $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
- $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
- $L_t = y_t$ 와 $\hat{y}_t$ 차이




Many to Many RNN

1. Loss 계산하기: Forward propagation

❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})

- $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
- $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
- $L_t = y_t$ 와 $\hat{y}_t$ 차이




One to Many RNN

1. Loss 계산하기: Forward propagation

❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})

- $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
- $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
- $L_t = y_t$ 와 $\hat{y}_t$ 차이



Many to One RNN


1. Loss 계산하기: Forward propagation

2. Gradient 계산하기: Backward propagation

❖ Backward Propagation Trough Time (BPTT) in RNN


- 학습 대상 (W_{xh} , W_{hh} , W_{hy} , parameters)

시간 흐름에 따라 파라미터 업데이트



RNN

- ❖ Backward Propagation Trough Time (BPTT) in RNN
- ❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})
 - $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
 - $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
 - $L_t = y_t$ 와 $\hat{y}_t$ 차이



RNN

❖ Backward Propagation Trough Time (BPTT) in RNN

❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})


- $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
- $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
- $L_t = y_t$ 와 $\hat{y}_t$ 차이

$$\frac{\partial \text{Loss}}{\partial W_{hy}} = \frac{\partial L_t}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial W_{hy}h_t} \times \frac{\partial W_{hy}h_t}{\partial W_{hy}}$$

반응 변수

RNN

설명 변수



RNN

❖ Backward Propagation Trough Time (BPTT) in RNN

❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})


- $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
- $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
- $L_t = y_t$ 와 $\hat{y}_t$ 차이

$$\frac{\partial \text{Loss}}{\partial W_{hy}} = \frac{\partial L_t}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial W_{hy}h_t} \times \frac{\partial W_{hy}h_t}{\partial W_{hy}}$$

반응 변수


RNN

설명 변수



RNN

- ❖ Backward Propagation Trough Time (BPTT) in RNN
- ❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})
 - $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
 - $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
 - $L_t = y_t$ 와 $\hat{y}_t$ 차이



시점 4 으로부터 전해진 영향 고려

$$\frac{\partial \text{Loss}}{\partial W_{hh}} = \frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_4} \times \frac{\partial h_4}{\partial W_{hh}} +$$

시점 3 으로부터 전해진 영향 고려

$$\frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_4} \times \frac{\partial h_4}{\partial h_3} \times \frac{\partial h_3}{\partial W_{hh}} +$$


시점 2 으로부터 전해진 영향 고려

$$\frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial y}{\partial h_4} \times \frac{\partial h_4}{\partial h_3} \times \frac{\partial h_3}{\partial h_2} \times \frac{\partial h_2}{\partial W_{hh}} + \frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_4} \times \frac{\partial h_4}{\partial h_3} \times \frac{\partial h_3}{\partial h_2} \times \frac{\partial h_2}{\partial h_1} \times \frac{\partial h_1}{\partial W_{hh}}$$

시점 1 으로부터 전해진 영향 고려

RNN

- ❖ Backward Propagation Through Time (BPTT) in RNN
- ❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})
 - $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
 - $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
 - $L_t = y_t$ 와 $\hat{y}_t$ 차이



시점 4으로부터 전해진 영향 고려

$$\frac{\partial \text{Loss}}{\partial W_{xh}} = \frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_4} \times \frac{\partial h_4}{\partial W_{xh}} +$$

시점 3으로부터 전해진 영향 고려

$$\frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_4} \times \frac{\partial h_4}{\partial h_3} \times \frac{\partial h_3}{\partial W_{xh}} +$$


시점 2으로부터 전해진 영향 고려

$$\frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_4} \times \frac{\partial h_4}{\partial h_3} \times \frac{\partial h_3}{\partial h_2} \times \frac{\partial h_2}{\partial W_{xh}} +$$

시점 1으로부터 전해진 영향 고려

$$\frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_4} \times \frac{\partial h_4}{\partial h_3} \times \frac{\partial h_3}{\partial h_2} \times \frac{\partial h_2}{\partial h_1} \times \frac{\partial h_1}{\partial W_{xh}}$$

- ❖ Backward Propagation Through Time (BPTT) in RNN
- ❖ RNN Parameter(학습 대상) : (W_{xh} , W_{hh} , W_{hy})
 - $h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t) \rightarrow$ 각 weight 곱하고 더한 값을 -1~1사이로 정규화 한 hidden state 생성
 - $y_t = \text{softmax}(W_{hy}h_t) \rightarrow$ Hidden state에 weight 곱한 값을 0~1사이로 정규화 한 output 생성
 - $L_t = y_t$ 와 $\hat{y}_t$ 차이



$$\frac{\partial \text{Loss}}{\partial W_{hy}} = \frac{\partial L_t}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial W_{hy} h_t} \times \frac{\partial W_{hy} h_t}{\partial W_{hy}}$$

$$\frac{\partial \text{Loss}}{\partial W_{hh}} = \sum_{k=0}^t \left(\frac{\partial L}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_k} \times \frac{\partial h_k}{\partial W_{hh}} \right)$$

$$\frac{\partial \text{Loss}}{\partial W_{xh}} = \sum_{k=0}^t \left(\frac{\partial L}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial h_t} \times \frac{\partial h_t}{\partial h_k} \times \frac{\partial h_k}{\partial W_{xh}} \right)$$

회귀 문제: Loss function(MSE) = $\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$

분류 문제: Loss function(cross entropy) = $\sum_{c=1}^M y_{o,c} \log(p_{o,c})$

❖ Parameter update in RNN

- 학습 대상 (W_{xh} , W_{hh} , W_{hy} , parameters) $\rightarrow$ BPTT를 통해 Gradient(기여도) 계산
- 학습률 (η , learning rate): 기여도를 얼마나 반영할 것인지 결정(예: $\eta=0.01$)

① A: W_{hy} 의 gradient(기여도) = $\frac{\partial L_t}{\partial W_{hy}}$


$\rightarrow W_{hy}^{new} = W_{hy}^{old} - \eta * A$

② B: W_{hh} 의 gradient(기여도) = $\frac{\partial L_t}{\partial W_{hh}}$


$\rightarrow W_{hh}^{new} = W_{hh}^{old} - \eta * B$

③ C: W_{xh} 의 gradient(기여도) = $\frac{\partial L_t}{\partial W_{xh}}$

$\rightarrow W_{xh}^{new} = W_{xh}^{old} - \eta * C$



❖ RNN 학습 예제: Many to Many RNN for Language modeling




e l l o 를 Output 하도록 학습하자

RNN

H e l l 이라는 문자를 Input했을 때

❖ RNN 학습 예제: Many to Many RNN for Language modeling

target chars: "e" "l" "l" "o"



1. Loss 계산하기: Forward propagation

Hidden size=4 # output from RNN

Batch_size = 1 # one sentence

Input_dim = 4 # one-hot size


Sequence length = 4 # len(hell) == 4

$$y_t = W_{hy} h_t$$

$$h_t = \tanh(W_{hh} h_{t-1} + W_{xh} x_t)$$

$$x_1 = [1 \ 0 \ 0 \ 0]$$

❖ RNN 학습 예제: Many to Many RNN for Language modeling



1. Loss 계산하기: Forward propagation

Hidden size=4 # output from RNN

Batch_size = 1 # one sentence

Input_dim = 4 # one-hot size


Sequence length = 4 # len(hell) == 4

$$y_t = W_{hy} h_t$$

$$h_t = \tanh(W_{hh} h_{t-1} + W_{xh} x_t)$$

$$x_1 = [1 \ 0 \ 0 \ 0]$$

❖ RNN 학습 예제: Many to Many RNN for Language modeling



1. Loss 계산하기: Forward propagation

Hidden size=4 # output from RNN

Batch_size = 1 # one sentence

Input_dim = 4 # one-hot size


Sequence length = 4 # len(hell) == 4

$$y_t = W_{hy} h_t$$

$$h_t = \tanh(W_{hh} h_{t-1} + W_{xh} x_t)$$

$$x_1 = [1 \ 0 \ 0 \ 0]$$

❖ RNN 학습 예제: Many to Many RNN for Language modeling



1. Loss 계산하기: Forward propagation

Hidden size=4 # output from RNN

Batch_size = 1 # one sentence

Input_dim = 4 # one-hot size


Sequence length = 4 # len(hell) == 4

$$y_t = W_{hy}h_t$$

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$x_1 = [1 \quad 0 \quad 0 \quad 0]$$

❖ RNN 학습 예제: Many to Many RNN for Language modeling



1. Loss 계산하기: Forward propagation

Hidden size=4 # output from RNN

Batch_size = 1 # one sentence

Input_dim = 4 # one-hot size

Sequence length = 4 # len(hell) == 4


$$y_t = W_{hy} h_t$$

$$h_t = \tanh(W_{hh} h_{t-1} + W_{xh} x_t)$$

$$x_2 = [0 \quad 1 \quad 0 \quad 0]$$

RNN

❖ RNN 학습 예제: Many to Many RNN for Language modeling



1. Loss 계산하기: Forward propagation

Hidden size=4 # output from RNN

Batch_size = 1 # one sentence

Input_dim = 4 # one-hot size


Sequence length = 4 # len(hell) == 4

$$y_t = W_{hy}h_t$$

$$h_t = \tanh(W_{hh}h_{t-1} + W_{xh}x_t)$$

$$x_2 = [0 \quad 1 \quad 0 \quad 0]$$

❖ RNN 학습 예제: Many to Many RNN for Language modeling



1. Loss 계산하기: Forward propagation

Hidden size=4 # output from RNN

Batch_size = 1 # one sentence

Input_dim = 4 # one-hot size

Sequence length = 4 # len(hell) == 4



$$y_t = W_{hy} h_t$$

$$h_t = \tanh(W_{hh} h_{t-1} + W_{xh} x_t)$$

$$x_4 = [0 \ 0 \ 0 \ 1]$$

RNN

❖ RNN 학습 예제: Many to Many RNN for Language modeling




- <https://cs224d.stanford.edu/>

RNN 한계

❖ RNN은 긴 시퀀스를 모델링하기 어려움

- Vanishing gradient



$$h_1 = \tanh(Ux_1 + Wh_0)$$


$$h_2 = \tanh(Ux_2 + Wh_1) \quad \dots$$

$$h_t = \tanh(Ux_t + Wh_{t-1})$$

<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

RNN 한계

- ❖ RNN은 긴 시퀀스를 모델링하기 어려움
 - Vanishing gradient



$$h_t = \tanh(Ux_t + Wh_{t-1}) \quad \text{“tanh 너무 많아!!”}$$
$$= \tanh(Ux_t + W(\tanh(Ux_{t-1} + W(\tanh(Ux_{t-2} + W(\tanh(\dots)))) \dots)))$$

- ❖ 길이가 긴 sequence 의 경우 Gradient Vanishing / Exploding 문제 발생
 - Vanishing gradient: 다른 모델 사용 → (LSTM, GRU 등)
 - Exploding gradient: Clip gradient(기여도에 한계선 부여)

Long-Term Dependency problem


h_t 가 의존하는 h_{t-1} 이 의존하는 h_{t-2} 가 의존하는 ...

$$\begin{aligned}
 & \text{시점 4 으로부터 전해진 영향 고려} & \text{시점 3 으로부터 전해진 영향 고려} \\
 \frac{\partial \text{Loss}}{\partial \mathbf{W}_{hh}} = & \frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial \mathbf{h}_4} \times \frac{\partial \mathbf{h}_4}{\partial \mathbf{W}_{hh}} + & \frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial \mathbf{h}_4} \times \frac{\partial \mathbf{h}_4}{\partial \mathbf{h}_3} \times \frac{\partial \mathbf{h}_3}{\partial \mathbf{W}_{hh}} + \\
 & \text{시점 2 으로부터 전해진 영향 고려} & \text{시점 1 으로부터 전해진 영향 고려} \\
 \frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial y}{\partial \mathbf{h}_4} \times \frac{\partial \mathbf{h}_4}{\partial \mathbf{h}_3} \times \frac{\partial \mathbf{h}_3}{\partial \mathbf{h}_2} \times \frac{\partial \mathbf{h}_2}{\partial \mathbf{W}_{hh}} + & \frac{\partial \text{Loss}}{\partial \hat{y}_t} \times \frac{\partial \hat{y}_t}{\partial \mathbf{h}_4} \times \frac{\partial \mathbf{h}_4}{\partial \mathbf{h}_3} \times \frac{\partial \mathbf{h}_3}{\partial \mathbf{h}_2} \times \frac{\partial \mathbf{h}_2}{\partial \mathbf{h}_1} \times \frac{\partial \mathbf{h}_1}{\partial \mathbf{W}_{hh}}
 \end{aligned}$$

RNN 한계

❖ RNN은 긴 시퀀스를 모델링하기 어려움

- Vanishing gradient: 긴 시퀀스의 경우, gradient가 0으로 수렴하는 문제 발생
 - = Back-propagation 수행 안됨
 - = 모델 학습 안됨!



$$\tanh(x)$$
$$\frac{d}{dx}\tanh(x)$$

❖ RNN은 긴 시퀀스를 모델링하기 어려움

- Vanishing gradient: 긴 시퀀스의 경우, gradient가 0으로 수렴하는 문제 발생
= 장기 의존성 문제(Long term dependency)

안녕하세요, 저는 데이터 마이닝 연구실 이지윤입니다.

제가 제일 좋아하는 음식은 계란말이랑 만두고,

... T M I ...

데이터 마이닝


앞으로도 ----- 과 관련된 공부를 열심히 할 계획입니다.

- ❖ RNN은 긴 시퀀스를 모델링하기 어려움
 - Vanishing gradient: 긴 시퀀스의 경우, gradient가 0으로 수렴하는 문제 발생
 - 관련 정보와 그 정보를 사용하는 시점 사이 거리가 길어질수록 RNN 학습능력 저하




LSTM (Long-Shor Term Memory)

❖ Standard RNN



❖ Standard RNN + Cell state

- 오랜 state가 경과하더라도 정보가 유실되지 않도록 중요한 정보 흘러가는 컨베이어 벨트
- Cell state 에서 잊어버릴 건 잊어버리고, 새로 추가할 건 추가하자
- Cell state 에서 Hidden state 정보를 얼마나 가져갈 지 정해주자



❖ advanced RNN: LSTM

- 오랜 state가 경과하더라도 정보가 유실되지 않도록 중요한 정보 흘려가는 컨베이어 벨트
- Cell state 에서 잊어버릴 건 잊어버리고, 새로 추가할 건 추가하자 → Forget & Input gate
- Cell state 에서 Hidden state 정보로 얼마나 가져갈 지 정해주자 → Output gate



❖ Gate

- 문, A gate or gateway is a point of entry to a space which is enclosed by walls. Gates may prevent or control the entry or exit of individuals. (Wikipedia)
출입을 막거나 통제
- 계수를 곱해주는 연산을 통해 제어 (element wise coefficient multiplication)
- 계수를 0~1사이 값으로 바꾸어 얼마나 잊어버리고, 추가할 것인지 정의

“가중치”

LSTM network

❖ Gate

- 계수를 곱해주는 연산을 통해 제어
- 계수를 0~1사이 값을 곱해서 얼마나 잊어버리고, 추가할 것인지 정의

현재: t

-0.2	0.1	0.5	0.7	0.9	-0.3	-1.1	2.0	0.6	0.7
------	-----	-----	-----	-----	------	------	-----	-----	-----

C_{t-1}

LSTM network

❖ Gate

- 계수를 곱해주는 연산을 통해 제어
- 계수를 0~1사이 값을 곱해서 얼마나 잊어버리고, 추가할 것인지 정의

현재: t

0	0.2	0.99	0.1	0.98	0.2	0.1	0.90	0.4	0.1
-0.2	0.1	0.5	0.7	0.9	-0.3	-1.1	2.0	0.6	0.7

$G(gate)$

C_{t-1}

LSTM network

❖ Gate

- 계수를 곱해주는 연산을 통해 제어
- 계수를 0~1사이 값을 곱해서 얼마나 잊어버리고, 추가할 것인지 정의

현재: t

-0.06	0.02	0.495	0.07	0.882	-0.06	-0.11	1.8	0.24	0.07
0	0.2	0.99	0.1	0.98	0.2	0.1	0.90	0.4	0.1
-0.2	0.1	0.5	0.7	0.9	-0.3	-1.1	2.0	0.6	0.7

element wise
coefficient multiplication

$G C_{t-1}$

$G (gate)$

C_{t-1}

LSTM network

❖ Gate

- 계수를 곱해주는 연산을 통해 제어
- 계수를 0~1사이 값을 곱해서 얼마나 잊어버리고, 추가할 것인지 정의
- **목적에 따라서 학습하는 linear transformation이 다름**

$$g_t = \underset{0 \sim 1}{\sigma} \overset{\text{Linear transformation}}{(W_g \cdot \underset{\text{input vector}}{v_{input}})}$$


0	0.2	0.99	0.1	0.98	0.2	0.1	0.90	0.4	0.1
---	-----	------	-----	------	-----	-----	------	-----	-----

G (gate)

RNN

LSTM network

❖ Gate


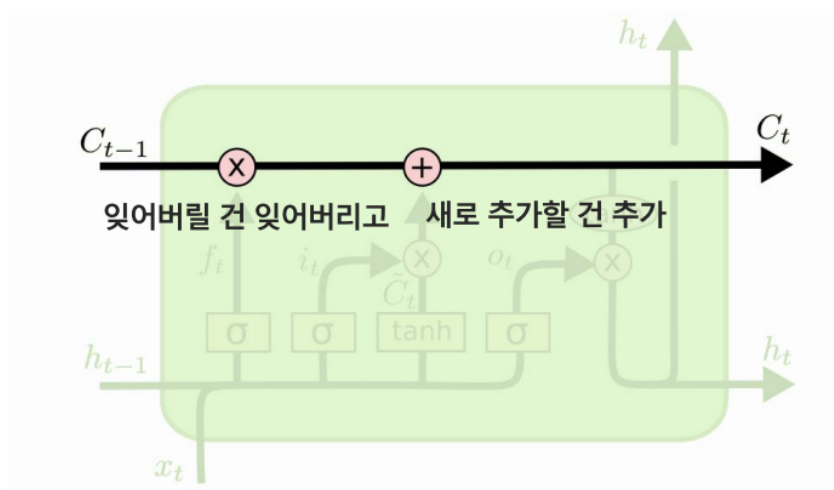


<https://github.com/heartcore98/Standalone-DeepLearning>

LSTM network

❖ Cell state


- 오랜 state가 경과하더라도 정보가 유실되지 않도록 중요한 정보 흘러가는 컨베이어 벨트
- 잊어버릴 건 잊어버리고, 새로 추가할 건 추가하자



LSTM network


❖ Forget gate: 잊을 것은 잊자

- Forget gate(f_t): 과거의 cell state 정보 c_{t-1} 을 얼마나 받아 들일지 결정



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

[] : concatenate
 . : point wise operation



<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>


LSTM network

❖ Input gate: 추가할 것은 추가하자

- **Input gate(i_t)**: cell state C_t 에 과거 시점의 입력과 출력을 얼마나 반영할 것인지 결정
- **Candidate value($\tilde{C}_t$)**: 과거 시점의 출력(h_{t-1})과 현재 입력 (x_t)정보를 이용해 현재 시점의 C_t 업데이트


어느 값을 얼마나 업데이트 할지

어느 값 후보 (Cell state 후보들)



$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$




LSTM network

❖ C_t : Cell state update

- 잊을 것은 잊고,
- 추가할 것은 추가하자.


: Forget gate (f_t)

: Input gate (i_t)



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

1	1	1	1	1	1	1	1	1	$f_t(\text{forget gate})$
-0.2	0.1	0.5	0.7	0.9	-0.3	-1.1	2.0	0.6	C_{t-1}




RNN

LSTM network


❖ C_t : Cell state update

- 잊을 것은 잊고, : Forget gate (f_t)
- 추가할 것은 추가하자. : Input gate (i_t)



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

0	0	0	0	0	0	0	0	0	0	$f_t(\text{forget gate})$
-0.2	0.1	0.5	0.7	0.9	-0.3	-1.1	2.0	0.6	0.7	C_{t-1}



<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

RNN


LSTM network

❖ C_t : Cell state update

- 잊을 것은 잊고,
- 추가할 것은 추가하자.


: Forget gate (f_t)

: Input gate (i_t)



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

0	0.2	0.9	0.1	1	0.2	0.1	0.9	0.4	0.1	$f_t(\text{forget gate})$
-0.2	0.1	0.5	0.7	0.9	-0.3	-1.1	2.0	0.6	0.7	C_{t-1}



<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>


LSTM network

❖ C_t : Cell state update

- 잊을 것은 잊고,
- 추가할 것은 추가하자.


: Forget gate (f_t)

: Input gate (i_t)



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

0.1	0	0.8	0.2	0.8	0	1	0.9	0.2	0.4	$i_t(\text{input gate})$
-0.1	0.3	0.6	0.2	0.9	-0.1	0.4	2.1	0.6	0.9	$\tilde{C}_t$




<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

LSTM network


❖ h_t : Hidden state update: 잊을 것 잊고, 추가할 것 추가한 hidden state 전달

- Output gate(o_t): Cell state에서 Hidden state로 넘겨줄 것은 넘겨주자
- 과거 시점의 출력(h_{t-1})과 현재 입력 (x_t)정보와 C_t 를 조합하여 출력 h_t 생산



LSTM network

- ❖ advanced RNN: **LSTM**
 - C_t , h_t 두 정보를 모두 제공



LSTM network

❖ advanced RNN: LSTM

- Work flow



1. Cell state C_{t-1} 에서 지울 것은 지운다.
2. 새로운 Cell state 후보 $\tilde{C}_t$ 에 새로운 input으로 중요한 정보를 넣는다.
3. 추가할 거 추가해서 새로운 Cell state C_t 를 만든다.
4. Cell state C_t 를 적절히 가공하여 t에서의 hidden state h_t 를 만든다.
5. Cell state C_t 과 hidden state h_t 를 다음 t+1시점으로 전달한다.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$


$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

LSTM 패턴 변화

❖ Peephole connections

- **Peephole connections**는 LSTM(Long Short-Term Memory)의 변형 중 하나로, **cell state**의 정보를 각 게이트에 추가적으로 전달하는 메커니즘
- **더 정교한 게이트 조절**: 게이트가 cell state의 정보를 직접 활용하므로, 정보의 흐름을 더 잘 제어
- **복잡한 의존성 학습**: 특히, time step 간 복잡한 의존성을 다룰 때 더 나은 성능
- **특정 문제에서 성능 개선**: Speech recognition, sequence modeling 등에서 peephole connections이 성능을 향상



$$f_t = \sigma(W_f \cdot [C_{t-1}, h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [C_{t-1}, h_{t-1}, x_t] + b_i)$$

$$o_t = \sigma(W_o \cdot [C_t, h_{t-1}, x_t] + b_o)$$

LSTM 패턴 변화

❖ GRU(Gated Recurrent Unit)

<http://www.kyunghyuncho.me/>



조경현 교수




New York University, Facebook AI Research



LSTM 패턴 변화

❖ GRU(Gated Recurrent Unit)

- LSTM의 gate 일부를 생략한 형태
- Cell state(C_t)가 다시 없어진 형태
- Reset gate(r_t)와 Update gate(z_t)로 구성



Neural Network Layer
Pointwise Operation


Vector Transfer
Concatenate

Copy
Sigmoid(logistic)

LSTM 패턴 변화

❖ GRU(Gated Recurrent Unit)

- Reset gate(r_t): 잊을 것은 잊자 (~forget gate)
- 임시 output $\tilde{h}_t$ 를 생성



Reset gate(r_t)


$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

LSTM 패턴 변화

❖ GRU(Gated Recurrent Unit)

- Update gate(z_t): $\tilde{h}_t$ 와 h_{t-1} 간의 비중을 결정
- 최종 output h_t 를 생성



Reset gate(r_t)

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

Update gate(z_t)


$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

LSTM 패턴 변화

❖ GRU(Gated Recurrent Unit)

- Update gate(z_t): $\tilde{h}_t$ 와 h_{t-1} 간의 비중을 결정
- 최종 output h_t 를 생성



Reset gate(r_t)

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

Update gate(z_t) = Forget gate + input gate

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$


$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

잊을 것은 잊고

추가할 것은 추가하자

RNN

- ❖ RNN은 Vanishing gradient(long-term dependency)문제 발생
- ❖ LSTM은 Cell state를 만들어서 non-linear 우회하도록
- ❖ GRU는 LSTM구조를 보다 간결화



<https://colah.github.io/posts/2015-08-Understanding-LSTMs/>

What else is there?

정답은 없는데 가이드라인을 줄게

1. 천리길도 한걸음 부터! 길이가 짧은 시퀀스에 첫번째 시도 → RNN 사용
2. 길이가 길어, 데이터가 많아? → LSTM 사용
3. 길이가 길어, 데이터가 많아, 시간이 없어? → GRU 사용
4. 나머지는 경험상 논외, 주목해 볼 테크닉은 Attention!