

[NLP & Text Mining]

Introduction to Text Analytics

박성호

컴퓨터공학부

한국공학대학교


학습 목표

1. 빅데이터 시대
2. 텍스트 분석이란?
3. 비정형/정형 데이터란
4. 텍스트 분석의 프로세스

Big Data

❖ 빅데이터의 시대!

제타바이트(Zettabyte, **ZB**)는 10^{21}




© Statista 2021

[Additional Information](#)

[Show source](#)

Big Data

❖ Why Big Data Keeps Getting Bigger




per minute

- Netflix users stream 694,444 hours of video
- Instagram users post 277,777 stories
- Youtube users watch 4,500,000 videos
- Twitter users send 511,200 tweets
- Skype users make 231,840 calls
-

What Kind of Data ?


- ❖ Structured and Unstructured
- ❖ Structured data is highly organized
- ❖ relational databases and spreadsheets (키와 값으로 구성된 테이블)
- ❖ 컬럼을 통해 데이터의 의미를 쉽게 파악




What Kind of Data ?

- ❖ Structured and **Unstructured**
- ❖ **cannot** be processed and analyzed using conventional tools and method
- ❖ 데이터의 의미를 쉽게 파악 x

Video



Signal (음파, 진동)



Text

Mode-wise Tensor Decompositions: Multi-dimensional Generalizations of CUR Decompositions

HanQin Cai

Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

HQCAI@MATH.UCLA.EDU

Keaton Hamm

Department of Mathematics
University of Texas at Arlington
Arlington, TX 76019, USA

KEATON.HAMM@UTA.EDU

Longxiu Huang

Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

HUANGL3@MATH.UCLA.EDU

Deanna Needell

Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

DEANNA@MATH.UCLA.EDU

Editor: Michael Mahoney


Abstract

Low rank tensor approximation is a fundamental tool in modern machine learning and data science. In this paper, we study the characterization, perturbation analysis, and an efficient sampling strategy for two primary tensor CUR approximations, namely Chidori and Fiber CUR. We characterize exact tensor CUR decompositions for low multilinear rank tensors. We also present theoretical error bounds of the tensor CUR approximations when (adversarial or Gaussian) noise appears. Moreover, we show that low cost uniform sampling is sufficient for tensor CUR approximations if the tensor has an incoherent structure. Empirical performance evaluations, with both synthetic and real-world datasets, establish the speed advantage of the tensor CUR approximations over other state-of-the-art low multilinear rank tensor approximations.

Keywords: tensor decomposition, low-rank tensor approximation, CUR decomposition, randomized linear algebra, hyperspectral image compression

What Kind of Data ?



❖ Structured and Unstructured



What Kind of Data ?

- ❖ Unstructured data is growing **twice as fast as** structured data in the past decade.

Data growth
Driven by unstructured data



The number of papers we downloaded from the arXiv

All of the papers available in the “artificial intelligence” section through November 18, 2018



AI papers in arXi

단어 빈도 분석 + Visualization

Machine Learning >>> Knowledge-based system

Change in mentions per 1,000 words for the top 100 words




Chart: MIT Technology Review • Source: [arXiv.org](https://arxiv.org) • Created with Datawrapper

Word frequency per 1,000 words




Chart: MIT Technology Review • Source: [arXiv.org](https://arxiv.org)


AI papers in arXi

단어 빈도 분석 + Visualization

Deep Learning!!!!

Percentage of papers that mention each method

neural networks bayesian networks markov methods evolutionary algorithms
support vector machines




AI papers in arXi

단어 빈도 분석 + Visualization

Machine Learning!!!!, Reinforcement Learning??

Share of papers that mention it compared to any type of machine learning



Why Text Analytics ?

"AI 대 변호사: 궁극의 대결"

과제: 다섯 개의 비밀유지계약서(NDA)에서 문제점을 찾아내기"

THE EXPERIMENT

In this experiment, 20 US-trained lawyers with decades of contract review experience were pitted against the LawGeex Artificial Intelligence solution.

5 NON-DISCLOSURE AGREEMENTS

NDA's are the most ubiquitous business contracts, creating a legal obligation to confidentiality. Reviewing NDA's is a daily legal task.



THE LAWYERS



The lawyer participants were made up of law firm associates, sole practitioners, in-house lawyers, and General Counsel.

THE AI



The LawGeex AI was trained on tens of thousands of NDAs, using machine-learning and deep learning technologies.

- 실력 있는 변호사 20명 (Goldman Sachs, Cisco, etc...)
- 4시간
- 5건 계약문서

20 LAWYERS

4 HOURS



The lawyers were given 4 hours to review 5 NDAs. These agreements were never processed by the LawGeex Artificial Intelligence.




20 lawyers with experience reviewing contracts at companies including Goldman Sachs and Cisco, and global law firms including Alston & Bird and K&L Gates.

Why Text Analytics ?

"AI 대 변호사: 궁극의 대결

과제: 다섯 개의 비밀유지계약서(NDA)에서 문제점을 찾아내기"

- 실력 있는 변호사 20명 (Goldman Sachs, Cisco, etc...)
- 4시간
- 5건 계약문서





Why Text Analytics ?

"AI 대 변호사: 궁극의 대결"

과제: 다섯 개의 비밀유지계약서(NDA)에서 문제점을 찾아내기"

- 실력 있는 변호사 20명 (Goldman Sachs, Cisco, etc...)
- 4시간
- 5건 계약문서

• AI vs. Lawyers: The ultimate showdown




Why Text Analytics ?

❖ 정확도, 실력, 시간 모두 AI 승리

- AI vs. Lawyers: The ultimate showdown



<https://www.lawgeex.com/resources/AlvsLawyer/>




Why Text Analytics ?

- ❖ 텍스트로부터 가치 있는 정보 추출
- ❖ 다양한 학문이 융합(Information Retrieval, 기계학습, 통계학, 언어학)

Text Mining (Def. Wikipedia)

Text mining, also known as intelligent text analysis, text data mining or knowledge-discovery in text (KDT), refers generally to the process of extracting interesting and non-trivial information and knowledge from unstructured text. Text mining is a young interdisciplinary field which draws on information retrieval, data mining, machine learning, statistics and computational linguistics. As most information (over 80%) is stored as text, text mining is believed to have a high commercial potential value.



Why Text Analytics ?

1. NLP(자연어 처리)

- **정의:** NLP는 컴퓨터가 인간의 언어를 이해하고, 해석하고, 생성할 수 있도록 하는 기술입니다. 텍스트나 음성 데이터에서 의미를 추출하여, 사람의 언어를 기계가 처리할 수 있는 형식으로 변환하는 것을 목표로 합니다.
- **목적:** 언어의 구조적 이해, 의미 분석, 대화 시스템 구축, 텍스트 분류 등 다양한 언어적 작업에 초점을 맞춥니다.
- **활용:**
 - 감정 분석(Sentiment Analysis)
 - 자동 번역(Translation)
 - 챗봇(Chatbots)
 - 음성 인식(Speech Recognition)
 - 문장 생성(Automatic Text Generation)

2. Text Mining(텍스트 마이닝)

- **정의:** 텍스트 마이닝은 비정형 텍스트 데이터에서 유용한 정보를 추출하는 데이터 마이닝 기법의 일종입니다. 텍스트 데이터를 통계적 방법으로 분석하여 패턴을 찾아내고, 이를 통해 새로운 지식을 발견하는 것을 목표로 합니다.
- **목적:** 대량의 텍스트 데이터에서 의미 있는 패턴을 찾아내거나, 데이터를 요약하고 분류하는 데 중점을 둡니다.
- **활용:**
 - 문서 분류(Document Classification)
 - 정보 검색(Information Retrieval)
 - 텍스트 요약(Text Summarization)
 - 트렌드 분석(Trend Analysis)


차이점

- **NLP**는 인간 언어를 이해하고 처리하는 기술에 더 집중되어 있으며, 문법적, 언어적 구조를 분석하는데 중점을 둡니다.
- **Text Mining**은 주로 대량의 텍스트에서 의미 있는 패턴과 통계를 찾아내는 데이터 분석 기법으로, NLP 기술을 활용할 수 있지만 더 넓은 범위의 데이터 분석에 중점을 둡니다.

NLP는 Text Mining의 하위 기술로 사용될 수 있으며, Text Mining은 NLP를 포함한 다양한 기법들을 사용해 텍스트 데이터를 분석합니다.

그래서 두 개념이 비슷해 보이지만, **NLP는 언어 처리 자체에 집중하고, Text Mining은 그 언어 데이터를 분석하여 정보를 추출하는 데 더 초점이 맞춰져 있습니다.**

AI & ML & Deep Learning



인공지능? 머신러닝?

$$f(x)$$

Input




Output

(사진: <http://koreadailytimes.com/>)

인공지능은 입력값을 넣어주면 출력값이 나오는 함수 시스템


기계학습 (Machine Learning)?

- Definition: an application of AI that provides systems the ability to automatically learn and improve from **experience (데이터)** without **being explicitly programmed (특정 상황에 대응하는 룰)**




기계학습 범주

- Deep learning은 machine learning에 속하는 방법론 중 하나
- 본 강의에서는 supervised learning의 관점에서 deep learning을 다룸



지도학습 데이터



독립변수 (Independent variable)

예측변수 (Explanatory variable)

인풋변수 (Input variable)

종속변수 (Dependent variable)

반응변수 (Response variable)

아웃풋변수 (Output variable)

지도학습 예시 (회귀 Regression, 문제)

중고차 데이터

x

y

모델	주행거리	마력	용량	가격
TOYOTA Corolla 2.0 D4D HATCHB TERRA 2/3-Doors	46,986	90	2,000	13,500
TOYOTA Corolla 1800 T SPORT VVT I 2/3-Doors	19,700	192	1,800	21,500
TOYOTA Corolla 1.9 D HATCHB TERRA 2/3-Doors	71,138	69	1,900	12,950
TOYOTA Corolla 1.8 VVTL-i T-Sport 3-Drs 2/3-Doors	31,461	192	1,800	20,950
TOYOTA Corolla 1.8 16V VVTLI 3DR T SPORT BNS 2/3-Doors	43,610	192	1,800	19,950
TOYOTA Corolla 1.6 VVTI Linea Terra Comfort 2/3-Doors	21,716	110	1,600	17,950
TOYOTA Corolla 1.6 16v LSOL 2/3-Doors	25,563	110	1,600	16,750
TOYOTA Corolla 1.6 16V VVT I 3DR TERRA 2/3-Doors	64,359	110	1,600	16,950
TOYOTA Corolla 1.6 16V VVT I 3DR SOL AUT4 2/3-Doors	43,905	110	1,600	16,950
TOYOTA Corolla 1.6 16V VVT I 3DR SOL 2/3-Doors	56,349	110	1,600	15,950
TOYOTA Corolla 1.4 VVTI Linea Terra 2/3-Doors	9,750	97	1,400	12,950
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	27,500	97	1,400	14,750
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	49,059	97	1,400	13,950
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	44,068	97	1,400	16,750
TOYOTA Corolla 1.4 16V VVT I 3DR 2/3-Doors	46,961	97	1,400	13,950
TOYOTA Corolla 2.0 D4D 90 5DR TERRA COMFORT 4/5-Doors	110,404	90	2,000	16,950
TOYOTA Corolla 2.0 D4D 90 5DR TERRA COMFORT 4/5-Doors	100,250	90	2,000	16,950
TOYOTA Corolla 2.0 D4D 90 5DR SOL 4/5-Doors	84,000	90	2,000	19,000
TOYOTA Corolla 2.0 D4D 90 5DR TERRA 4/5-Doors	79,375	90	2,000	17,950
TOYOTA Corolla 1.4 16V VVT I 5DR TERRA COMFORT 4/5-Doors	75,048	97	1,400	15,800



지도학습 예시 (회귀 Regression, 문제)

❖ 종속변수 (y), 독립변수 (x)

❖ 관측치, 샘플, Observation

The diagram illustrates a data table with four columns and six rows. The first three columns are grouped under the variable x , and the fourth column is labeled y . The first three columns are also grouped under the variable p . The entire table is grouped under the variable n . The second row is highlighted with a red border.

x			y
p			
Bedrooms	Sq. feet	Neighborhood	Sale price
3	2000	Normaltown	\$250,000
2	800	Hipsterton	\$300,000
2	850	Normaltown	\$150,000
1	550	Normaltown	\$78,000
4	2000	Skid Row	\$150,000

지도학습 예시 (분류 Classification, 문제)

❖ 종속변수 (y), 독립변수 (x)


❖ 관측치, 샘플, Observation

The diagram shows a table with 5 rows and 4 columns. The first three columns are grouped under the label x (independent variables), and the fourth column is labeled y (dependent variable). A bracket labeled p spans the first three columns, indicating the number of features. A bracket labeled n spans all four columns of the table, indicating the number of observations. The second row is highlighted with a red border.

x			y
p			
Bedrooms	Sq. feet	Neighborhood	Sale price
3	2000	Normaltown	High
2	800	Hipsterton	Low
2	850	Normaltown	High
1	550	Normaltown	Low
4	2000	Skid Row	High

비지도학습 (Unsupervised Learning)


- ❖ 학습데이터에 내재되어 있는 숨은 구조를 찾아내는 학습법
- ❖ 관측치 단 - 군집화, 변수 단 - 차원 축소



x

군집화


- ❖ 유사한 속성들을 갖는 관측치들을 묶어 전체 데이터를 몇 개의 군집(그룹)으로 나누는 것




군집화

- 데이터가 어떻게 구성되었는지를 알아내는 문제를 푸는 방법론
- 입력값(X)에 대한 목표값(Y)이 없다.

지도 학습




비지도 학습



군집화




❖ 군집화 기준

- 동일한 군집에 속한 관측치들은 서로 유사할수록 좋음
- 상이한 군집에 속한 관측치들은 서로 다를수록 좋음
- 유사도는 관측치가 거리 (distance)를 이용해 측정





차원 축소

- ❖ 3D → 2D → 1D
- ❖ 변수추출(feature extraction)을 차원 축소(dimension reduction)의 용도로 널리 쓰임



차원 축소


•Dimension Reduction & Visualization - CIFAR10 dataset



차원 축소

- Dimension Reduction & Visualization - MNIST dataset


0	4	1	9	2	1	3	1	4	3
5	3	6	1	7	2	8	6	9	4
0	9	1	1	2	4	3	2	7	3
8	6	9	0	5	6	0	7	6	1
8	7	9	3	9	8	5	9	3	3
0	7	4	9	8	0	9	4	1	4
4	6	0	4	5	6	1	0	0	1
7	1	6	3	0	2	1	1	7	9
0	2	6	7	8	3	9	0	4	6
7	4	6	8	0	7	8	3	1	5




차원 축소

❖ 주성분 분석 vs Auto Encoder

A 주성분 분석



B Auto Encoder



3	4	2	1	9	5	6	2	1	8
8	9	1	2	5	0	0	6	6	4
6	7	0	1	6	3	6	3	7	0
3	7	7	9	4	6	6	1	8	2
2	9	3	4	3	9	8	1	2	5
1	5	9	8	3	6	5	7	2	3
9	3	1	9	1	5	8	0	8	4
5	6	2	6	8	5	8	8	9	9
3	7	7	0	9	4	8	5	4	3
7	2	6	4	1	0	6	9	2	3

Text Analytics Applications (Unsupervised Learning)

❖ Simple Task: 문서 요약 및 시각화

강의평가 이용한 word cloud

강의평가 데이터.txt - Windows 메모장

파일(F) 편집(E) 서식(O) 보기(V) 도움말(H)

교수님이 학생들의 질문을 귀기울여 들어주시는 것이 매우 좋았습니다.

다만 학생 입장에서 뭔가를 배울 때 먹살 잡고 끌려가는 기분일까요,, 교수님의 열정 한 학기동안 노고에 감사드립니다. 교수님의 열정 잃지 않으시길 바랄게요^^ "

1학기 인공지능 수업 감사했습니다 교수님.

교수님께서 열정적이셔서 저도 더 집중해 공부할 수 있었던 것 같습니다. 강의 내용도 두
처음으로 대학 들어와서 대학 강의의 다운 강의를 들은 것 같아 좋았습니다. 그러나 이 강:
감사합니다

없습니다

난이도가 매우 어려워서 힘들었지만 교수님이 정말 열정적인분 같아서 좋았습니다
수업이 유익하고 배우기 좋았다

교수님의 열정은 좋지만 과목자체의 난이도가 매우높았음

감사합니다

없음

처음 배우는 분야라 어려웠지만, 많은것을 배웠다.

한학기동안 잘들었습니다

한 학기동안 좋은 강의 해주셔서 감사합니다.

감사합니다

한학기동안 고생많으셨습니다!! 다음에는 조금 난이도 낮춰주시면 좋을거같습니다ㅠㅠ

없습니다

고생하셨습니다

좋은 강의 감사드립니다

수고하셨습니다

감사합니다!

좋은 강의였습니다



내용자체가 많이 어려웠다.

너무 좋았습니다

한학기 수고많으셨습니다

인공지능의 이론적인 부분을 알게된건 좋았지만 난이도가 너무 높았고 학부 수준에서는

2



Text Analytics Applications (Unsupervised Learning)

❖ Simple Task: 문서 요약 및 시각화

강의평가 이용한 word cloud

불용어/토큰화 등 전처리

```

korean_stopwords.extend(['어서', '의', '어', '는', '고', '를', '라', '교수님', '강의', '저만', '께서', '!', '수업', '게', '도',
                          '습니다', '동안', '나', '있', '었', '시', '을', '는', '은', '하기', '있어', '다', '아서', '!', '보니다'])

from konlpy.tag import Kkma
from konlpy.tag import Okt

kkma = Kkma()


okt = Okt()

new_corpus= []

i = 1
for comment in data:
    ....
    ...#(1) Tokenize
    ...tokens = kkma.morphs(comment)
    ....
    ...for token in tokens:
    .......#(2) stop word
    .......if token not in korean_stopwords:
    .......    new_corpus.append(token)

...if i%100==0:
...    print(i)
...    i += 1

```




Text Analytics Applications (Unsupervised Learning)

✓ Central Bank speech analysis: Similarities between the central banks in the world



이창을 한국은행 총재가 통화정책방향 기자회견단회에서 취재진의 질문에 답하고 있다. (사진=연합뉴스)



Text Analytics Applications (Unsupervised Learning)

✓ Central Bank speech analysis: Similarities between the central banks in the world


Year	Common Concern	Federal Reserve System	European Central Bank	Deutsche Bundesbank	Bank of England	Bank of Japan
2004	Sustainability Credibility	Expansion Imports	Parliaments Cooperation	Retirement Ages Working Hours	Household-Spending	QE Deflation
2005	China Inflation	Deficits Competitive	Financial Integration	Global Imbalance	Households Future Inflation	QE Recession
2006	Competitive Global Imbalance	Incentives Risk Taking	Administered Price Indirect Taxes	Inflation	China / India Commodities	Domestic and- External Demand
2007	Subprime-Mortgage	Subprime-Mortgage	Price Stability Turmoil	Banking Supervision Disclosure	Credit	Subprime-Mortgage
2008	Financial Turmoil Commodity Prices	Financial Turmoil Funding Markets	Financial Turmoil Liquidity	Financial Turmoil Subprime	Commodity Prices Housing Market	Securitized Product
2009	Financial Crisis Lehman Brothers	Financial Crisis ABS	Non-standard-Measure	Financial Crisis Rescue	Asset Purchase Recovery	Credit Bubble Financial Crisis
2010	Recovery Reform	Recovery Recession	ESRB/ FSB Deficits	Microprudential Macprudential	Recovery/ QE VAT/ TAX	Deflation
2011	Sovereign Debt Basel III	Dodd-Franc Act Recovery	Sovereign Debt EFSF	Debt Crisis Basel III	Commodity Prices Basel III	Asset Purchase ETFs / REITs
2012	Europe Deleveraging	Recovery (has been) Labor Market	OMT/ ESM/ SSM Fragmentation	Banking Union Taxpayer	Investment-Banking	European Debt Deleveraging
2013	Real Economy Price Stability	(At least as long as) Unemployment	SRM/ SSM/ OMT	SRM / SSM Banking Union	Prudential-Regulation	Price Stability QE

Text Analytics Applications (Unsupervised Learning)

- Topic Extraction

- ✓ Analyze documents and extract latent topics in the corpus

Figure 2. Real inference with LDA. We fit a 100-topic LDA model to 17,000 articles from the journal *Science*. At left are the inferred topic proportions for the example article in Figure 1. At right are the top 15 most frequent words from the most frequent topics found in this article.



Text Analytics Applications (Unsupervised Learning)

- Topic Extraction


✓ 30 Topics discovered by LDA

Fault detection with DBN	Convolutional neural network	Network Learning	Representation learning	Face Recognition	Speech Recognition	Acoustic Modeling	Extreme Learning	Deep learning architecture	Image Segmentation
deep belief network dbn fault	neural convolutional pool convolution convnet	layer input output unit hide function	feature level extract learn extraction	face recognition estimation facial shape	speaker speech noise adaptation source	speech recognition acoustic hmm neural	deep learn algorithm structure extreme	deep architecture neural standard explore	image scene scale segmentation pixel
Long-short term memory	Predictive analytics	Signal processing	Classification models	Large-scale computing	Image quality assessment	Visual recognition	NLP	Detection using CNN	Action recognition
term recurrent long lstm network	data prediction technique information research	analysis filter signal component audio	classification classifier class vector support	application implementation efficient process power	domain state quality resolution relationship	pattern process compute visual field	word text language representation semantic	cnn detection convolutional neural detect	video human temporal action track
Image retrieval	Medical image diagnosis	Reinforcement learning	Parameter optimization	Auto encoder	RBM and variations	Learning with few labeled data	Fast learning complexity reduction	Applications for vehicles & robots	Character recognition
image visual retrieval descriptor attribute	image segmentation disease cell medical	learn question state answer reinforcement	train algorithm gradient sample optimization	representation learn sparse encode stack	machine boltzmann rbm restrict distribution	train data label few transfer	fast reduce parameter weight complexity	time real application drive Vehicle	recognition system character network neural

Text Analytics Applications (Unsupervised Learning)

- Topic Extraction


✓ Relations between topics




Text Analytics Applications (supervised Learning)

❖ 문서 분류

스팸 메일/문자



Gmail 기능



Spam classification at a high level. Source: developers.google.com

스팸함의 메일은 30일 후에 자동 삭제됩니다. 지금 모든 스팸 메일 삭제		
☐ ☆	Medium Daily Digest	Predicting Titanic Survivors using ML Mi...  
☐ ☆	sales8	교수님 안녕하세요. 2학기 인공지능 실습 참고자료 공...
☐ ☆	Medium Daily Digest	Text Summarization using Deep Learning Priya Dwi...
☐ ☆	리서치컴퍼니	《시장동향》 2차전지 산업의 글로벌 시장 분석과 기술 ...
☐ ☆	주식회사 우레	[자료전달_드론제어 실습장비 소개]안녕하세요 (주) 우...
☐ ☆	Medium Daily Digest	Your Guide to Natural Language Processing (NLP) ...
☐ ☆	Medium Daily Digest	Logistic Regression with Python ODSC - Open Data ...
☐ ☆	Medium Daily Digest	Puzzle: Make 1 litre of water using a 23 litre bucket ...
☐ ☆	Medium Daily Digest	Evolving the Partner Program Medium Staff in 3 mi...
☐ ☆	산업경제리서치	[시장분석] "미래 인공지능 시스템 정책과 시장 분석 및 메타...
☐ ☆	산업경제리서치	[시장분석] "2021년 스마트병원/원격의료와 의료기기 ...
☐ ☆	산업경제리서치	[시장분석] "2021년 제품별/업체별 시장규모 총람" - "2...
☐ ☆	리서치컴퍼니	《산업동향》 국내외 디지털 헬스케어 및 차세대 의료기...
☐ ☆	Medium Daily Digest	LOGISTIC REGRESSION CLASSIFIER Caglar Subasi ...
☐ ☆	Medium Daily Digest	Text Classification Using Naive Bayes: Theory & A W...
☐ ☆	닐슨컴퍼니코리아	2021 수업목적 저작물 이용 실태조사에 참여 부탁 드...
☐ ☆	Medium Daily Digest	Support Vector Machine (SVM). Machine Learning f...
☐ ☆	산업경제리서치	[보고서] "2021년 국내외 (박)데이터 시장분석과 해외...
☐ ☆	리서치컴퍼니	《산업동향》2021 제품별 · 업체별 시장규모총람 - "202...

Text Analytics Applications (supervised Learning)

❖ 문서 분류

스팸함의 메일은 30일 후에 자동 삭제됩니다. 지금 모든 스팸 메일 삭제	
☐ ☆ Medium Daily Digest	Predicting Titanic Survivors using ML Mi...
☐ ☆ sales8	교수님 안녕하세요. 2학기 인공지능 실습 참고자료 공...
☐ ☆ Medium Daily Digest	Text Summarization using Deep Learning Priya Dwi...
☐ ☆ 리서치컴퍼니	《시장동향》 2차전지 산업의 글로벌 시장 분석과 기술 ...
☐ ☆ 주식회사 우레	[자료전달_드론제어 실습장비 소개]안녕하세요 (주) 우...
☐ ☆ Medium Daily Digest	Your Guide to Natural Language Processing (NLP) ...
☐ ☆ Medium Daily Digest	Logistic Regression with Python ODSC - Open Data ...
☐ ☆ Medium Daily Digest	Puzzle: Make 1 litre of water using a 23 litre bucket ...
☐ ☆ Medium Daily Digest	Evolving the Partner Program Medium Staff in 3 mi...
☐ ☆ 산업경제리서치	[시장분석] "미래 인공지능 시스템 정책과 시장 분석 및 메타...
☐ ☆ 산업경제리서치	[시장분석] "2021년 스마트병원/원격의료와 의료기기 ...
☐ ☆ 산업경제리서치	[시장분석] "2021년 제품별/업체별 시장규모 총람" - "2...
☐ ☆ 리서치컴퍼니	《산업동향》 국내외 디지털 헬스케어 및 차세대 의료기...
☐ ☆ Medium Daily Digest	LOGISTIC REGRESSION CLASSIFIER Caglar Subasi ...
☐ ☆ Medium Daily Digest	Text Classification Using Naive Bayes: Theory & A W...
☐ ☆ 닐슨컴퍼니코리아	2021 수업록적 저작물 이용 실태조사에 참여 부탁 드...
☐ ☆ Medium Daily Digest	Support Vector Machine (SVM). Machine Learning f...
☐ ☆ 산업경제리서치	[보고서] "2021년 국내외 (빅)데이터 시장분석과 해외...
☐ ☆ 리서치컴퍼니	《산업동향》 2021 제품별 · 업체별 시장규모총람 - "20...

교수님 안녕하세요. 2학기 인공지능 실습 참고자료 공유드립니다.

외부 스팸함 x

sales8 <sales8@aiposeidon.com>

8월 31일 (화) 오후 4:49 (2일 전)

kycho, pjh, onamjin, kbko, khw, jaesung.lee, clim, smlim, c.song, mgkang, hogijung, ohnnuri, thyang, psji, yheong, kang, moon, kujun



이 메일이 스팸으로 분류된 이유는 무엇인가요? 이전에 aiposeidon.com에서 보낸 다수의 메일이 스팸으로 확인되었습니다.

스팸이 아님

영어 > 한국어 메일 번역

영어 번역 안함 x

폴단지 신청하기!

POSEIDON α & β Series 더 알아보기

POSEIDON 을 사용중인 대학교

Contact

02-717-1089


sales@baroAI.com

[Click here to unsubscribe](#)

Text Analytics Applications (supervised Learning)

❖ 문서 분류


✓ Spam mail filtering



Text Analytics Applications (supervised Learning)

❖ 문서 분류)

✓ Sport player evaluation



Text Analytics Applications (supervised Learning)

❖ 문서 분류)

✓ Sentiment Analysis

Player	Line	Score	승	패배	피안타	피홈런	볼넷	실점	평균 자책점	이닝당 삼진	이닝당 볼넷	삼진 /볼넷	방어율
웨이	NC 웨이는 7이닝 동안 1안타 3볼넷 10탈삼진으로 무실점 호투했다.	0.991	1	0	0	0	1	0	0	1	1	1	0
이재학	이재학 '10승' 3년만에 달라진 위상 증명하다	0.986	1	0	0	1	0	1	0	0	0	1	0
이태양	'이태양 완벽투' NC LG 상대로 창단 첫 스윙	0.966	1	0	0	0	0	0	0	0	0	1	0
에릭	한편, 이날 7이닝 3실점으로 잘 던지며 7경기 만에 국내 첫 승을 거둔 에릭은 "굉장히 흥분된다.	0.803	1	0	1	0	0	0	0	0	0	0	0
찰리	어이없는 실책 2개가 나오자 찰리는 흔들리기 시작했다.	0.506	0	1	1	1	0	1	0	1	0	1	1
찰리	찰리가 대량 실점을 했지만 그 과정에서 3루수 모창민과 1루수 테임즈의 실책이 동반되면서 자책은 1점 밖에 되지 않았다.	0.506	0	1	1	1	0	1	0	1	0	1	1
원종현	NC 원종현이 패전투수가 됐다.	0.293	0	1	0	0	0	1	1	1	0	1	1
원종현	세 번째 투수로 등판한 원종현 역시 1사 후 8번 김성현에게 솔로포를 맞았다.	0.102	0	0	0	1	1	0	1	1	1	0	0
이재학	NC 선발 이재학은 8이닝 8피안타(2홈런) 5탈삼진 3볼넷 2실점을 기록했다.	0.079	0	0	1	1	0	1	1	0	0	0	1
이해천	이해천이 올라온 뒤 한꺼번에 5점을 내주면서 맥빠진 경기가 되고 말았다.	0.066	0	0	1	1	0	1	0	0	1	0	0

Text Analytics Applications (supervised Learning)

❖ 문서 분류 – sentiment analysis (감성분석)

   이번 주 도움돼요

기대가 너무 컸던 탓일까요?
예전엔 알볼로 많이 먹었는데 피자도 피클도 기대 이하네요

사장님 그제
그 어떤 기대를 말하는 건가요?
그대의 목소리에는 사람의 향기가 하나도 느껴지지 않아요~♪
설령 그대의 잘못이지만 매장에서 피자한판을 더 구워 그대에게 전해줬더라도
그대의 씩레기같은 삶의 단면이 나아질까요??
다음 생에는 제발 인간으로 다시 태어나길 간절히 기도하겠습니다
이번생은 그대와 그대의 가정에 저주가 함께 하길.....!

많이 힘들죠 그렇게 살려니
제가 아는 해변이 하나 있는데 그곳에 가서 쉬시죠
그 해변 이름은...

son of a bitch



브랜드 상호 분석 고객 코멘트 분석



$$\text{NET PROMOTER SCORE} = \% \text{PROMOTERS} - \% \text{DETRACTORS}$$

제품을 추천/비추천/중립하는 코멘트 분석

Text Analytics Applications (supervised Learning)

❖ 문서 분류 – sentiment analysis (감성분석)

 dmsd*** >
★★★★★ 작년

급하게 먹느라 사진을 못찍었어요 전 근데 스시 안좋아하거든요 근데 다음에 또먹죠 뭐;;

사장님 작년

dmsd***님, 감사합니다.^^
제가 이해하기에 조금은 난해한 리뷰입니다.^^;; 스시를 안좋아 하시지만 그런데로 입에 맞으셨고, 그래서 다음에 또 들려주시겠다는 말씀으로 이해하면 될까요?
못드시거나 입에 맞지 않는 재료들은 요청사항에 남겨주시며 반영해서 만들어 보내드립니다.~ 다음에 꼭 다시한번 들려주세요. 정말 맛있게 만들어 보내드릴게요.^^

브랜드 상호 분석 고객 코멘트 분석




$$\text{NET PROMOTER SCORE} = \% \text{PROMOTERS} - \% \text{DETRACTORS}$$

제품을 추천/비추천/중립하는 코멘트 분석

Text Analytics Applications (supervised Learning)

❖ 문서 분류 – sentiment analysis (감성분석)

✓ Sentiment Analysis



Text Analytics Applications (supervised Learning)

❖ 문서 분류 – sentiment analysis (감성분석)

✓ Sentiment Analysis

Methodology	Sentence
Raw text	I hate this movie. It is a horrid movie. Sean Young's character is completely unsympathetic. Her performance is wooden at best. The storyline is completely predictable and completely uninteresting. I would never recommend this film to anyone. It is one of the worst movies I have ever had the misfortune to see. (1 / 10 points)
Class Activation CAM ² -Rand	I hate this movie It is a horrid movie Sean Young s character is completely unsympathetic He r performance is wooden atbest The storyline is completely predictable and completely uninteresting I would never recommend this film to anyone It is one of the worst movies I have ever had the misfortune to see Negative
CAM ² -Static	I hate this movie It is a horrid movie Sean Young s character is completely unsympathetic He r performance is wooden atbest The storyline is completely predictable and completely uninteresting I would never recommend this film to anyone It is one of the worst movies I have ever had the misfortune to see Negative
CAM ² -Non-Static	I hate this movie It is a horrid movie Sean Young s character is completely unsympathetic He r performance is wooden atbest The storyline is completely predictable and completely uninteresting I would never recommend this film to anyone It is one of the worst movies I have ever had the misfortune to see Negative
CAM ² -2channel	I hate this movie It is a horrid movie Sean Young s character is completely unsympathetic He r performance is woodenat best The storyline is completely predictable and completely uninteresting I would never recommend this film to anyone It is one of the worst movies I have ever had the misfortune to see Negative
CAM ² -4channel	I hate this movie It is a horrid movie Sean Young s character is completely unsympathetic He r performance is woodenat best The storyline is completely predictable and completely uninteresting I would never recommend this film to anyone It is one of the worst movies I have ever had the misfortune to see Negative
HAN	I hate this movie It is a horrid movie Sean Youngs character is completely unsympathetic He rperformance is wooden at best The storyline is completely predictable and completely uninteresting I would never recommend this film to anyone It is one of the worst movies I have ver had the misfortune to see Negative

Text Analytics Applications (supervised Learning)

❖ 문서 분류


- 범행 조사서, 진술서 등을 이용해서 자동 범죄분류 모델 구축
- 신규 범죄 유형 탐지 및 의미 없는 범죄 유형 제거

과제 목표: 신종 범죄수법에 대응한 경찰 범죄수법 분류체계 개선

▶ 범행수법 현황 파악 및 다차원 분석



▶ 집중화 그룹 인터뷰(FGI) 및 전문가 인터뷰



▶ 범죄수법 예측결과 기반 기존범죄 분류 체계 개선




Text Analytics Applications (supervised Learning)

❖ 추천시스템

sentiment analysis (감성분석)

- Recommendation

- ✓ Analyze texts in daum café, blogs, and SNS contents
- ✓ Named entity recognition/extraction (NEE/NER) technique in natural language processing is used
- ✓ For 60,000 keywords



Text Analytics Applications (supervised Learning)


❖ 추천시스템

sentiment analysis (감성분석)

- Recommendation

- ✓ Dining code: restaurant recommendation service

- Analyze restaurant review from top 3 blog services (naver, daum, tistory)
 - Assign higher weights to opinion leaders' posts
 - Filter advertising blog posts by analyzing the comments on a post




Text Analytics Applications (supervised Learning)

❖ 정형데이터 + 비정형 데이터 혼합 기반 상품 판매량 (수요예측)

과거 판매정보, 유사 제품 판매량 정보 + 고객의 제품에 대한 기대 평가 정보

[수요 예측]



#갤럭시z플립3크림


#갤럭시Z플립사전예약

T 다이렉트샵에서 지난주 토요일(8/21)
사전예약을 했고, 어제(8/27) 받아보았으니
딱 일주일 걸렸네요!

삼성 갤럭시 z플립3 컬러가 제법
다양하더라고요?

팬텀 블랙, 크림, 그린, 라벤더
그리고 삼성닷컴 단독 컬러로 나온
화이트, 핑크, 그레이까지!

저는 라벤더랑 크림 고민하다가
크림으로 최종 결정했고
결론적으로 매우 만족합니다 '^^'



Text Analytics Applications (supervised Learning)

❖ 정형데이터 + 비정형 데이터 혼합 기반 상품 판매량 (수요예측)

과거 판매정보, 유사 제품 판매량 정보 + 고객의 제품에 대한 기대 평가 정보



#갤럭시z플립3크림

#갤럭시z플립사전예약

T 다이렉트샵에서 지난주 토요일(8/21)
사전예약을 했고, 어제(8/27) 받아보았으니
딱 일주일 걸렸네요!

삼성 갤럭시 z플립3 컬러가 제법
다양하더라고요?

팬텀 블랙, 크림, 그린, 라벤더
그리고 삼성닷컴 단독 컬러로 나온
화이트, 핑크, 그레이까지!

저는 라벤더랑 크림 고민하다가
크림으로 최종 결정했고
결론적으로 매우 만족합니다 'ㄷ'

Text Analytics Tasks

❖ 문서요약 (Document Summarization)

다양한 Article

뉴스기사 요약, 법률문서 요약, 사업보고서 요약

Mode-wise Tensor Decompositions: Multi-dimensional Generalizations of CUR Decompositions

HanQin Cai
Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

HQCAI@MATH.UCLA.EDU

Keaton Hamm
Department of Mathematics
University of Texas at Arlington
Arlington, TX 76019, USA

KEATON.HAMM@UTA.EDU

Longxiu Huang
Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA

HUANGL3@MATH.UCLA.EDU

Deanna Needell
Department of Mathematics
University of California, Los Angeles
Los Angeles, CA 90095, USA


DEANNA@MATH.UCLA.EDU

Editor: Michael Mahoney

Abstract

Low rank tensor approximation is a fundamental tool in modern machine learning and data science. In this paper, we study the characterization, perturbation analysis, and an efficient sampling strategy for two primary tensor CUR approximations, namely Chidori and Fiber CUR. We characterize exact tensor CUR decompositions for low multilinear rank tensors. We also present theoretical error bounds of the tensor CUR approximations when (adversarial or Gaussian) noise appears. Moreover, we show that low cost uniform sampling is sufficient for tensor CUR approximations if the tensor has an incoherent structure. Empirical performance evaluations, with both synthetic and real-world datasets, establish the speed advantage of the tensor CUR approximations over other state-of-the-art low multilinear rank tensor approximations.

Keywords: tensor decomposition, low-rank tensor approximation, CUR decomposition, randomized linear algebra, hyperspectral image compression



1. 요약문 추출 Task

2. 요약문 생성 Task

Text Analytics Applications (supervised Learning)


❖ 문서요약 (Document Summarization)

뉴스기사 요약, 법률문서 요약, 사업보고서 요약

정치면 뉴스

["정세균 국무총리가 21일 오전 서울시청에서 열린 코로나 19 대응 중앙재난안전대책본부(중대본) 회의에서 발언하고 있다."] "연합 뉴스정세균 국무총리는 21일 "(코로나 19) 관련 허위조작정보 생산 및 유포행위에 무관용 원칙으로 법에 따라 엄정 대응하겠다"라고 말했다." "정 총리는 이날 서울시청에서 주재한 코로나 19 중앙재난안전대책본부 회의에서 "코로나 19 위기가 계속되는 상황에서 '사회적 거리 두기' 3단계 확정, '생필품 사재기 조짐' 등 허위조작정보가 다시 기승을 부리고 있다"며 이렇게 말했다."

"정 총리는 "이러한 허위조작정보 유포행위는 불신과 혼란을 조장하고 방역 역량을 저해하는 사회악에 해당한다"며 "방통위, 경찰청 등은 이런 위법행위를 끝까지 추적해 엄벌하라"고 지시했다." "거리두기 3단계"에는 선을 그었다." 정 총리는 "(수도권 거리 두기 2.5단계로) 확진자 수가 당장은 줄지 않았으나 휴대폰과 교통 이동량 등이 감소세에 있고 공격적 진단검사로 60살 이상 확진자 비율도 줄어드는 긍정적 신호가 있다"고 평가했다. "그러면서 "거리 두기 단계 조정은 치밀하게 준비하되 마지막 카드가 되어야 한다. "감염 취약시설로 확인된 요양병원, 요양시설, 정신병원, 스키장 등에 대한 특단의 방역 대책이 필요하다"고 강조했다." "연말연시를 맞아 방역대책 강화도 주문했다." "정 총리는 "중수본(중앙사고수습본부)은 한층 강화한 연말연시 특별방역대책을 마련해 신속하게 시행해 달라"며 "고강도 방역대책에 따른 고통을 정부가 모른 척해서도 안 되는 만큼 재정 당국은 합리적 지원대책을 검토하라"고 말했다."



1. 요약 문장 추출Task

정 총리는 이날 서울시청에서 주재한 코로나 19 중앙재난안전대책본부 회의에서 "코로나 19 위기가 계속되는 상황에서 '사회적 거리 두기' 3단계 확정, '생필품 사재기 조짐' 등 허위조작정보가 다시 기승을 부리고 있다"며 이렇게 말했다."


"정 총리는 "이러한 허위조작정보 유포행위는 불신과 혼란을 조장하고 방역 역량을 저해하는 사회악에 해당한다"며 "방통위, 경찰청 등은 이런 위법행위를 끝까지 추적해 엄벌하라"고 지시했다."

에 내안 특단의 방역 대책이 필요하냐"고 상소했다." "연말연시를 맞아 방역대책 강화도 주문했다." "정 총리는 "중수본(중앙사고수습본부)은 한층 강화한 연말연시 특별방역대책을 마련해 신속하게 시행해 달라"며 "고강도 방역대책에 따른 고통을 정부가 모른 척해서도 안 되는 만큼 재정 당국은 합리적 지원대책을 검토하라"고 말했다."

Text Analytics Applications (un+supervised Learning)

❖ 문서요약 (Document Summarization)

정치면 뉴스



뉴스기사 요약, 법률문서 요약, 사업보고서 요약

2. 요약문 생성 Task

제목 : [그래픽] 미국 대선 승패 핵심
경합주 개표 상황

요약 : (서울=연합뉴스) 이재운 기자
= 미국 대선 승자가 개표 나흘째인
6일(현지시간)까지도 확정되지
않으면서 미국뿐만 아니라 전세계
이목이 네바다, 펜실베이니아 등에
쏠리게 됐다. 이들 주(州)에서는
개표율이 일찌감치 90%를
넘어섰는데도 정작 마지막 남은 몇%를
세는 데 몇날 며칠이

자세히 보기

example

Text Analytics Applications (un+ supervised Learning)

❖ 번역 (Translation)

인간-AI 번역 대결 결과		
순위	번역	점수(60점 만점)
1위	인간	49
2위	구글	28
3위	네이버	17
4위	시스트란	15

Facebook AI leads in 2019 WMT international machine translation competition

August 01, 2019



인간 대 인공지능 번역대결

For this language direction, our translations have been declared superhuman by the WMT organizers, meaning that human evaluators preferred them over translations done by human experts.

Text Analytics Applications (un+supervised Learning)

❖ Natural Language Understanding: Question Answering



고객상담 업무에 도입된 인공지능(AI) 솔루션

회사	서비스 내용
SK텔레콤	차세대 AI 챗봇·AI 보이스봇 개발 검토
KT	AI 상담 어시스트, AI 챗봇, AI 목소리 인증 적용. 연내 AI 보이스봇 도입
LG유플러스	자사 홈페이지·온라인 쇼핑몰에 'U봇' 등 AI 챗봇 적용
삼성SDS	음성인식 등을 활용한 브리티 컨택센터 삼성 계열사에 적용
카카오	챗봇 1만7,000개 이상이 카카오톡 기반으로 운영 중

※ 자료=각 사

〈사진 제공=게티이미지뱅크〉



Text Analytics Applications (un+supervised Learning)

❖ Natural Language Understanding: Question Answering

ChatGPT's Unique Blend of Supervised and Unsupervised Learning

Chatgpt works with this combination of supervised and unsupervised learning which increases its power of adaptability.

- During its initial training, ChatGPT receives vast amounts of internet text in an unsupervised manner. It becomes a language expert, soaking in the nuances of human expression.
- Then comes the supervised learning phase, where ChatGPT refines its skills for specific tasks or domains. It's like taking that newfound language proficiency and tailoring it to excel in specific scenarios.
- This combined approach is what makes ChatGPT a versatile [conversational AI](#), which can understand versatile user inputs and deliver relevant answers.

Text Analytics Applications (un+supervised Learning)

❖ Natural Language Understanding: Question Answering

1. 텍스트 분류(Task: Text Classification)

이 작업에서는 모델이 주어진 텍스트를 특정 범주나 클래스에 분류할 수 있도록 학습됩니다.

- **입력 데이터:** 뉴스 기사 제목, 소셜 미디어 게시물, 리뷰 등
- **라벨 데이터:** 해당 텍스트가 속한 카테고리 또는 감정 (예: 긍정, 부정, 중립)

예시:

- 입력: "이 영화 정말 재미있었어!"
- 라벨: 긍정
- 입력: "서비스가 형편없어요."
- 라벨: 부정

이 경우, 모델은 각 텍스트를 '긍정', '부정', '중립' 같은 감정 상태로 분류하는 법을 학습합니다.

2. 질문-답변(Task: Question Answering)

이 작업에서는 모델이 질문에 대한 답변을 텍스트 내에서 찾아낼 수 있도록 훈련됩니다.

- **입력 데이터:** 질문과 관련된 문단 또는 문서
- **라벨 데이터:** 해당 질문에 대한 정답이 위치한 텍스트 범위

예시:

- 입력(문단): "로마는 이탈리아의 수도이며, 역사적인 랜드마크로 유명합니다."
- 입력(질문): "이탈리아의 수도는 어디인가요?"
- 라벨: "로마"

여기서 모델은 질문에 맞는 정보를 문장에서 찾아내는 법을 학습합니다.

3. 기계 번역(Task: Machine Translation)

이 작업에서는 모델이 하나의 언어에서 다른 언어로 텍스트를 번역하는 방법을 학습합니다.

- **입력 데이터:** 원문 텍스트
- **라벨 데이터:** 번역된 텍스트

예시:

- 입력: "I love programming."
- 라벨: "나는 프로그래밍을 좋아해."

모델은 이러한 문장 쌍을 통해 한 언어에서 다른 언어로 번역하는 방식을 학습합니다.

4. 개체명 인식(Task: Named Entity Recognition, NER)

이 작업에서는 모델이 문장 내에서 특정한 개체(예: 사람, 장소, 날짜 등)를 인식하는 법을 학습합니다.

- **입력 데이터:** 문장
- **라벨 데이터:** 각 단어에 해당하는 개체 유형

예시:

- 입력: "제임스는 2024년에 서울로 이사했습니다."
- 라벨: ["제임스" - 인물(Person), "2024년" - 날짜(Date), "서울" - 장소(Location)]

이 경우, 모델은 문장에서 특정 개체를 인식하고 그 유형을 분류하는 방법을 학습합니다.

5. 요약(Task: Text Summarization)

이 작업에서는 긴 문장을 짧고 핵심적인 요약문으로 바꾸는 방법을 학습합니다.

- **입력 데이터:** 긴 문단 또는 기사
- **라벨 데이터:** 요약된 짧은 문장

예시:

- 입력: "이 영화는 주인공이 전 세계를 여행하며 다양한 모험을 겪는 이야기를 그립니다. 그는 많은 도전에 직면하지만 결국 모든 문제를 해결합니다."
- 라벨: "주인공이 전 세계에서 모험을 하며 문제를 해결하는 이야기."

Text Analytics Applications (un+supervised Learning)

❖ Natural Language Understanding: Question Answering

과정은 대략 다음과 같습니다:

1. 사용자의 질문 이해:

- 제가 받은 입력을 분석하여 사용자가 요청한 작업의 유형을 파악합니다. 예를 들어, 사용자가 감정 분석을 원할 때와 번역을 원할 때는 전혀 다른 방식으로 질문을 처리해야 하기 때문에, 이를 구분하는 것이 중요합니다.

2. 작업 유형 분류:

- 만약 사용자가 특정 문장에 대해 감정을 묻는다면, 이것은 **텍스트 분류** 작업으로 처리됩니다.
- 질문에 대한 답을 찾아달라는 요청은 **질문-답변(Q&A)** 작업으로 분류됩니다.
- 문장을 다른 언어로 바꿔달라는 요청은 **번역**으로 인식됩니다.
- 긴 텍스트를 짧게 줄여달라는 요청은 **요약** 작업으로 처리됩니다.

3. 적용되는 기술 및 모델 사용:

- 작업 유형에 따라 저를 학습시킨 다양한 모델과 알고리즘을 사용하게 됩니다.
- 예를 들어, **번역**을 요청하면 번역 모델이 활성화되고, ****질문-답변(Q&A)****를 요청하면 질문에 맞는 답변을 찾는 모델이 작동합니다.

4. 답변 생성:

- 해당 작업에 적합한 방법을 적용한 후, 결과를 생성해 사용자에게 답변을 제공합니다.

NLP (Natural Language Process) & Text Mining

❖ Natural Language Understanding: Chat Bot

[Browse State-of-the-Art](#) [Datasets](#) [Methods](#) [More ▾](#) [We are hiring!](#)

 Natural Language Processing

Question Answering

1123 papers with code • 64 benchmarks • 249 datasets

Question Answering is the task of answering questions (typically reading comprehension questions), but abstaining when presented with a question that cannot be answered based on the provided context (Image credit: SQuAD)

Benchmarks

[Add a Result](#)

Trend	Dataset	Best Model	Paper Title	Paper	Code	Compare
	SQuAD1.1	🏆 LUKE (single model)				See all
	SQuAD1.1 dev	🏆 T5-11B	Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer			See all
	SQuAD2.0	🏆 IE-Net (ensemble)				See all
	WikiQA	🏆 TANDA-RoBERTa (ASNQ, WikiQA)	TANDA: Transfer and Adapt Pre-Trained Transformer Models for Answer Sentence Selection			See all
	Quora Question Pairs	🏆 XLNet (single model)	XLNet: Generalized Autoregressive Pretraining for Language Understanding			See all

[Question Answering | Papers With Code](#)

NLP & Text Mining

자연어 처리 (NLP, Natural Language Processing)

자연어 처리(自然語處理) 또는 자연 언어 처리(自然言語處理)는 인간의 언어 현상을 컴퓨터와 같은 기계를 이용해서 묘사할 수 있도록 연구하고 이를 구현하는 인공지능의 주요 분야 중 하나다. 자연 언어 처리는 연구 대상이 언어 이기 때문에 당연히도 언어 자체를 연구하는 언어학과 언어 현상의 내적 기재를 탐구하는 언어 인지 과학과 연관이 깊다. 구현을 위해 수학적 통계적 도구를 많이 활용하며 특히 기계학습 도구를 많이 사용하는 대표적인 분야이다. 정보검색, QA 시스템, 문서 자동 분류, 신문기사 클러스터링, 대화형 Agent 등 다양한 응용이 이루어지고 있다.

Text mining


From Wikipedia, the free encyclopedia

Text mining, also referred to as ***text data mining***, similar to **text analytics**, is the process of deriving high-quality information from text. It involves "the discovery by computer of new, previously unknown information, by automatically extracting information from different written resources."^[1] Written resources may include websites, books, emails, reviews, and articles. High-quality information is typically

NLP & Text Mining

자연어 처리 (NLP, Natural Language Processing)

요약 문장 생성 Task




번역



지난 대 인공지능 번역대결

Q&A Chatbot



텍스트 마이닝 Text Mining 시각화



문서분류





추천시스템



NLP & Text Mining: Challenges

✓ High number of possible "dimensions" (word, Sparsity, phrases, etc.)

Language ♦	Approx. no. of headwords ♦	Approx. no. of definitions ♦	Dictionary ♦	Notes ♦
Tamil	1,533,669 		Sorkuvai 	An online open dictionary run by the Tamil Nadu government. ^[3] [citation needed]
Korean	1,149,538 		Urimalsaem	Online open dictionary run by South Korean government, including North Korean dialects(66,172 words). ^[4]
Portuguese	818,000 		Aulete Digital	Online dictionary including expressions. ^[5]
Finnish	800,000 		RedFox Pro	Online dictionary. The free version has over 300,000 Finnish words and the Pro version has over 800,000 Finnish words. The dictionary has agglomerated other dictionaries, such as technical ones, ^[6] and the largest set comes from Wordnet. ^[7] This dictionary essentially does not include inflections.
English	755,865 	1,439,188	English Wiktionary	Contains 780,489 gloss entries and 1,439,188 total definitions. ^{[8][9]}
Swedish	600,000 		Svenska Akademiens ordbok, Swedish Academy	After having completed letters A through T SAOB included 470,000 words, but 600,000 words when the alphabet was completed in 2017.
Korean	511,282 		Standard Korean Language Dictionary ^[10]	Contains 511,282 entries.
Italian	500,000 		Grande Dizionario Hoepli Italiano ^{[11][12]}	The number of "sayable and writable" word-forms is estimated at over 2 million ^[13]
Japanese	500,000 		Nihon Kokugo Daijiten ^[14]	

NLP & Text Mining: Challenges

문장 내에 모호성

“교수님이 동영상에서 최근에는 Text Mining과 NLP 간에 차이가 모호하다고 했다”

“교수님이 강의에서 최근에는 Text Mining과 Natural Language Processing 간에 차이가 모호하다고 했다”

신경-언어프로그래밍(Neuro-Linguistic Programming, **NLP**)은 20세기에 개발된 실용심리학의 한 분야로 인간 행동의 긍정적인 변화를 이끌어 내는 기법을 종합해 놓은 지식 체계의 명칭이다.

[https://ko.wikipedia.org > wiki > 신경언어_프로그래밍](https://ko.wikipedia.org/wiki/신경언어_프로그래밍)

신경언어 프로그래밍 - 위키백과, 우리 모두의 백과사전

NLP & Text Mining: Challenges

문장 내에 모호성

- Challenges
 - ✓ Ambiguity and context sensitivity
 - automobile = car = vehicle = Hyundai



vs.




vs.



NLP & Text Mining: Challenges

- How Unstructured is “Unstructured”? (by Feldman and Sanger)



- ✓ Weakly structured

- Few structural cues to text based layout or markups: research papers, legal memoranda, news stories, etc.


- ✓ Semi-structured

- Extensive format elements, metadata, field labels: E-mail, HTML/XML web pages, pdf files, etc.

- Why is Text Mining Hard?


- ✓ Language itself is ambiguous

- Contexts is needed to clarify
 - Same word with different meanings, different words with same meaning
 - Misspellings, abbreviations, etc.



What is Text Analytics Processing ?

NLP & Text Mining 프로세스



What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (1) 데이터 수집을 어떻게???

Source of text data

Digital library



Corporate document archive



Word Wide Web (WWW)



SNS



Raw Text

What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (1) 데이터 수집을 어떻게??? -Crawling

Raw Text

The screenshot shows a web browser displaying the Wikipedia page for HTML. A red arrow points to the raw text content of the page, which is highlighted in blue. The text describes the history and development of HTML, mentioning Tim Berners-Lee and the CERN project. The browser's developer tools are open at the bottom, showing the 'Elements' tab. The page title is '역사' (History) and the URL is 'ko.wikipedia.org/wiki/HTML'.

Raw Text

역사 [편집]

개발 [편집]

1980년, 유럽 입자 물리 연구소(CERN)의 계약자였던 물리학자 팀 버너스리가 H...
형인 인과이어를 제안하였다. 인과이어는 CERN의 연구원들이 문서를 이용하고 공...
한 체계였다. 1989년에 팀 버너스리는 인터넷 기반 하이퍼텍스트 체계를 제안하는...
작성했다.[2] 버너스 리는 1990년 말에 HTML을 명시하고, 브라우저와 서버 소프트...
성했다. 그 해에 버너스리와 CERN 데이터 시스템 엔지니어 로버트 카일리아우와...
CERN측에 자금 지원을 요청하였지만, 이 프로젝트는 CERN으로부터 정식으로 채택...
했다. 버너스리의 개인적인 기록[3]에 1990년부터 "하이퍼텍스트가 사용되는 여러...
부"를 열거했고 백과사전을 그 목록의 첫 번째로 두었다.

최초 규격 [편집]

HTML 최초의 일반 공개 설명은 1991년 말에 버너스리가 처음으로 인터넷에서 문...
"HTML 태그"(HTML tag)로 부르면서 시작되었다.[4][5]

거대상위 상한가 하한가 시가총액 상위

상한가	하한가	시가총액 상위
KODEX 200선물인버스2X	4,045	▲ 75 +1.89%
KNN	2,210	▲ 445 +25.21%
법온	2,530	- 0.00%
코디엠	298	▼ 10 -3.25%
KODEX 레버리지	15,640	▼ 350 -2.19%
고려산업	4,425	▲ 315 +7.66%

수익률 상위펀드 5개월수익률 순 | 2020.08.17기준

코스닥 835.03 ▼ 19.74 -2.31%

코스피 200 319.24 ▼ 4.09 -1.26%

업종상위

부동산 +3.96%	한국자산.. +7.27%	SK디앤디 +5.49%
한글화물운송과.. +3.52% <td>인터지스 +17.96%<td>현대글로비.. +7.32%</td></td>	인터지스 +17.96% <td>현대글로비.. +7.32%</td>	현대글로비.. +7.32%
다스플레이패널 +3.32% <td>LG디스플레이 +3.40%<td>일진디스플레이 -1.13%</td></td>	LG디스플레이 +3.40% <td>일진디스플레이 -1.13%</td>	일진디스플레이 -1.13%

인기 검색어


1. 삼성전자	58,000	▼ 700
2. 씨젠	221,400	▼ 52,300
3. 셀트리온	304,500	▼ 4,000
4. 엑세스바이오	29,500	▲ 6,800
5. SK하이닉스	80,200	▼ 500

공자사항

임시공휴일(8월 17일) 휴장 안...
주요 재무정보에 최근 4분기 데이...

What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (2) 데이터 전처리




문장 토큰화

Time is an illusion. Lunchtime double so!

형태소 분석

"성호가 자연어처리 수업을 한다."



자립: 성호, 자연어, 처리, 수업

의존: -가, 을-, 하-, -ㄴ 다

(읽-, -었, -다,)


불용어 처리

Korean Stopwords


아	어찌됐든	하기보다는
휴	그위에	차라리
아이구	게다가	하는 편이 낫다
아이쿠	점에서 보아	흐흐
아이고	비추어 보아	놀라다
어	고려하면	상대적으로 말하
나	하게될것이다	자면
우리	일것이다	마치
저희	비교적	아니라면
따라	좀	숫
의해	보다더	그렇지 않으면
을	비하면	그렇지 않다면
를	시키다	안 그러면
에	하게하다	아니었다면

What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (3) 벡터화 또는 임베딩



From unstructured to structured



What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (3) 벡터화 또는 임베딩

From unstructured to structured

S1: Jon likes to watch movies. Mary likes too.


S2: John also likes to watch football game.




Word	S1	S2
John	1	1
Likes	2	1
To	1	1
Watch	1	1
Movies	1	0
Also	0	1
Football	0	1
Games	0	1
Mary	1	0
too	1	0

What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (4) 모델 구축 및 적용



다양한 기계학습 알고리즘 적용 (Supervised Learning or Unsupervised learning)



What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (4) 모델 구축 및 적용

다양한 기계학습 알고리즘 적용 (Supervised Learning or Unsupervised learning)


S1: Jon likes to watch movies. Mary likes too.

S2: John also likes to watch football game.

Word	S1	S2
John	1	1
Likes	2	1
To	1	1
Watch	1	1
Movies	1	0
Also	0	1
Football	0	1
Games	0	1
Mary	1	0
too	1	0


Movie Football

여가 범주로 문장 분류!



What is Text Analytics Processing ?

NLP & Text Mining 프로세스: (5) 예측, 평가, 의미 도출




S1: Jon likes to watch movies. Mary likes too.

S2: John also likes to watch football game.


Word	S1	S2
John	1	1
Likes	2	1
To	1	1
Watch	1	1
Movies	1	0
Also	0	1
Football	0	1
Games	0	1
Mary	1	0
too	1	0

Movie Football

여가 범주로 문장 분류!



Text Analytics



문맥을 어떻게 고려하는가?

- automobile = car = vehicle = Hyundai



vs.



vs.



Summary

- 왜 빅데이터 시대인가?
- 빅데이터 시대와 자연어 처리 분석은 어떤 관계가 있는가?
- 정형과 비정형 데이터는 무슨 차이인가?
- 자연어 처리 또는 텍스트 분석은 방대한 텍스트로부터 정보를 추출하는 것
- 대표적인 응용사례는 시각화, 문서 분류, 추천, 정형 비정형을 혼합, 문서요약, 번역, Q&A 등 굉장히 다양하게 있음